

# **VISÃO COMPUTACIONAL**

# **Visão Computacional**

**3.1. Principais Etapas de um Sistema de Visão Computacional**

**3.2. Visão Humana X Computacional**

**3.3. A Imagem Digital**

**3.4. Histograma de imagem digital**

**3.5. Sistemas de visão binária**

**3.6. Operações pontuais globais em imagens**

# **Principais Etapas de um Sistema de Visão Computacional**

**3.1.1 Aquisição de Imagens**

**3.1.2 Restauração e Realce**

**3.1.3. Segmentação**

**3.1.4. Extração de Atributos ou  
Características**

**3.1.5. Classificação e Reconhecimento**

**3.1.6. Decisão**

# Principais Etapas de um Sistema de Visão Computacional

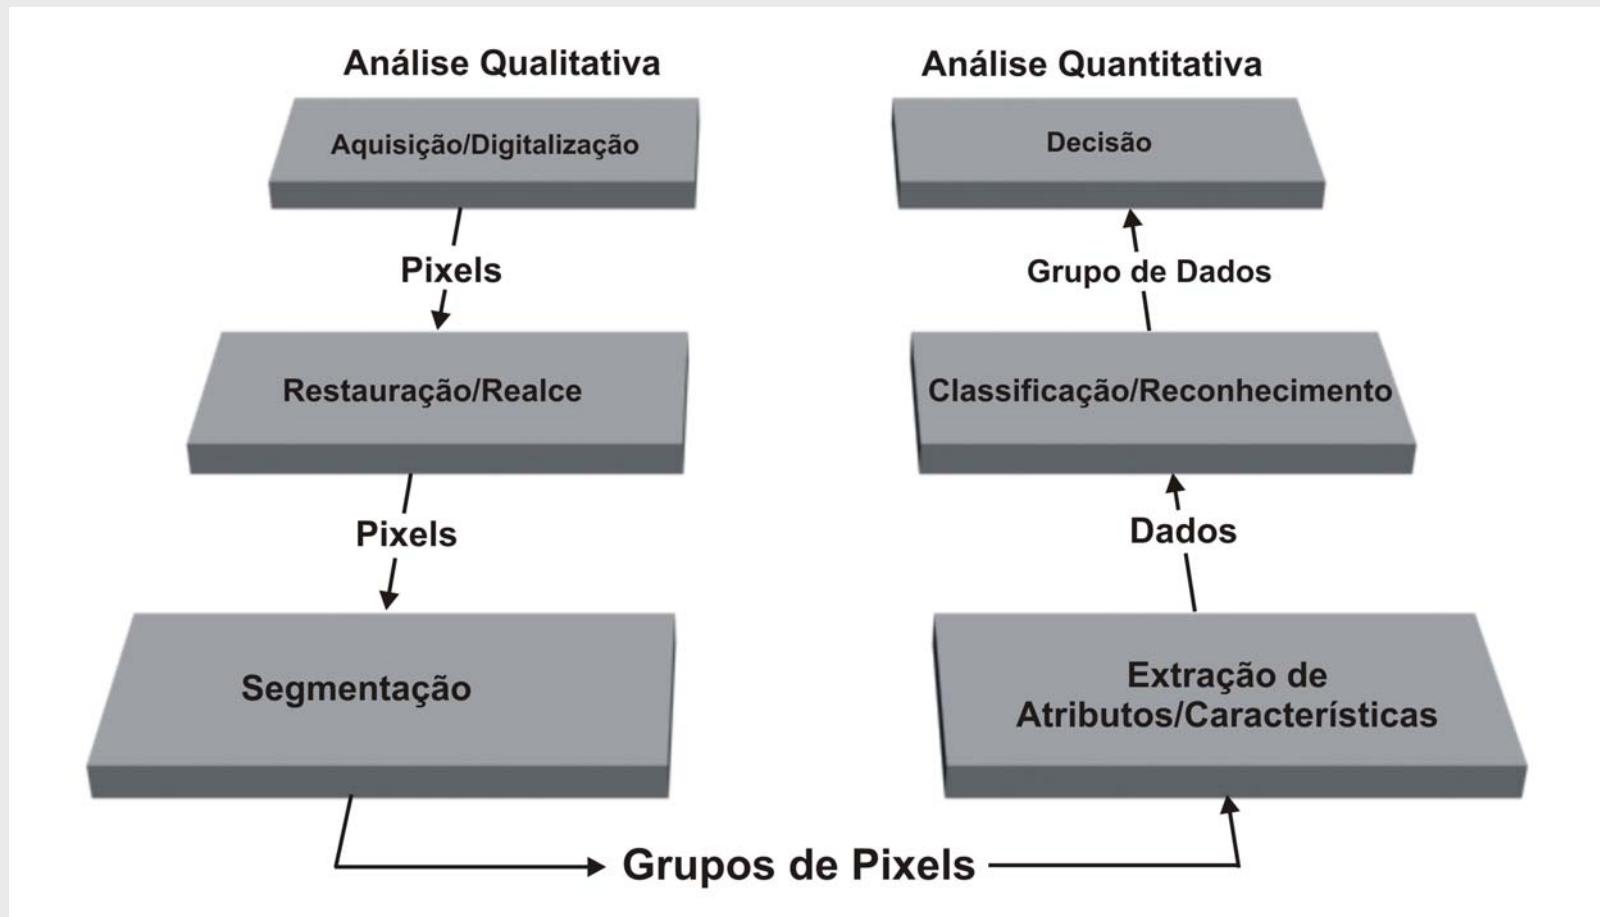
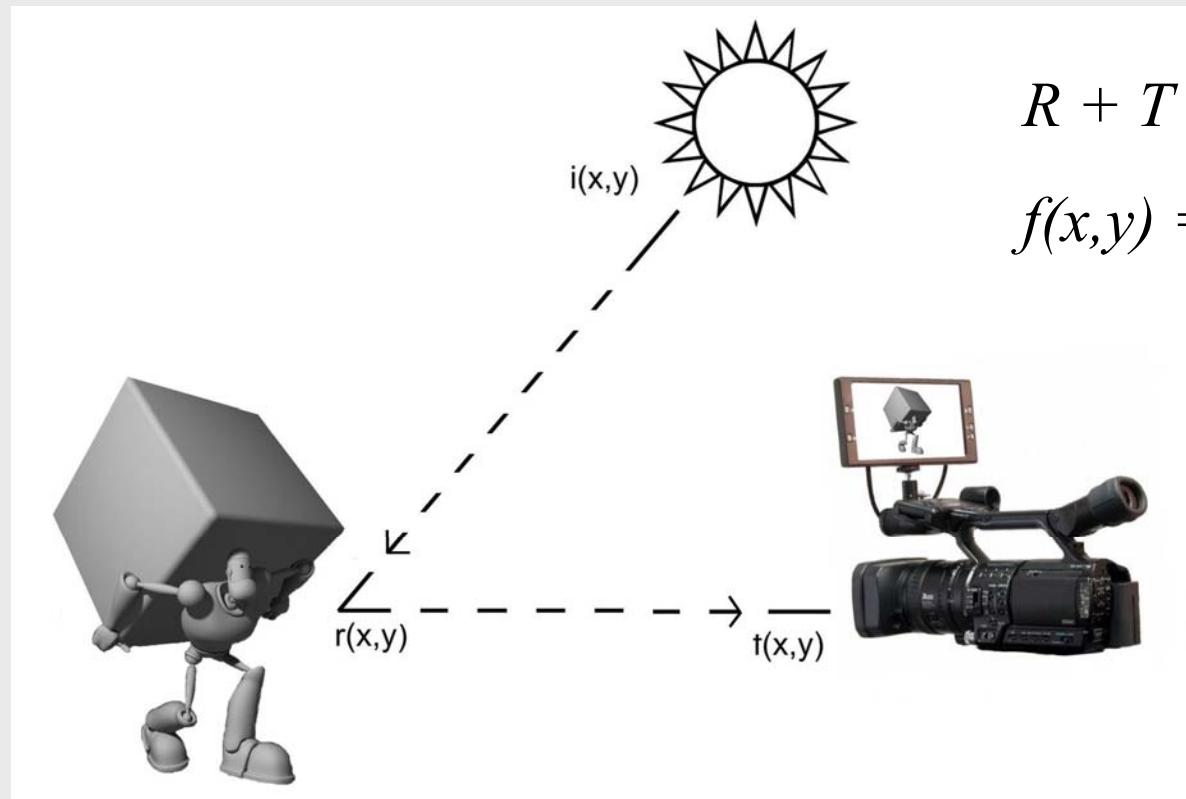


Figura 3.1 – Etapas de um sistema de VC genérico.

# Aquisição de Imagens



$$R + T + A = I \quad (3.1)$$

$$f(x,y) = i(x,y) \cdot r(x,y) \quad (3.2)$$

Figura 3.2 – Aquisição da Imagem.

# Amostragem e Quantização

- Amostragem – refere-se ao número de pontos amostrados de uma imagem digitalizada (resolução).
- Quantização - quantidade de níveis de tons que pode ser atribuído a cada ponto digitalizado.

As imagens reais possuem um número ilimitado de cores ou tons. No processamento de imagens computacional é necessário limitar os níveis de cores ou tons possíveis de serem atribuídos a cada *pixel* da imagem (gradação tonal).

# Resolução



**256 x 160**



**128 x 80**



**64 x 40**

Figura 3.3 – Efeito da redução da resolução espacial na qualidade da imagem

# Quantização



**256 níveis de cinza**



**16 níveis de cinza**

Figura 3.4 – Efeito da variação da gradação tonal ou quantização na qualidade da imagem.

# Restauração e Realce

## Objetivo



- Restauração - busca compensar deficiências específicas, geradas no momento de aquisição, na transmissão ou em alguma etapa do processamento.
- Realce - destaca detalhes da imagem que são de interesse para análise ou que tenham sofrido alguma deteriorização.

# Segmentação

## Objetivo



Isolar regiões de pontos da imagem pertencentes a objetos para posterior extração de atributos e cálculo de parâmetros descritivos.

# Extração de Atributos ou Características

## Objetivo



A partir de imagens já segmentadas (em objeto e fundo) ou binárias busca obter dados relevantes ou atributos, das regiões ou objetos destacados.

Os tipos de atributos ou características mais comuns são: número total de objetos; dimensões; geometria; propriedades de luminosidade e textura.

# Classificação e Reconhecimento

Distinguir objetos na imagem agrupando parâmetros de acordo com sua semelhança para cada região de *pixels* encontrada.

Os objetos são:

reconhecidos como pertencentes a um mesmo grupo e então sejam classificados em uma base de imagens.

apresentados para o sistema, que compara suas características com aquelas dos objetos das classes previamente estabelecidas.

# Decisão

- O objetivo de um sistema de Visão Computacional é tomar decisões a partir da extração de informações do mundo real através de imagens.
- A tomada de decisão pode ser feita a partir de indagações simples a respeito de parâmetros extraídos dos objetos ou de algoritmos mais complexos de Inteligência Artificial.

# Visão Humana X Computacional

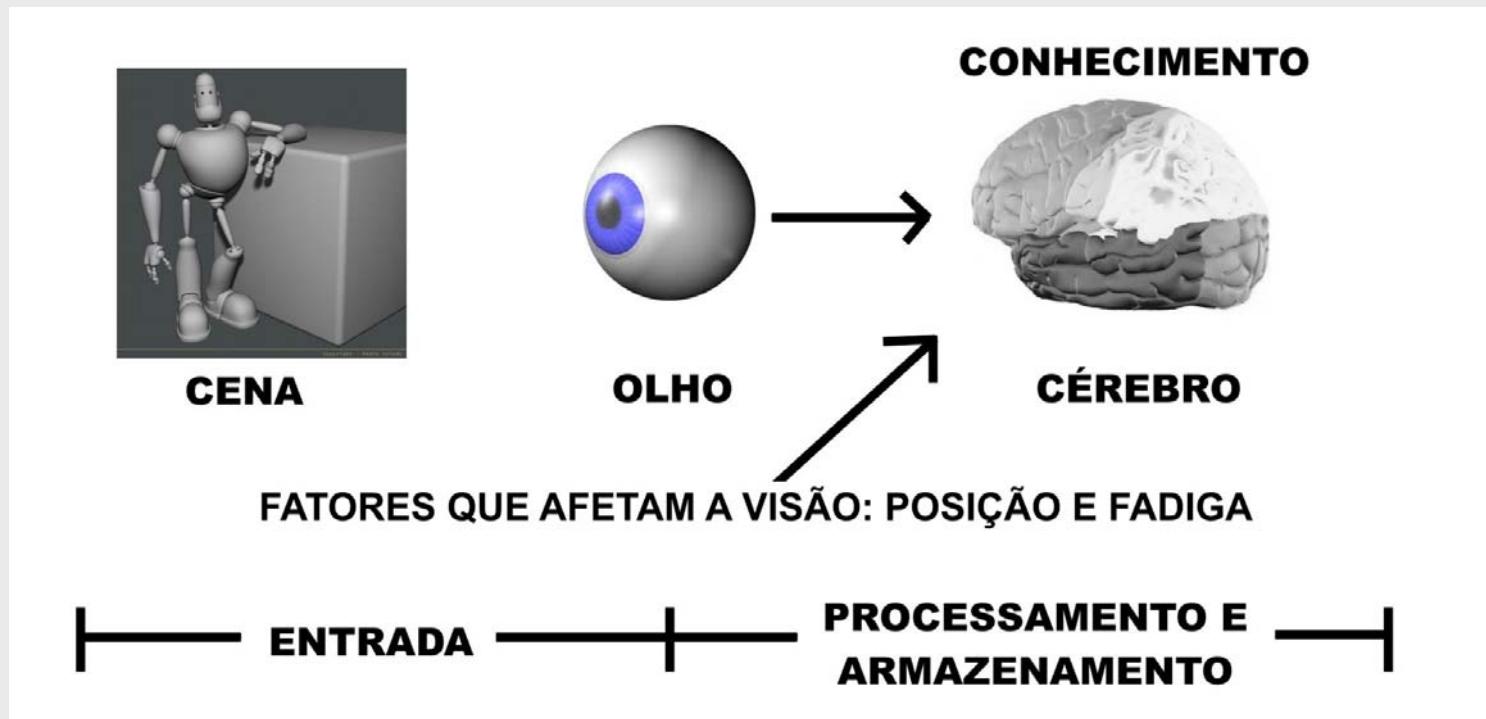


Figura 3.7. Sistema de Visão Humano.

# Características

- Adaptabilidade
- Tomada de Decisão
- Qualidade das Medições
- Velocidade de Resposta
- Percepção de Espectros
- Dimensão dos Objetos

# Exemplo de sistema de Visão Computacional

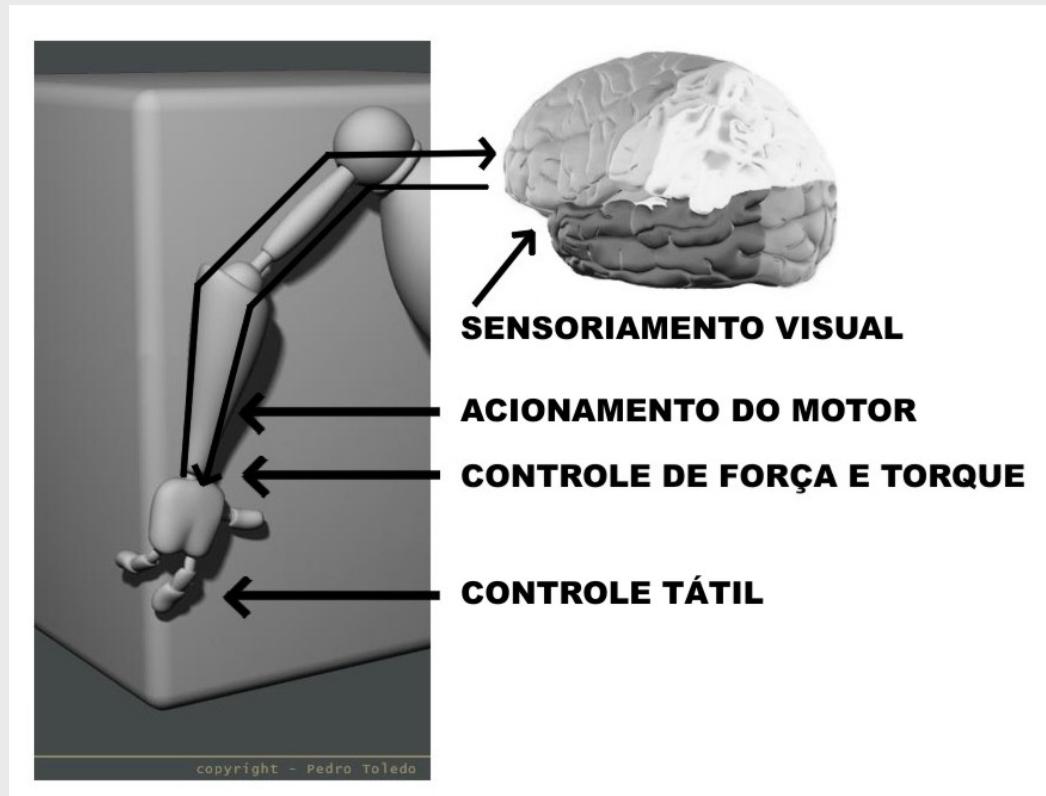


Figura 3.8. Integração da visão com o sistema motor.

# Analogia entre a visão humana e a computacional.



Figura 3.9. Analogia do sistema de visão humano e computacional.

# A Imagem Digital

**3.3.1. Discretização e Reconstrução**

**3.3.2. Amostragem e Quantificação**

**3.3.3. Resolução Espacial**

**3.3.4. Aliasing**

**3.3.5. Imagens Monocromáticas**

**3.3.6. Imagens Coloridas**

# A Imagem Digital

- Do latim *imago* - representação visual de um objeto.
- Do grego *eidos* (raiz etimológica do termo *idea* ou *eide*) – considera a *idea* da coisa, a sua imagem, uma projeção na mente.
- Imagem pode ser adquirida ou gerada pelo ser humano.
- Uma imagem consiste em qualquer forma visual de expressão de uma idéia.

# Formas de captação de uma imagem

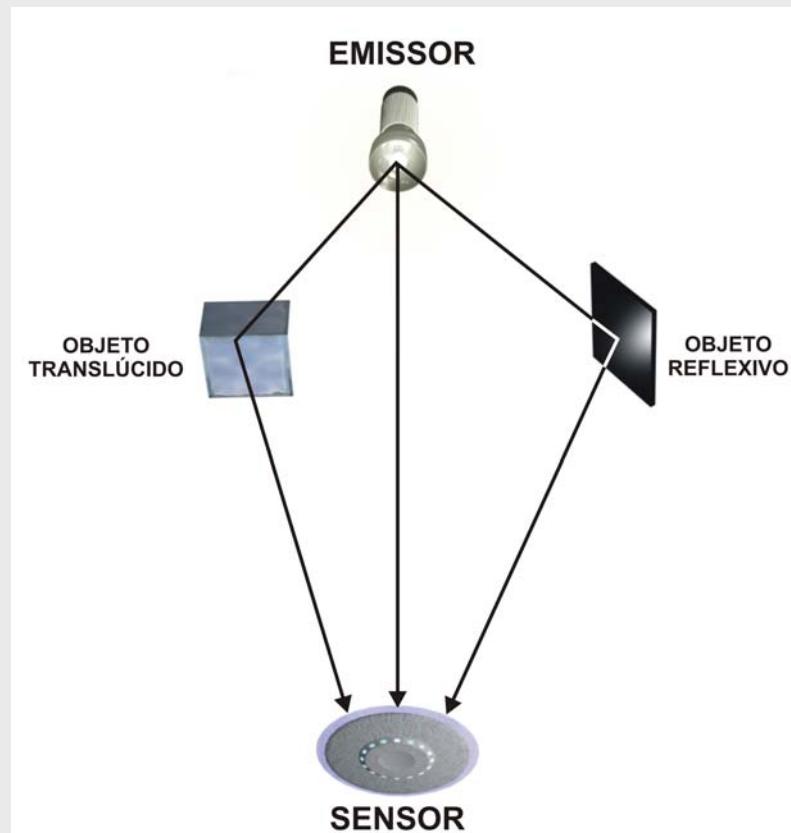


Figura 3.10 - Formas de Captação da Imagem por Radiação

# Etapas do processamento de imagem digital

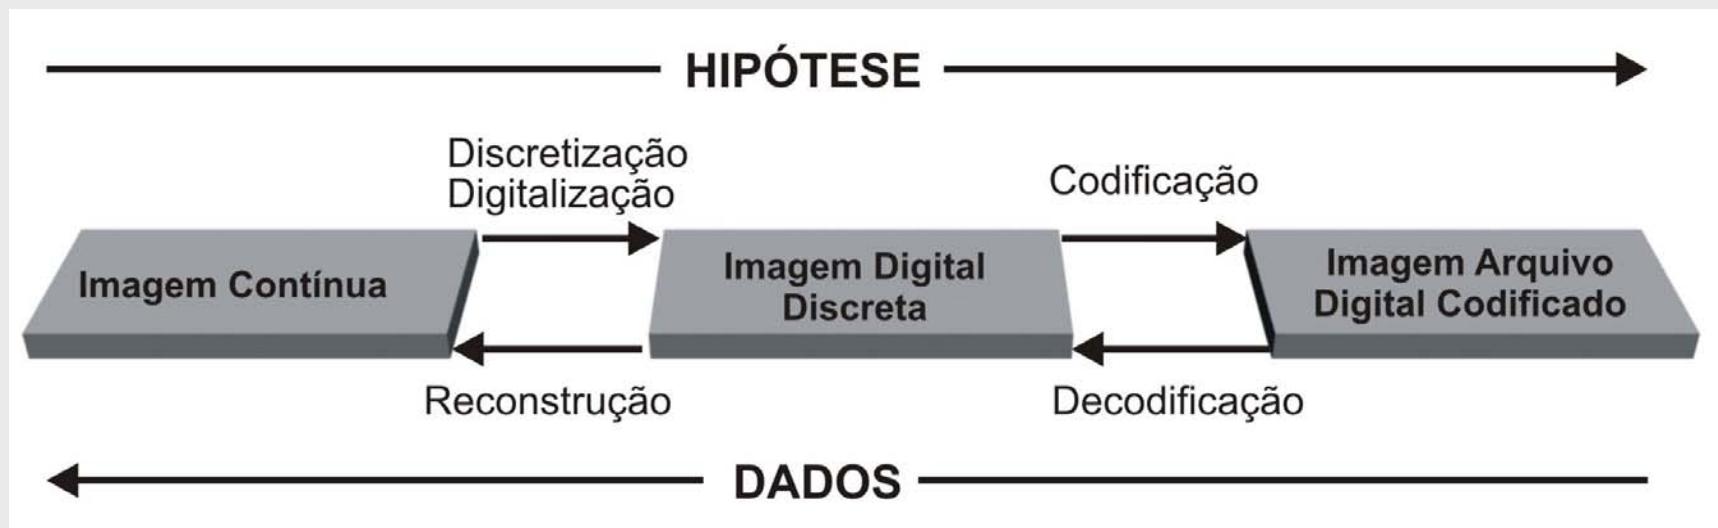


Figura 3.11 - Etapas do Processamento da Imagem

Discretização - conversão da imagem na forma contínua em um uma representação discreta.

Reconstrução - processo inverso da discretização.

Codificação - a partir da representação discreta da imagem, gera um conjunto de dados representativos da imagem, dados estes que podem ser transformados no formato de arquivos.

Decodificação - processo oposto à codificação no qual acessam-se informações codificadas na forma de uma representação discreta.

# Discretização e Reconstrução

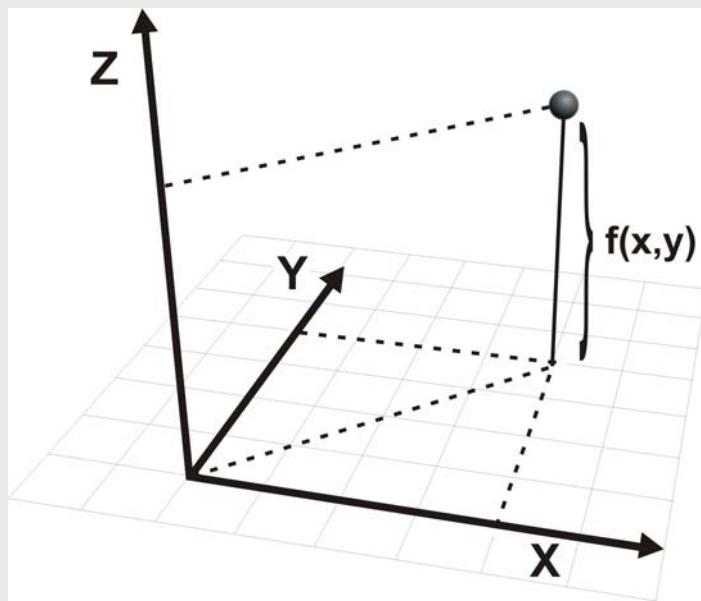
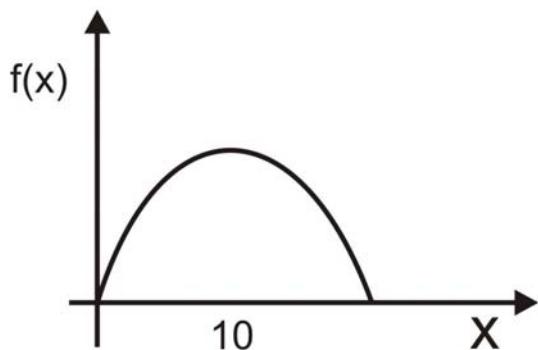


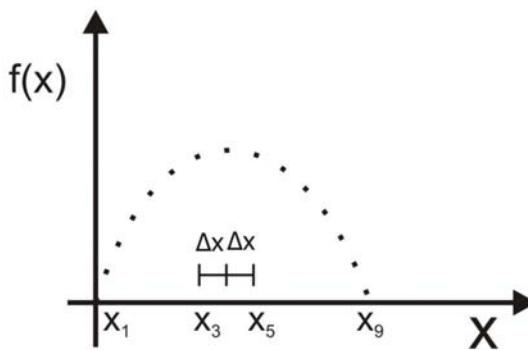
Figura 3.12. Gráfico de uma imagem contínua.

A forma de representar o mundo contínuo ou uma função contínua no computador é discretizando-a.

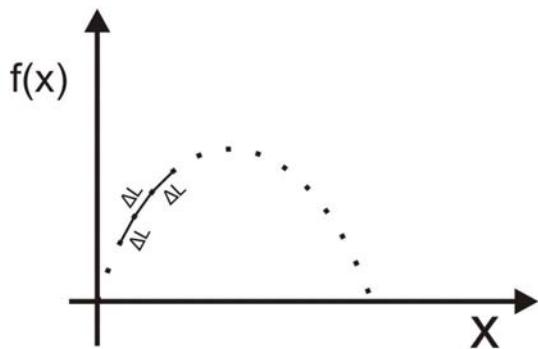
A operação que a partir dos valores discretos retorna uma aproximação da função contínua inicial é chamada de reconstrução.



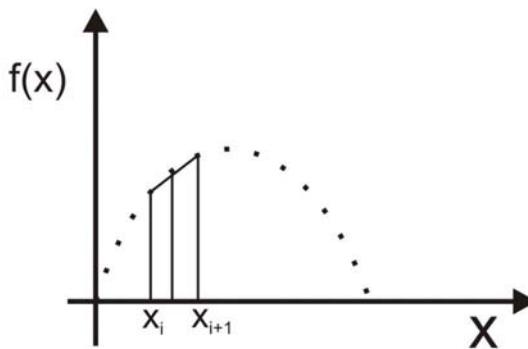
Representação Contínua



Representação Discreta a Intervalos Constantes em x



Amostragem a Intervalos Constantes em Relação a Distância entre os pontos  $(x, f(x))$



Reamostragem Criando Valores Intermediários por Interpolação Linear por Pares de Valores Anteriores

Figura 3.13 – Formas de Representação de uma função  $y = f(x)$ .

# Amostragem e Quantificação

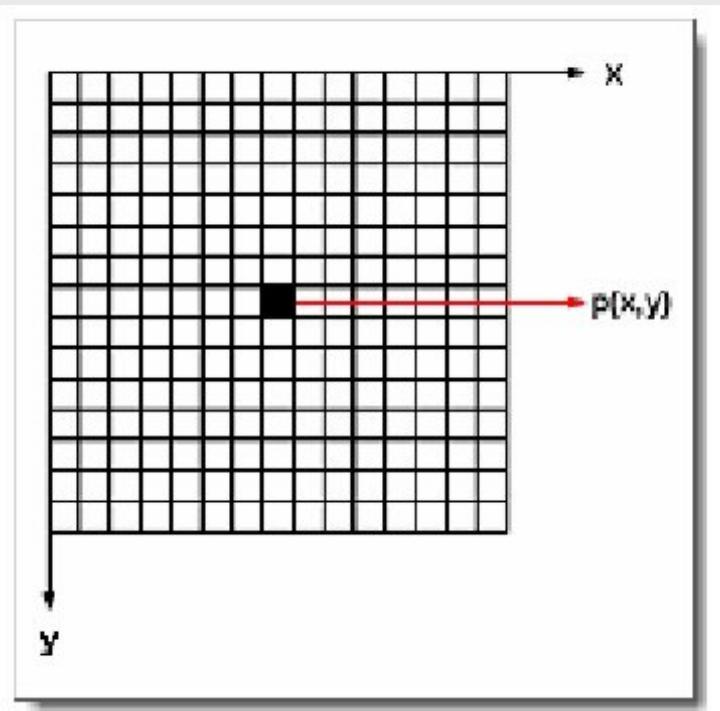


Figura 3.15 – Reticulado uniforme da representação matricial da imagem.

Uma imagem digital é descrita por uma matriz  $N \times M$  de valores de *pixel* ( $p(x,y)$ ) inteiros positivos, que indica a intensidade de cor em cada posição  $[x,y]$  da imagem.



Um *pixel* é caracterizado pelo valor de tonalidade de cor e pela sua localização na imagem.

47	52	64	132	153
51	58	121	149	142
49	99	143	144	164
94	135	161	170	199
138	165	180	212	213

Figura 3.16 – Representação matricial de uma região da imagem.

# Resolução Espacial

Ao ser digitalizada a imagem assume um tamanho adimensional, em *pixels*.

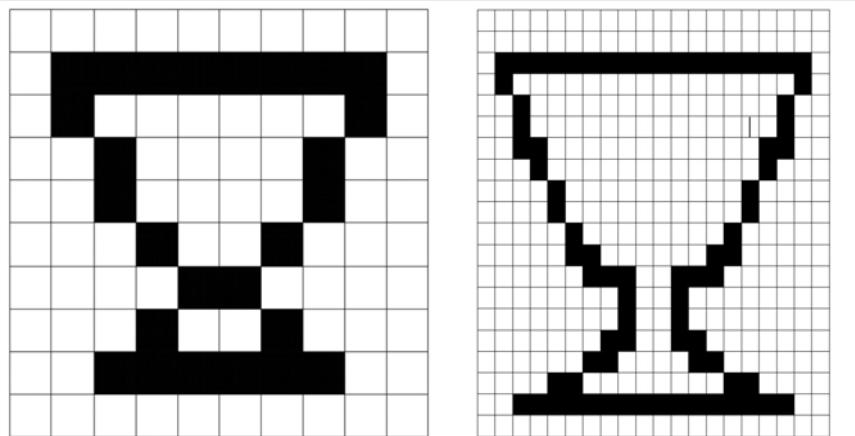


Figura 3.17 – Círculo em duas resoluções, mas exibido no seu tamanho original.

Pode-se conhecer o tamanho da amostragem, conhecendo-se a razão entre o número de *pixels* obtido e o tamanho da imagem real no filme fotográfico ou equivalente.

A isso chama-se de resolução espacial, que em geral é medida em pontos por polegada ou dpi (*dots per inch*).

# Aliasing

Ocorre quando a freqüência de amostragem é inferior à maior freqüência de variação da função contínua.

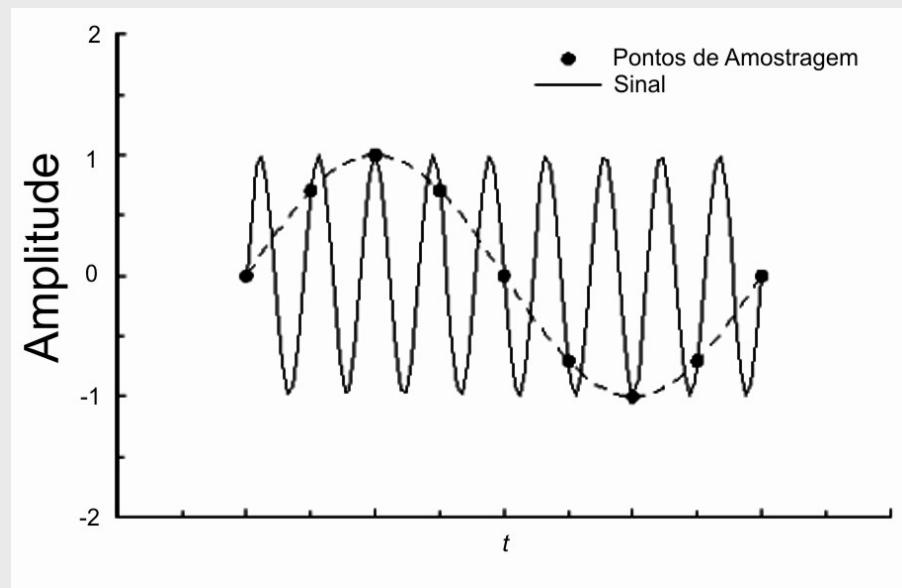
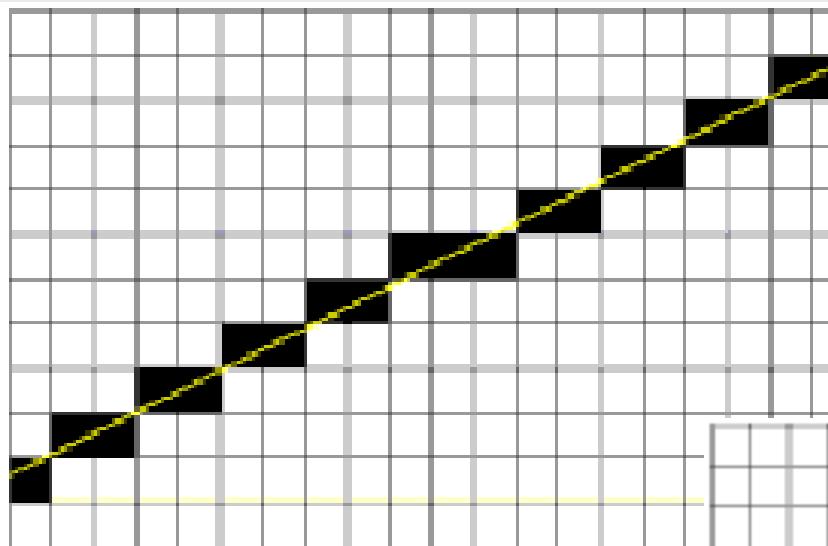
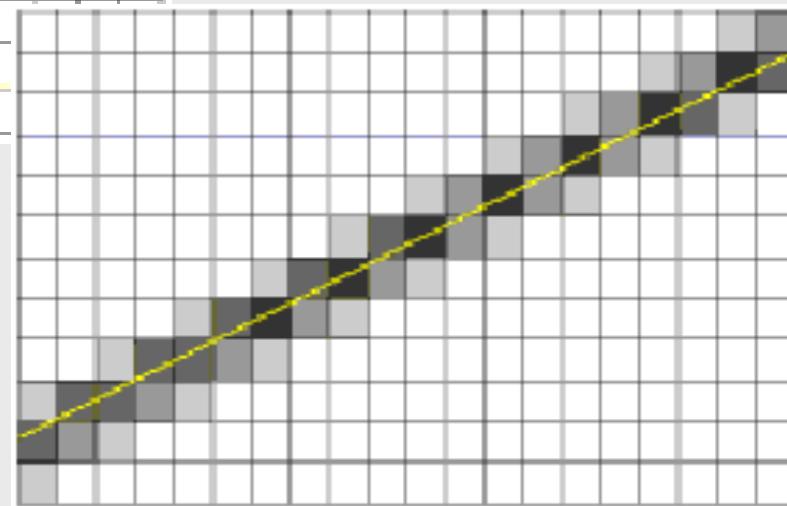


Figura 3.19 – O sinal digitalizado fica completamente diferente do sinal original devido a sua baixa freqüência de amostragem.



(a) “Dentes” na  
representação de retas.



(b) Uma forma de amenizar o  
problema.

Figura 3.20 - Problema do *aliasing* em monitores de computadores antigos.

# Imagens Monocromáticas

Imagens monocromáticas são imagens digitais onde cada *pixel* possui apenas uma banda espectral.



Figura 3.22 – Exemplos de imagens monocromáticas

O número de tons entre os valores limites, branco e preto, que se pode representar em tons, depende de quantos bits são alocados na matriz de imagem para armazenar o tom de cada *pixel*.

Número de elementos na Escala de cinza	Tons de cinza limites	Números de Bits necessários para representação do <i>pixels</i>
$2^1$ 2 valores	0,1	1
$2^3$ 8 valores	0 a 7	3
$2^4$ 16 valores	0 a 15	4
$2^8$ 256 valores	0 a 255	8

Uma imagem monocromática pode ser representada geometricamente também por valores reais quanto à posição dos *pixels* como no gráfico  $G(f)$  da função  $f$ :

$$G(f) = \{(x,y,z); (x,y) \in U; z = f(x,y)\} \quad (3.4)$$

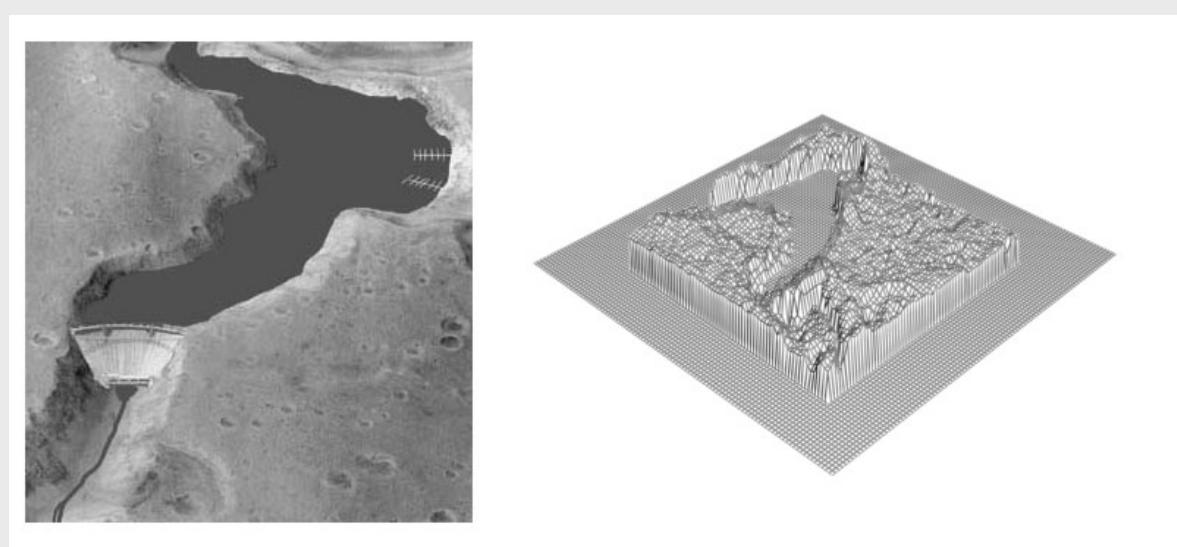


Figura 3.24 – Imagem Monocromática e gráfico 3D de sua função  $g(f)$  no  $R^3$ .

# Imagens Coloridas

Imagens multibandas são imagens digitais onde cada *pixel* possui  $n$  bandas espectrais. Quando uma imagem é representada pela composição das três bandas visíveis (RGB) tem-se uma imagem colorida aos olhos humanos.



(a) Imagem Colorida



(b) Banda Vermelha (Red)



(c) Banda Verde (Green)



(d) Banda Azul (Blue)

Figura 3.25 – Imagem colorida e bandas RGB.

# Histograma de imagem digital

O histograma de uma imagem é simplesmente um conjunto de números indicando o percentual de *pixels* naquela imagem, que apresenta um determinado nível de cinza ou cor.

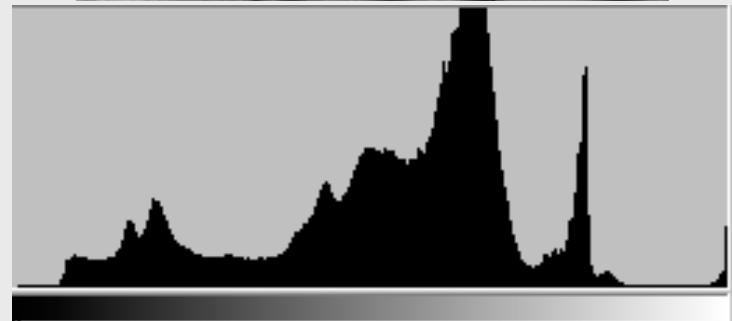


Figura 3.26 – Imagem em tons de cinza e o seu histograma.

Fornece uma indicação de sua qualidade quanto ao nível de contraste e quanto ao seu brilho médio.

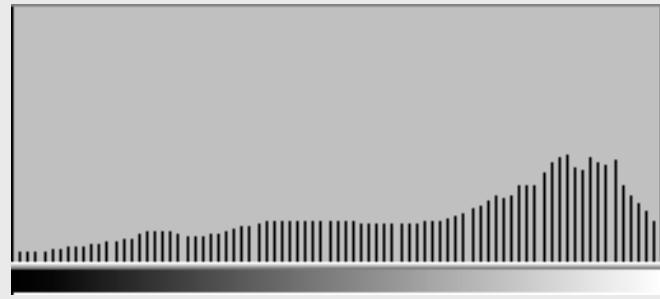
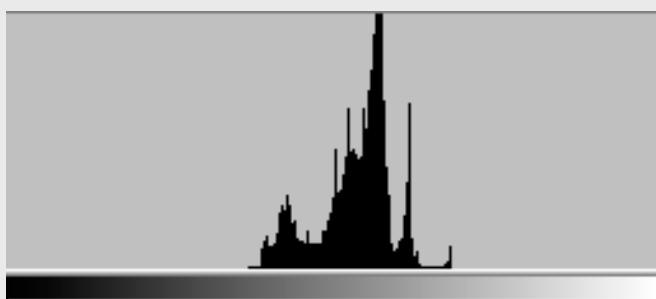
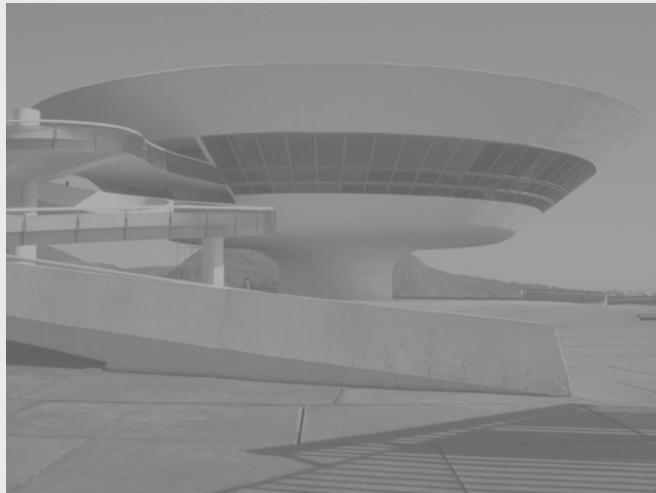


Figura 3.27 – Imagens em tons de cinza e seus respectivos histogramas: com alto contraste e com baixo contraste,

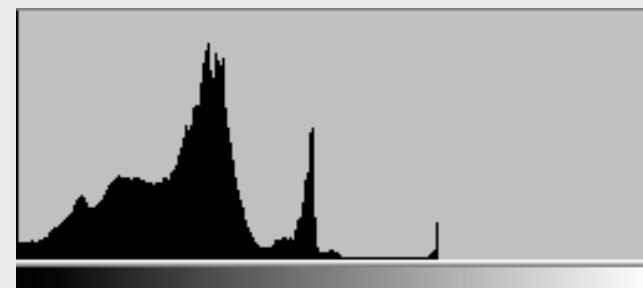
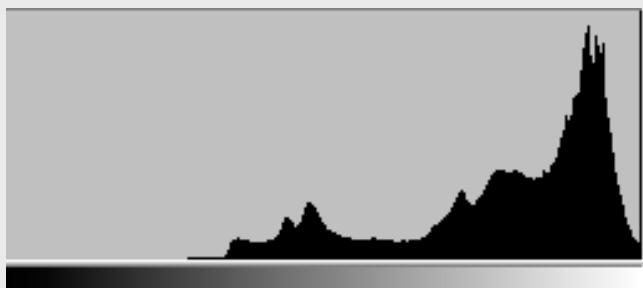
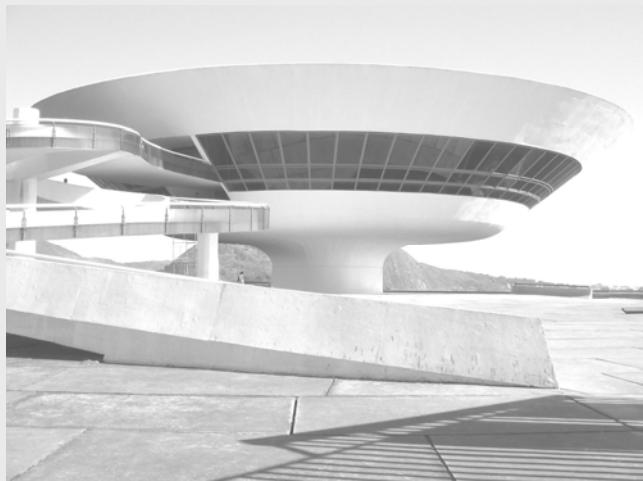


Figura 3.27 – Imagens em tons de cinza e seus respectivos histogramas: com alto brilho e com baixo brilho.

## Histogramas de uma imagem colorida

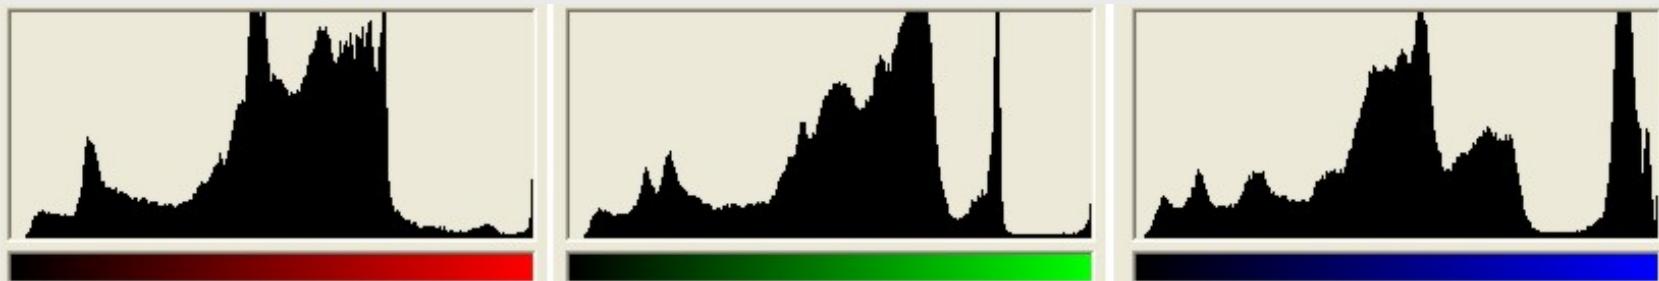


Figura 3.28 - Histogramas da Imagem 3.25 quanto à intensidade dos canais R,G B.

# **Sistemas de visão binária**

## **3.5.1. Agrupamento por limiar (limiarização)**

# Sistemas de visão binária

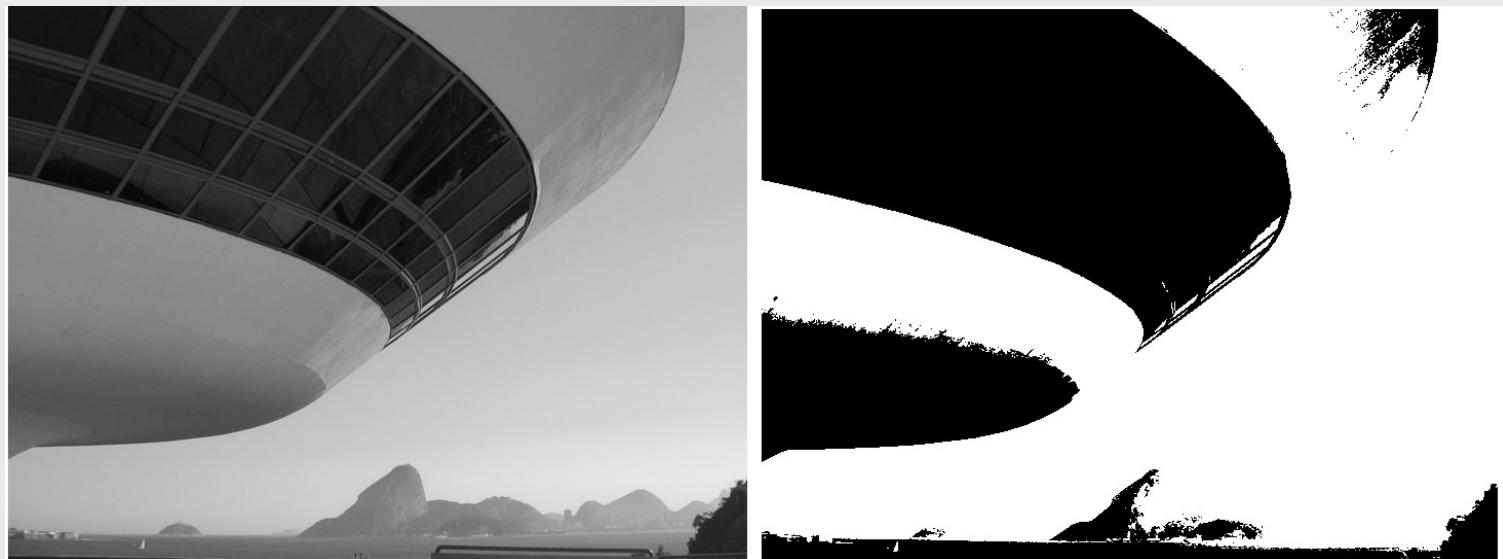


Figura 3.30 - Exemplo de binarização: (a) Imagem em tons de cinza, (b) Imagem binária

# Agrupamento por limiar (limiarização)

Uso em imagens em que o objeto a ser segmentado apresenta uma tonalidade bem diferente do fundo de

Em um histograma bimodal, é possível estabelecer um limiar entre as duas tonalidades.

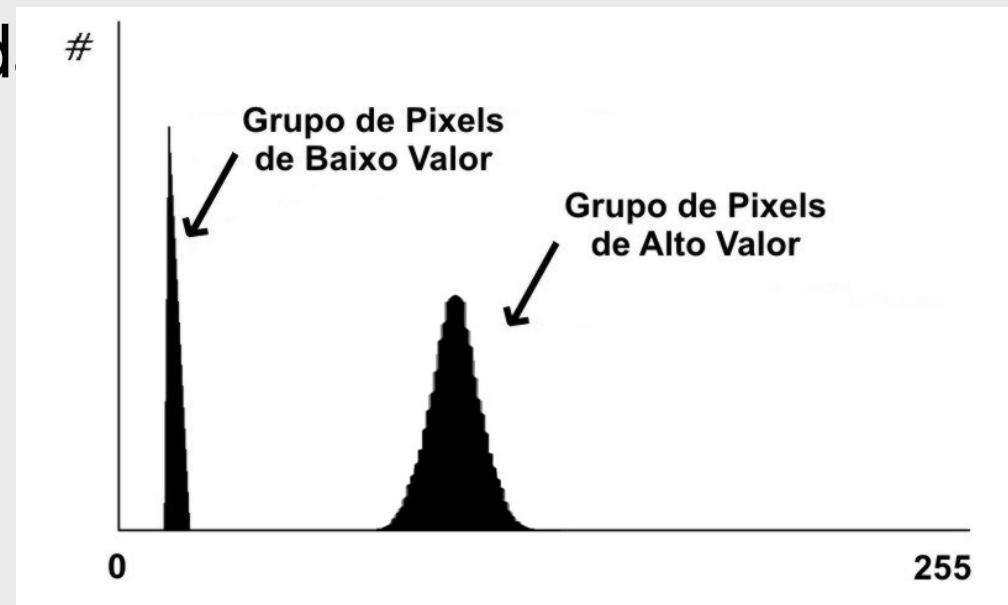


Figura 3.31 - Exemplo de histograma bem-dividido.

Quando a imagem tem mais de dois objetos com cinzas diferentes em um fundo mais escuro, pode ser usada a técnica de limiarização multinível (*multilevel thresholding*).

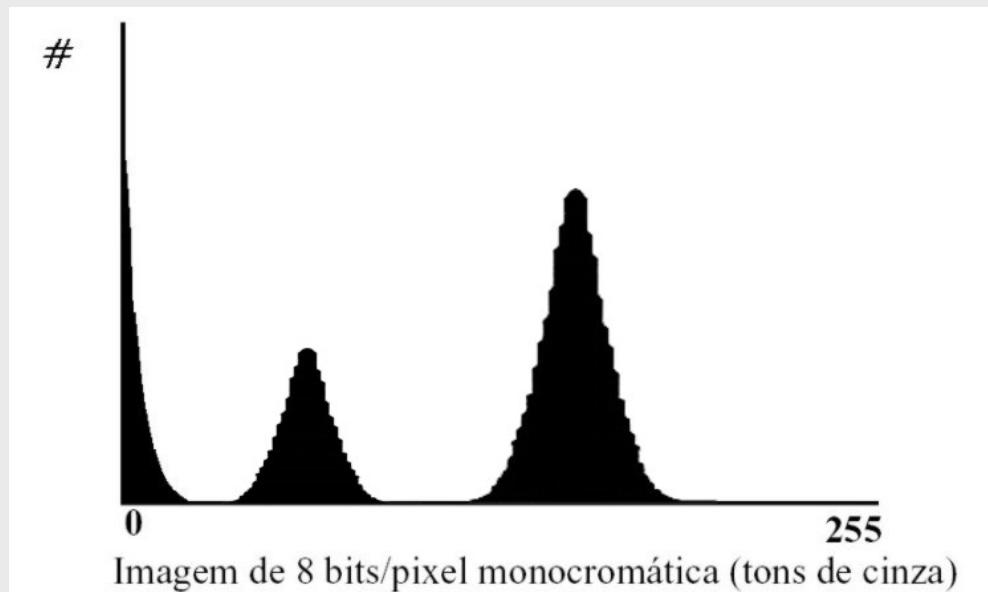


Figura 3.34 - Exemplo de um histograma trimodal.

Há casos em que torna-se necessário o uso de interpolação.

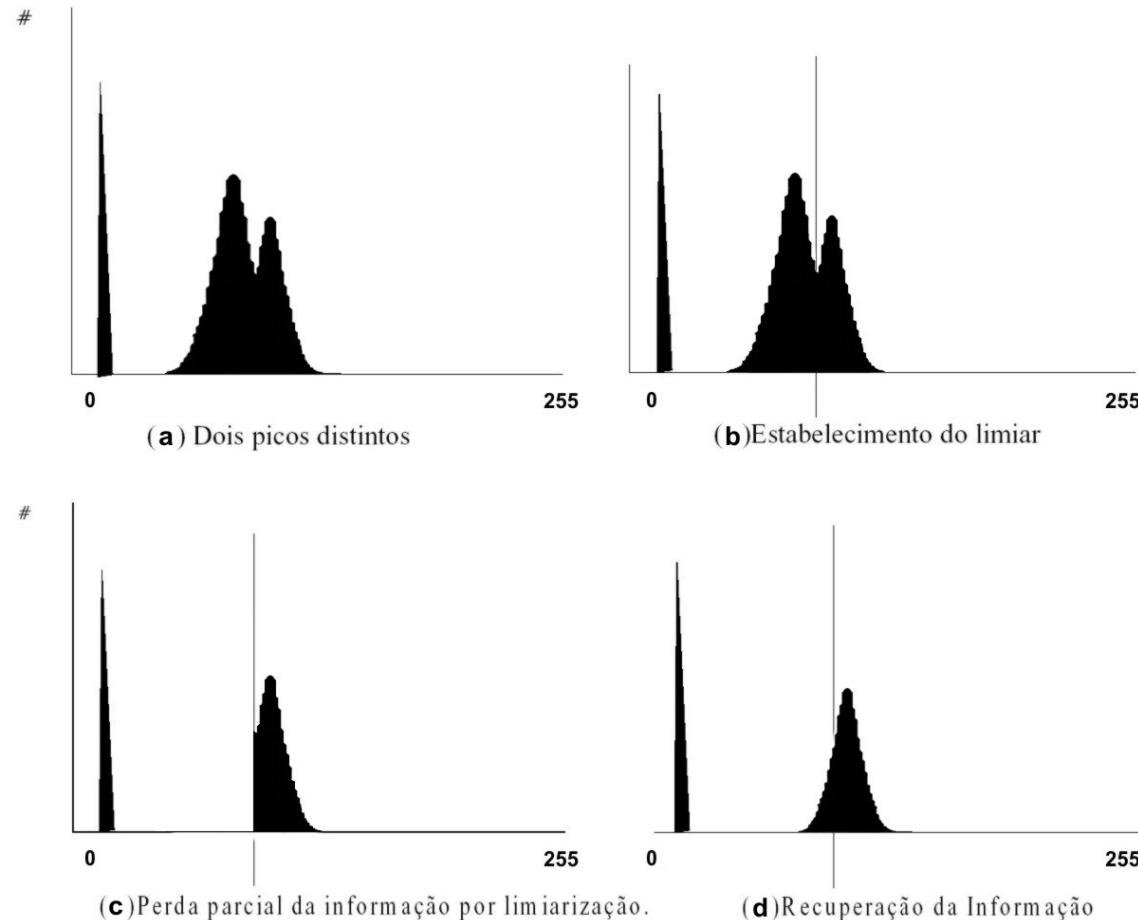


Figura 3.33 - Limiarização por interpolação (Chow e Kaneko, 1972).

A limiarização converte uma imagem de entrada:

$f(x, y)$  de  $N$  níveis de cinza

em uma imagem  $g(x, y)$ , chamada de imagem limiarizada (ou posterizada), com número de níveis de cinza menor do que  $N$ .

No limite,  $g(x, y)$ , terá só dois níveis de cinza, como na equação:

$$g(x, y) = \begin{cases} R_1 & se f(x, y) \leq T \\ R_2 & se f(x, y) > T \end{cases} \quad (3.5)$$

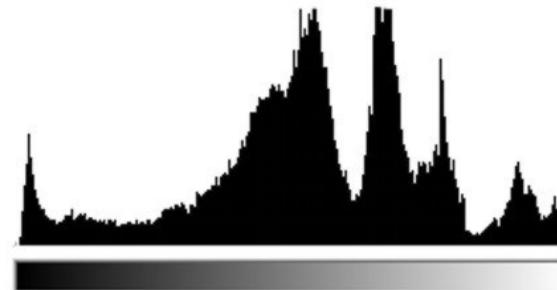
De uma maneira mais genérica, a definição de  $T$  é a função de várias variáveis na forma:

$$T = T [x, y, p(x,y), f(x,y)] \quad (3.6)$$

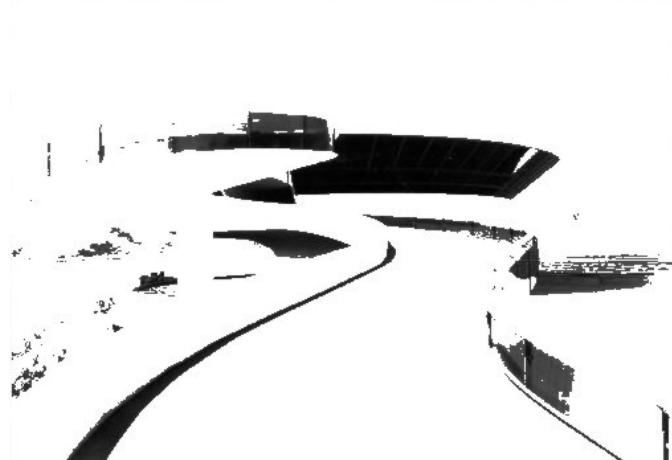
onde  $p(x,y)$  é uma propriedade local de  $x,y$ .



(a) Imagem com 256 tons de cinza



(b) Histograma



(c) Limiarização com valor 80



(d) Limiarização com valor 150

Figura 3.36 – Influência do valor do limiar sobre a qualidade da limiarização.

# **Operações pontuais globais em imagens**

**3.6.1. Operações pontuais globais baseadas na curva de tom**

**3.6.2. Operações globais baseadas em histograma**

**3.6.3. Técnicas Baseadas no Histograma de Imagens Coloridas**

# Operações pontuais globais em imagens

Uma operação pontual em uma imagem digital  $r$  é a função  $f(r)$  aplicada a todo *pixel* da imagem:

$$r: s = f(r) \tag{3.7}$$

# Operações pontuais globais baseadas na curva de tom

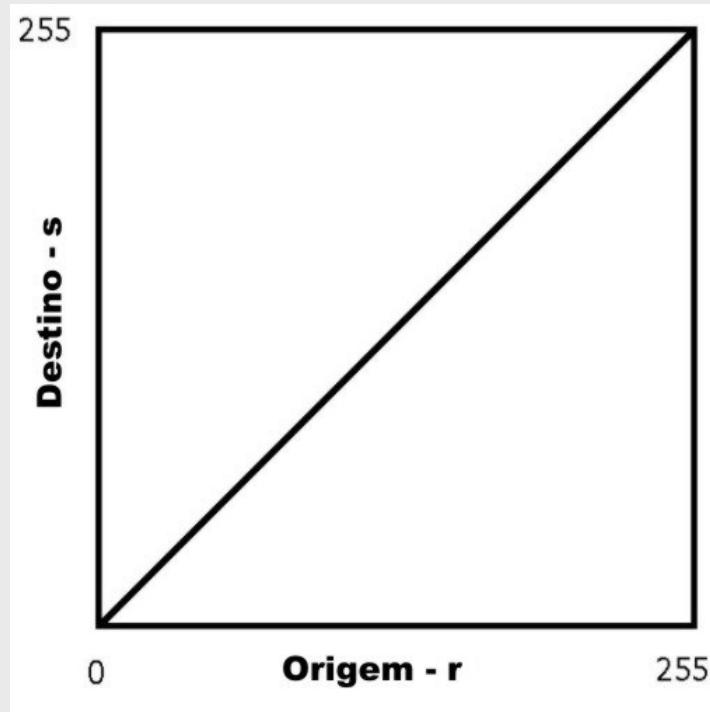
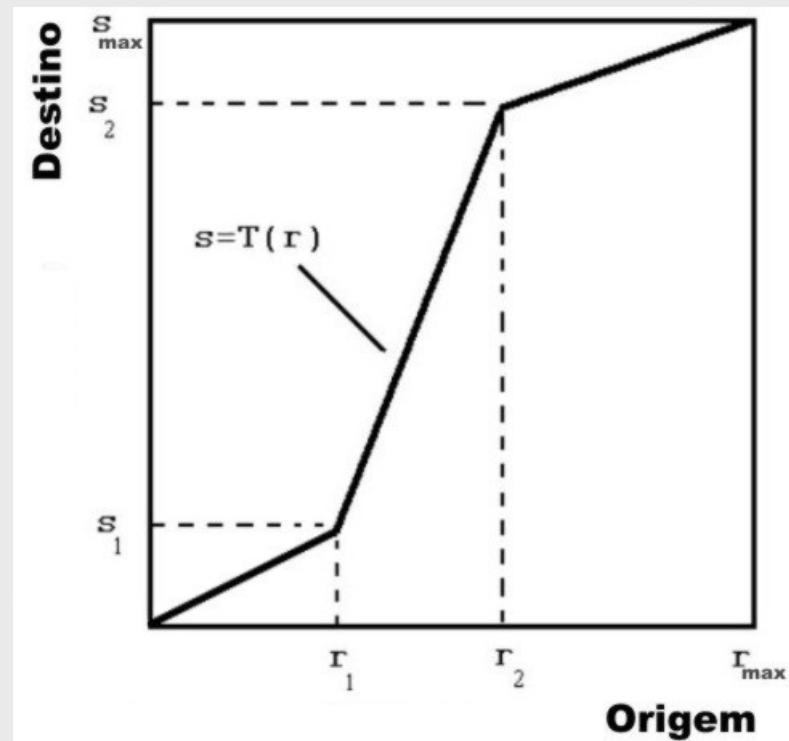
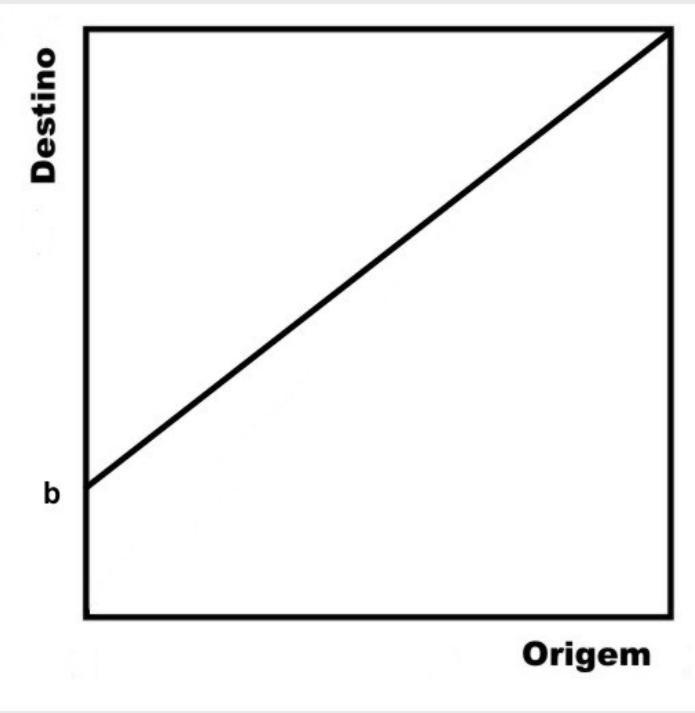


Figura 3.38 - Relação entre imagem origem e destino.



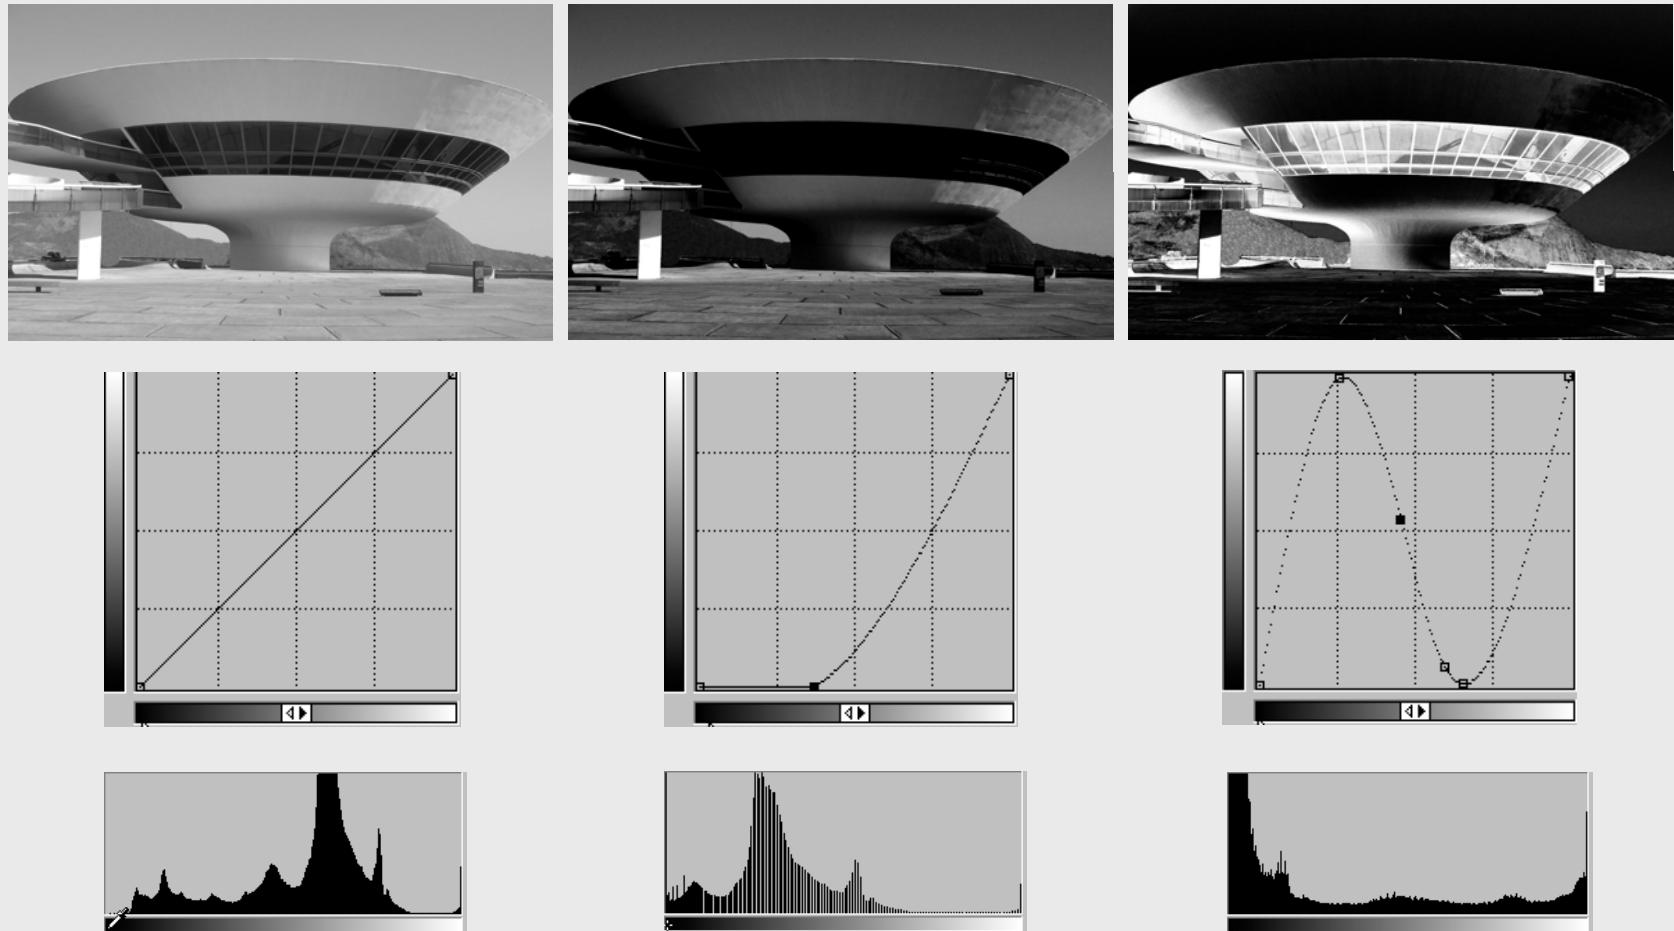


Figura 3.44 Curva de tom original e alteradas, com suas respectivas curvas de tom e histogramas.

# Compressão de histograma

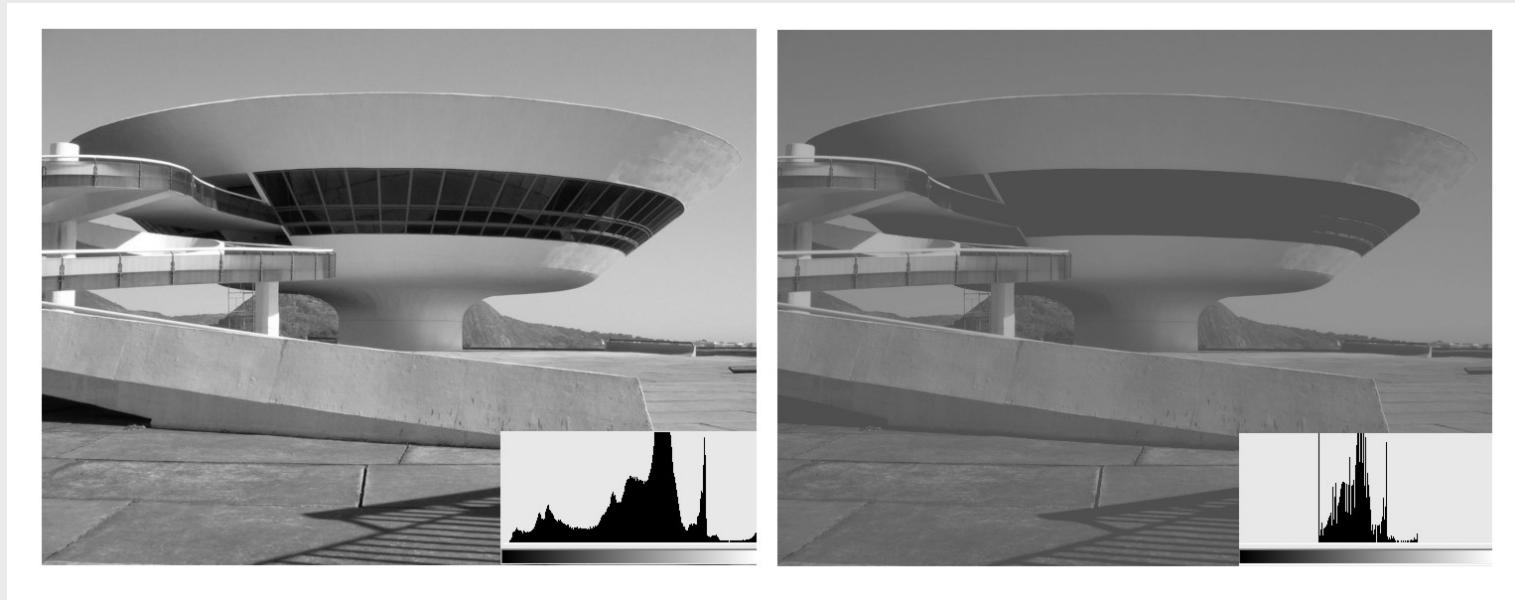


Figura 3.45 - Efeito da Compressão de Histogramas

# Expansão de histograma



Figura 3.46. Efeito da Expansão de Histogramas.

# Imagen negativa

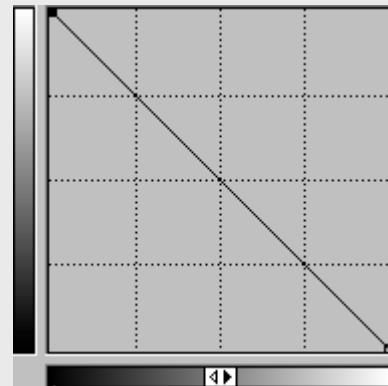
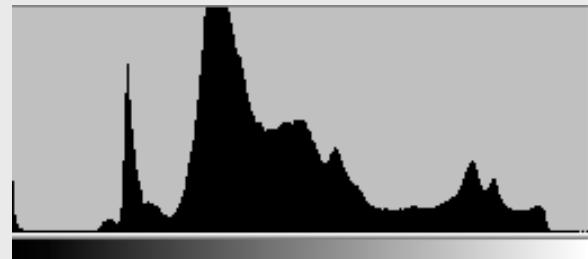
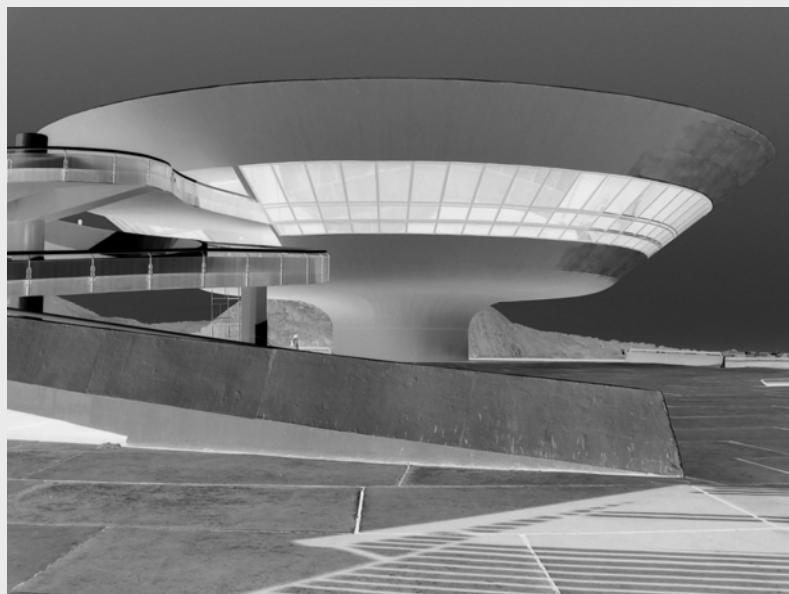


Figura 3.47. Efeito da imagem negativa.

# Operações globais baseadas em histograma

## Equalização

O objetivo da equalização de imagens é a melhoria do seu contraste.

Para tanto, o ideal é que os níveis de cinza sejam representados de maneira uniforme e distribuída.

A equalização de histograma consiste na redistribuição dos valores de nível de cinza em uma imagem de forma que todos os *pixels* tenham a mesma probabilidade de aparecer.

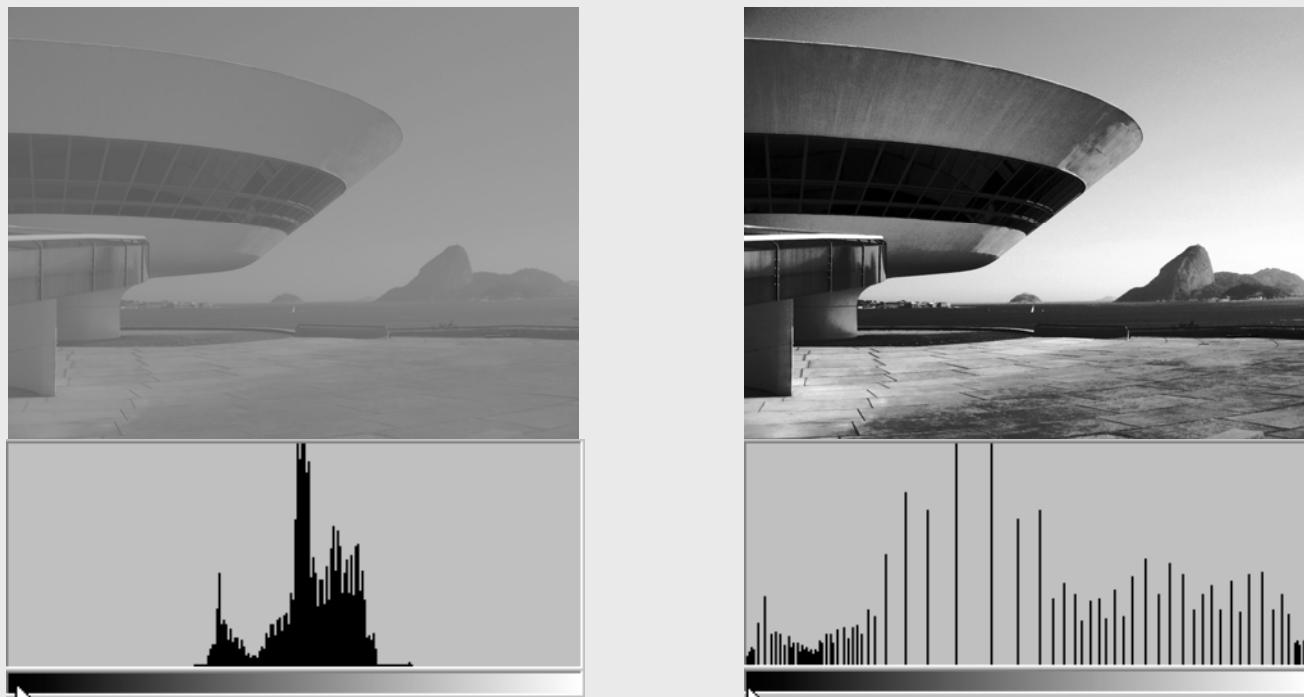


Figura 3.49 – (a) Imagem com baixo contraste e seu histograma.(b) Imagem após equalização e seu histograma.

# Especificação Direta

A equalização de histogramas procura distribuir igualmente para todos os níveis de *pixels* da imagem o que não permite estabelecer parâmetros de mudança capazes de ressaltar faixas de níveis de cinza na imagem.

Esta pode ser realizada por outra técnica chamada de especificação direta de histograma.

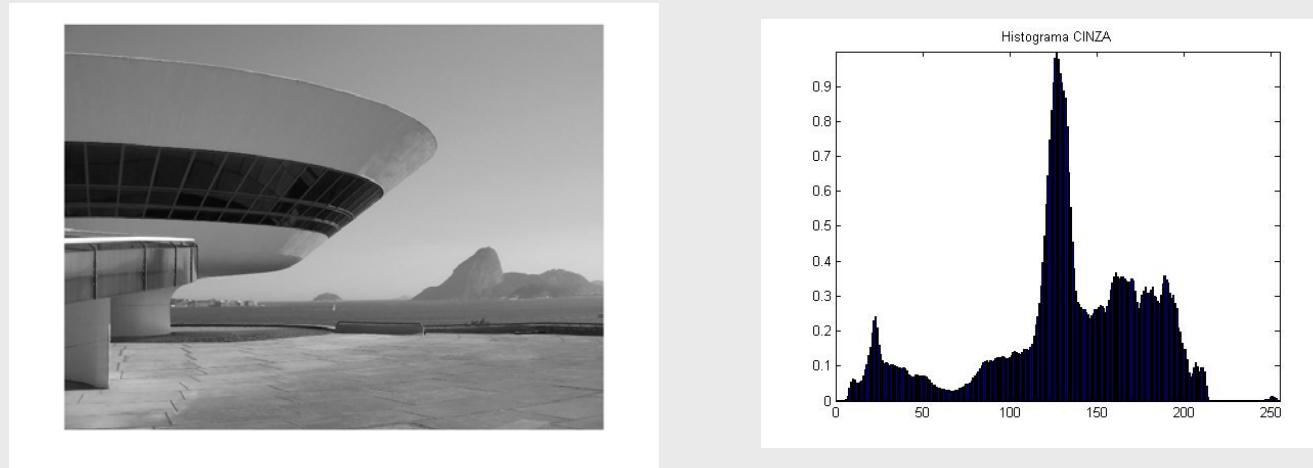


Figura 3.51 – Imagem original e seu histograma normalizado

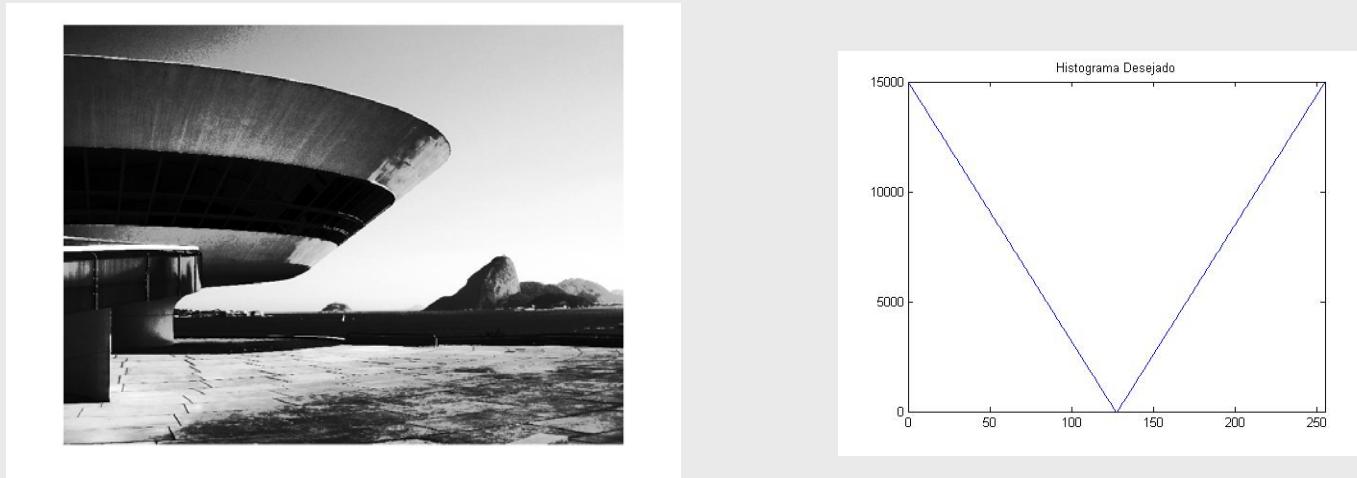


Figura 3.52 – Imagem obtida (a) após a especificação do histograma (b).

# Técnicas Baseadas no Histograma de Imagens Coloridas

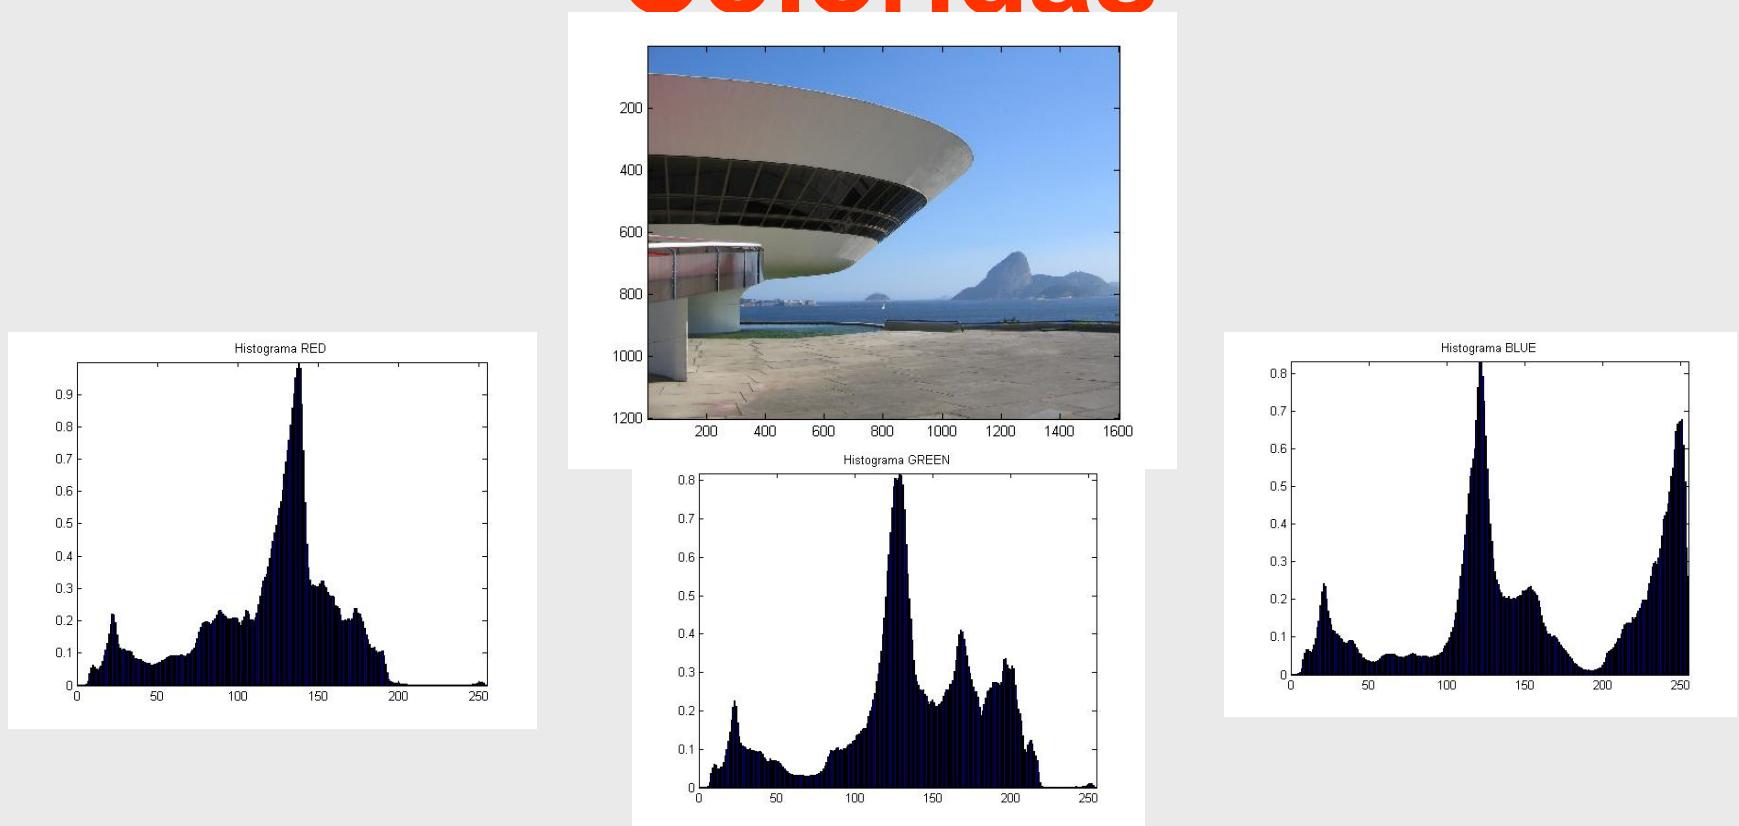


Figura 3.55 – Imagem original e seus histogramas normalizados (Gonçalves, 2006)

Quando as técnicas de mudança de histograma para imagens em tons de cinza são simplesmente triplicadas para cada um dos canais (RGB) independentemente, o resultado será o surgimento de cores não presentes na imagem original.

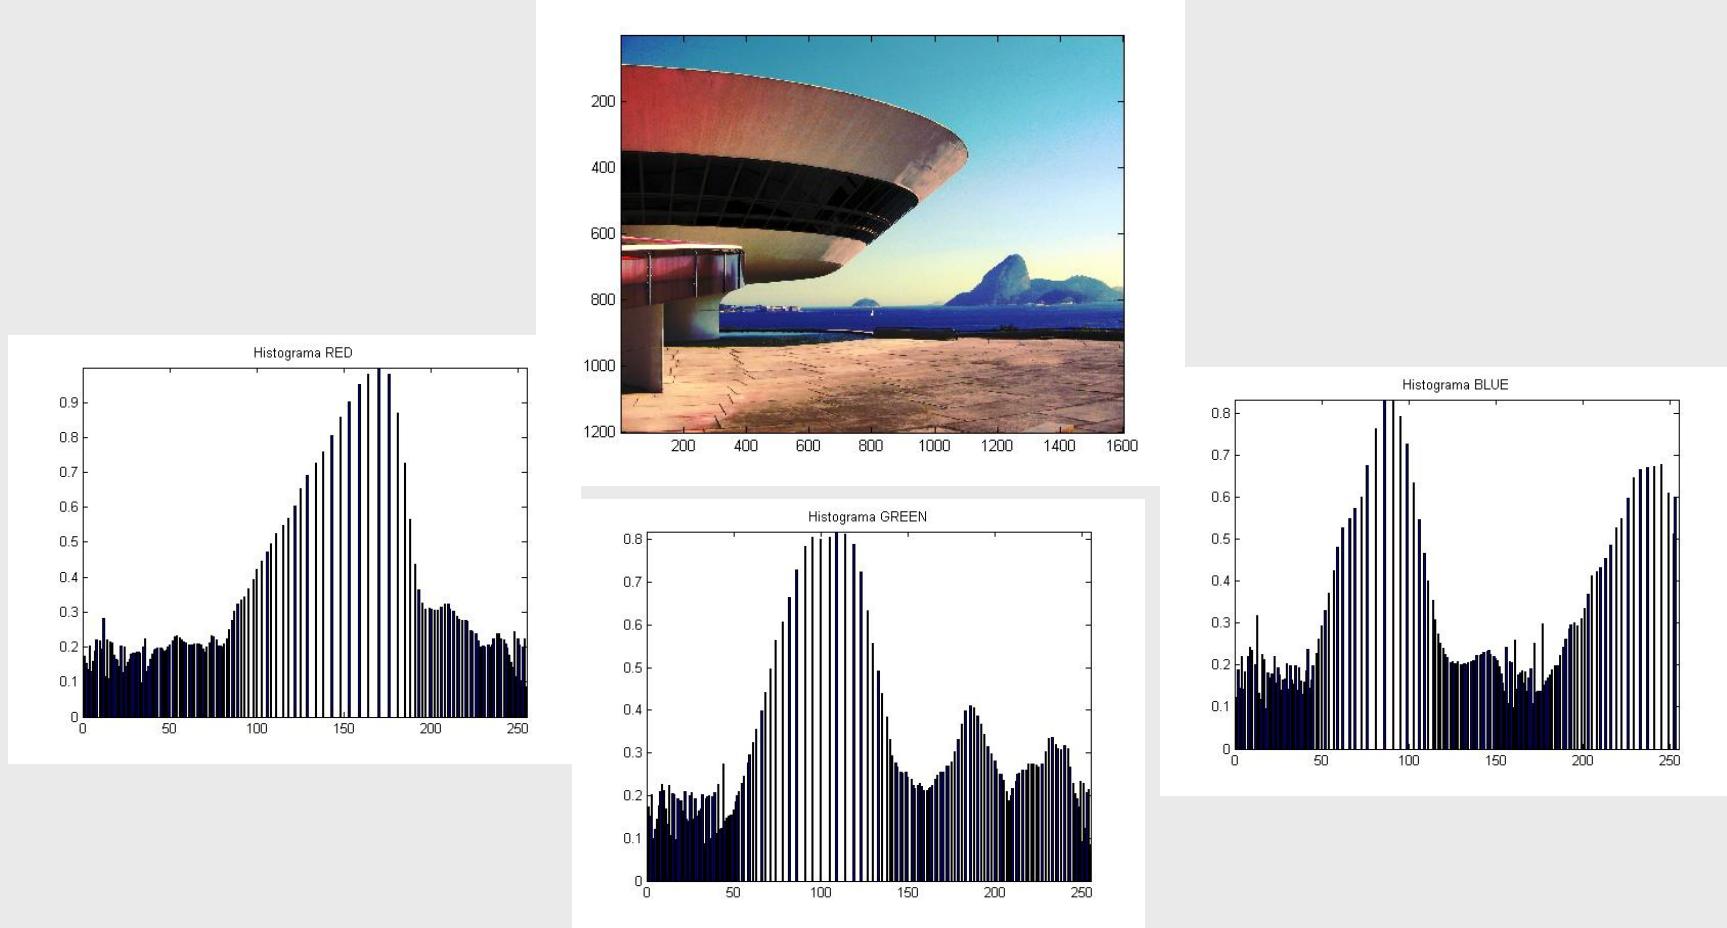


Figura 3.56 – Imagem modificada por equalização seus histogramas equalizados normalizados (Gonçalves, 2006).

# Soluções:

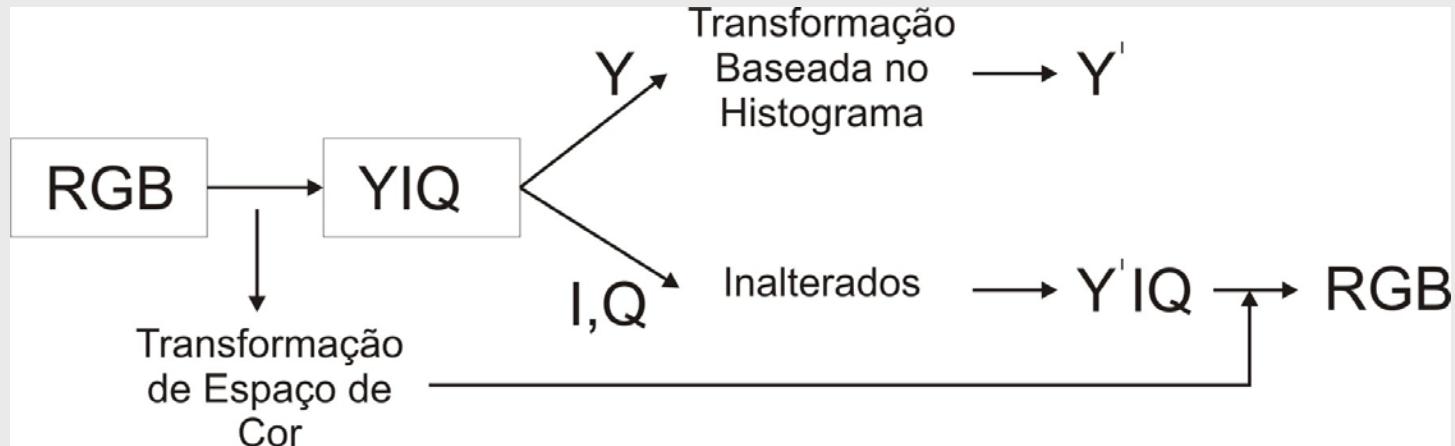


Figura 3.58 – Esquema de modificações baseadas no histograma para imagens coloridas.



Figura 3.59 – Esquema de modificação para espaços HSV e HLS

# Operações em Imagens

# **Operações em Imagens**

**4.1. Operações Pontuais**

**4.2. Operações Locais**

**4.3. Operações Globais**

**4.4. Transformações Geométricas**

Operações em imagens são realizadas:

- pontualmente nos *pixels*;
- em partes da imagem; e,
- em toda a imagem

# **Operações Pontuais**

- **Operações Aritméticas**
- **Operações Lógicas**

# Operações Pontuais

O *pixel*, na posição  $(x_i, y_i)$ , da imagem resultante depende apenas do *pixel* na imagem original.

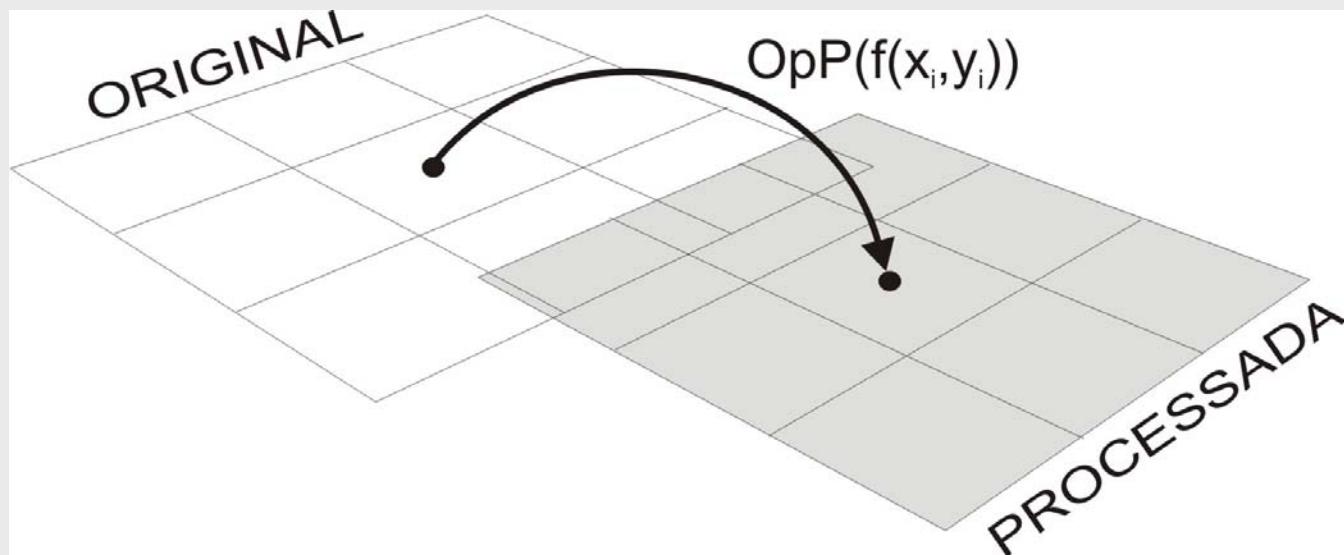


Figura 4.1 – Esquema de operações pontuais em imagens.

Algumas operações que alteram apenas características de cor ou luminância:

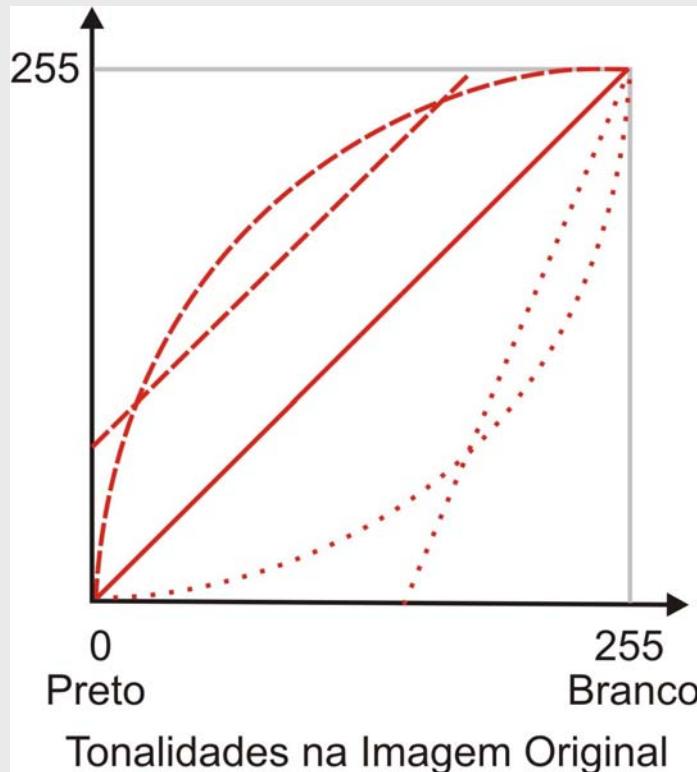


Figura 4.2 – Esquema de Mudanças de Tons para Imagem em 256 tons de cinza.

O processamento pode levar em consideração dados globais da imagem, como por exemplo, o histograma.



As operações locais *pixel-a-pixel* de duas imagens podem ser descritas pela expressão:

$$= ( X \text{ } OpP \text{ } Y ) \quad (4.3)$$

$OpP$  é um operador aritmético ou lógico.

# Operações Aritméticas

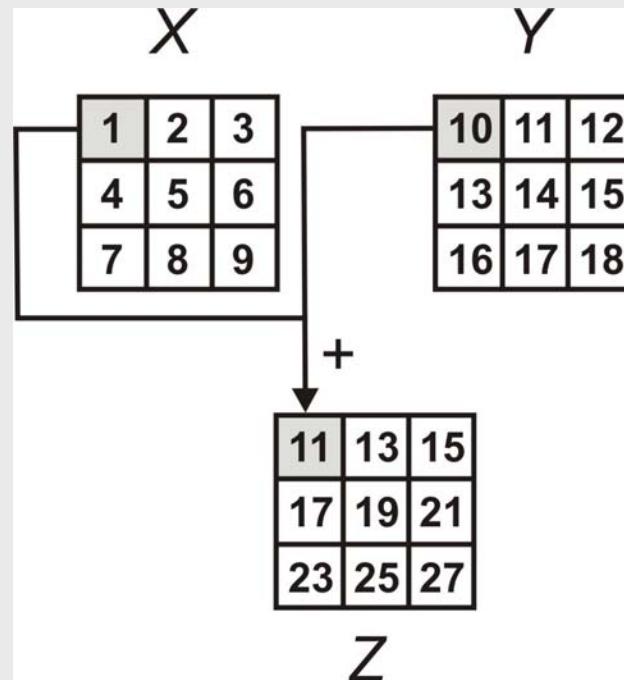
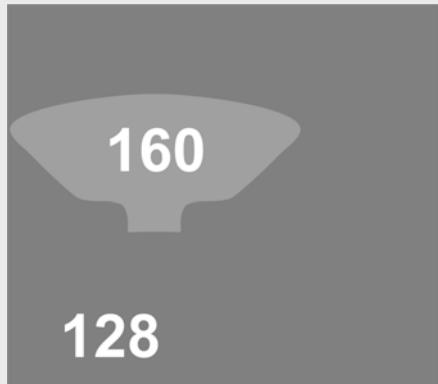
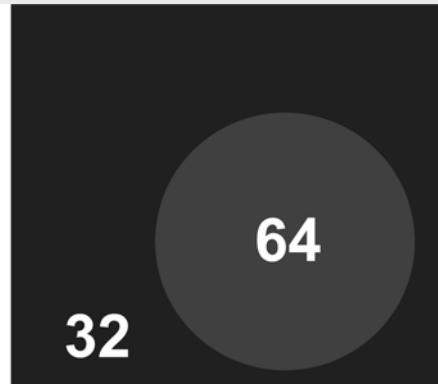


Figura 4.3 – Exemplo de operação aritmética de soma

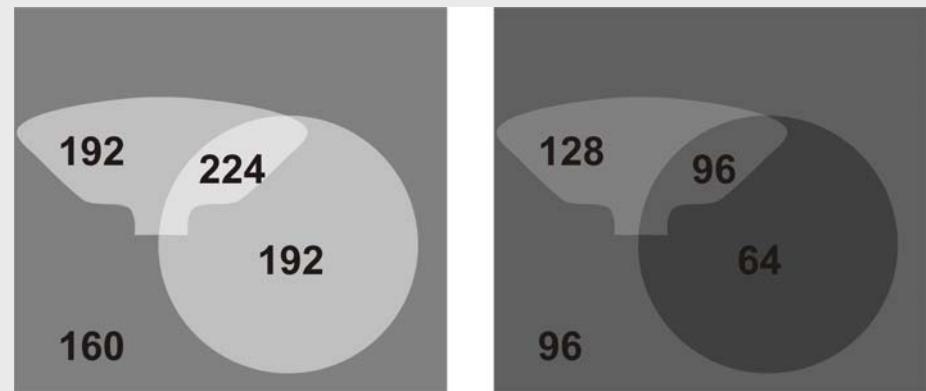


(a)  $X$



(b)  $Y$

Figura 4.4 – Imagens  $X$  e  $Y$  utilizadas como exemplos.



(a)  $X+Y$

(b)  $X-Y$

Figura 4.5 – Exemplos de operações aritméticas com as imagens da Figura 4.4.

# Limites Inferior e Superiores nas Operações

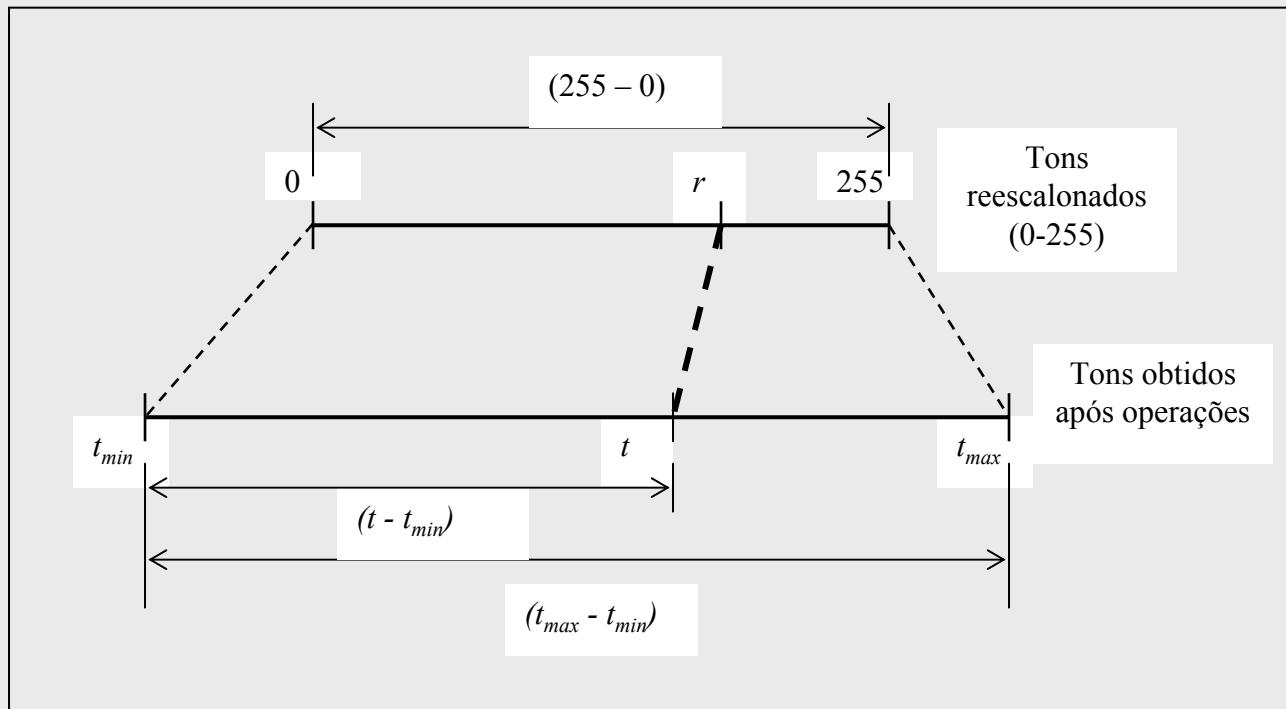


Figura 4.6 – Reescalonamento em casos de *underflow* e de *overflow*.

# Operações Lógicas

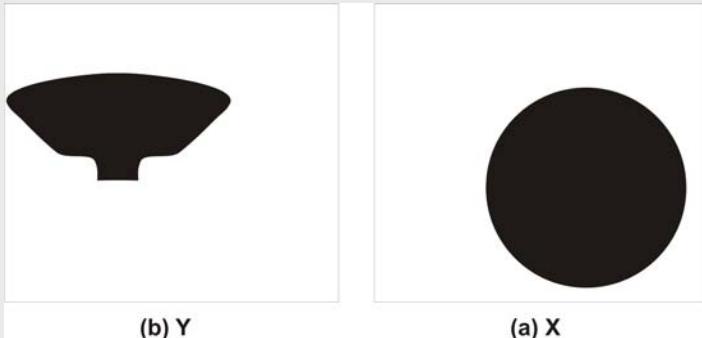


Figura 4.7 – Objetos X e Y utilizados como modelo.

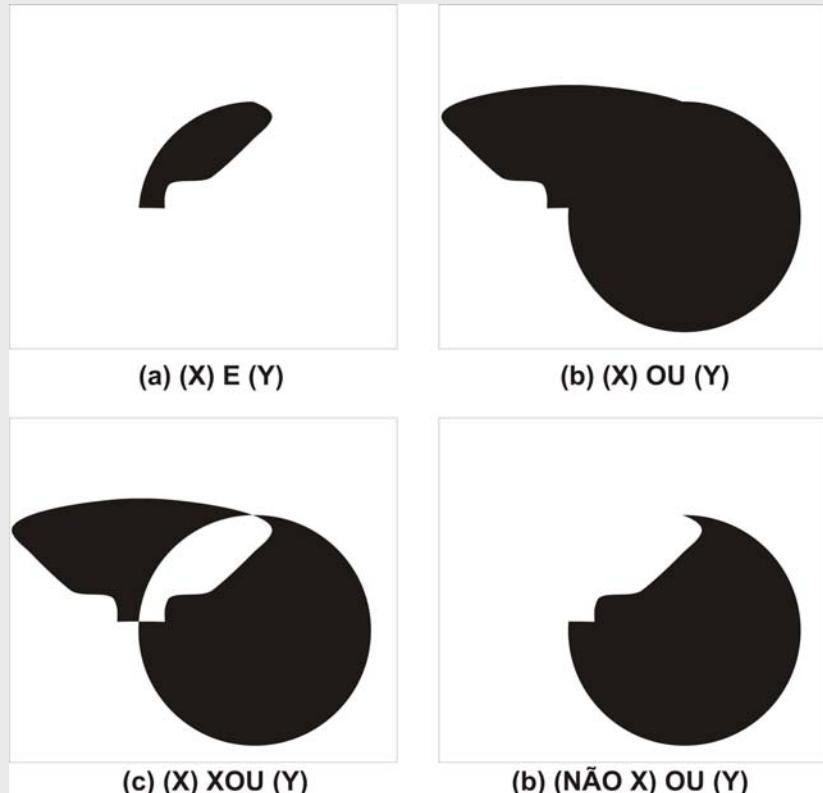


Figura 4.8 - Exemplos de operações lógicas com objetos da figura 4.10.

# Operações Locais

Um *pixel* da imagem resultante depende de uma vizinhança do mesmo *pixel* na imagem original

$$\text{OpL}(f(x_i, y_i), f(x_i-1, y_i-1), f(x_i+1, y_i+1), f(x_i-1, y_i+1), f(x_i+1, y_i-1), \dots)$$

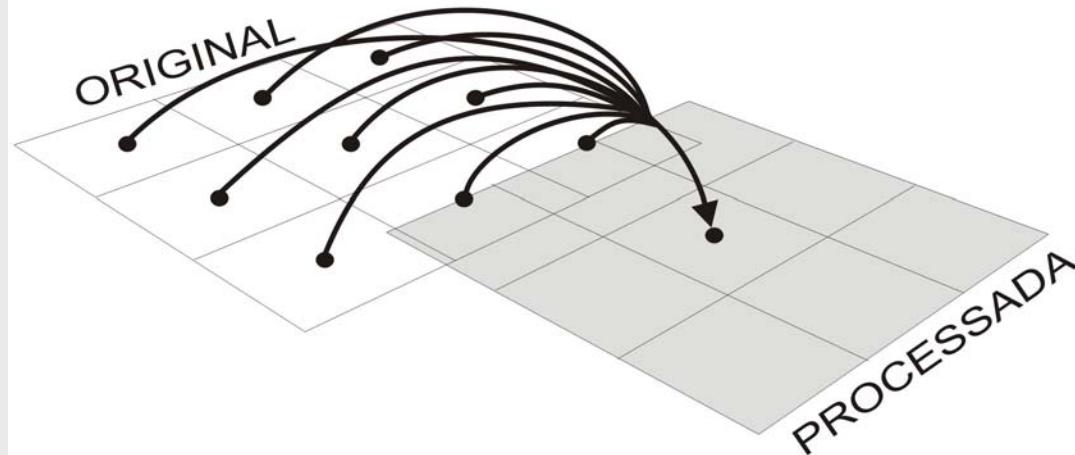
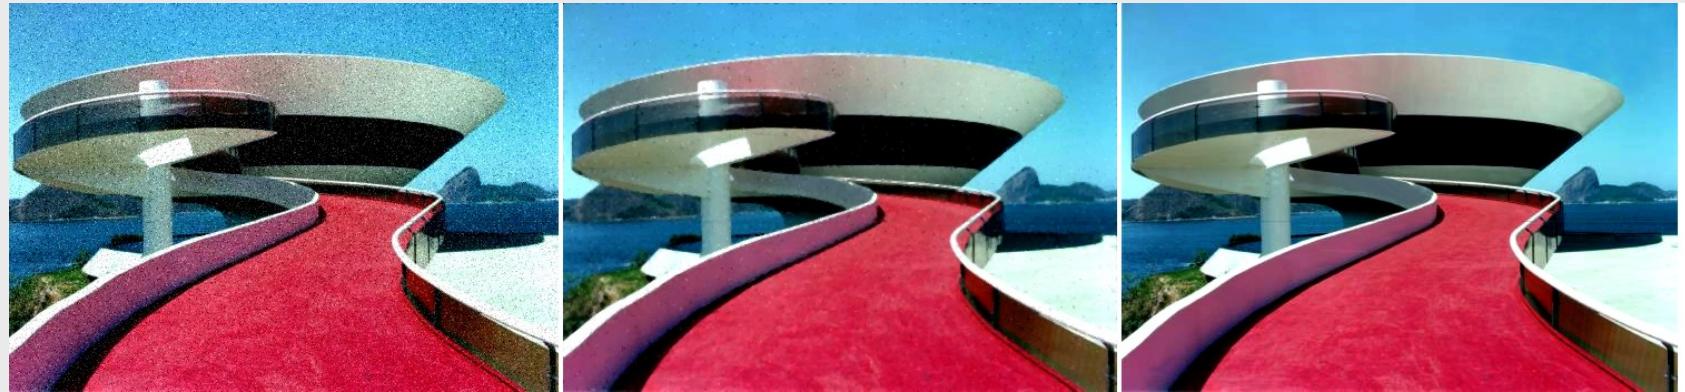


Figura 4.9 – Exemplo de uma operação local em uma área em torno do *pixel*  $(x_i, y_i)$ .



(a)

(b)

(c)

Figura 4.10 - Redução de ruídos na imagem. (a) Imagem com ruído. (b) Redução do ruído usando filtro de *blur*. (c) Imagem original.

# Forma de atenuar o efeito de *aliasing*

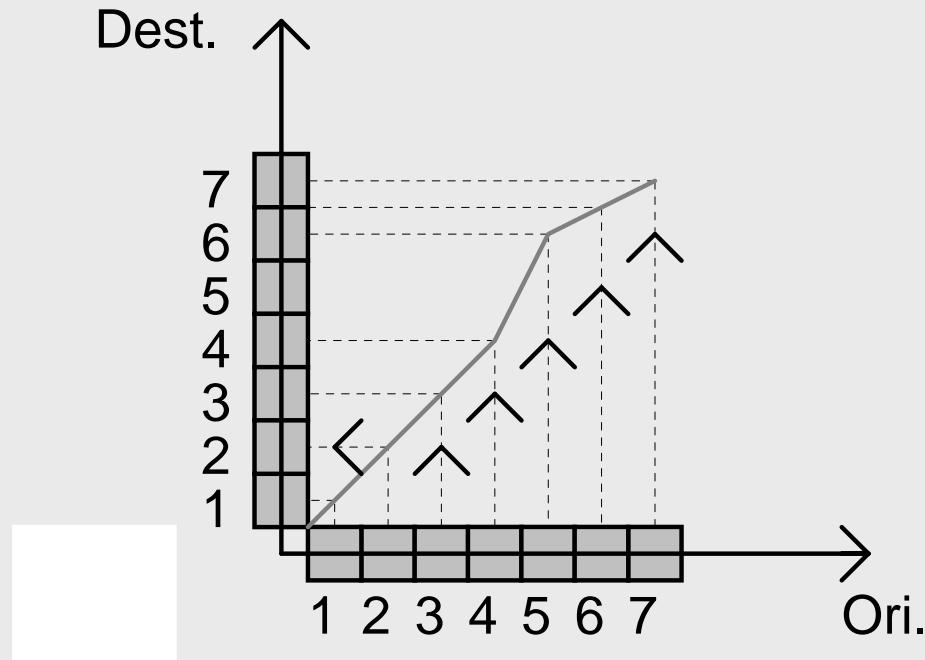


Figura 4.11 - Efeito da expansão e contração no domínio discreto.

## Filtro de média:

$$g(x_i, y_i) = \frac{1}{9} \left( f(x_{i-1}, y_{i-1}) + f(x_i, y_{i-1}) + f(x_{i+1}, y_{i-1}) + \right. \\ \left. f(x_{i-1}, y_i) + f(x_i, y_i) + f(x_{i+1}, y_i) + \right. \\ \left. f(x_{i-1}, y_{i+1}) + f(x_i, y_{i+1}) + f(x_{i+1}, y_{i+1}) \right) \quad (4.2)$$



(c)



(d)

Figura 4.12 – Imagem com Aliasing (c) e o efeito da aplicação de filtro de média (d).

# Operações Globais

Um *pixel* da imagem resultante depende de um processamento realizado em todos os *pixels* da imagem original.

Transformadas de: Fourier, Wavelet, Hough, Cosenos (usada para codificação) e funções interativas ou fractal.

# Transformações Geométricas

Levam o tom do *pixels* na posição  $(x_o, y_o)$  da *imagem origem*, para outra posição  $(x_d, y_d)$  do espaço em uma *imagem destino*

# **Transformações Geométricas**

**4.4.1. Translação, Rotação e Escala**

**4.4.2 Espelhamento ou reflexão**

**4.4.3. Deformações e *Morphing***

# Translação, Rotação e Escala

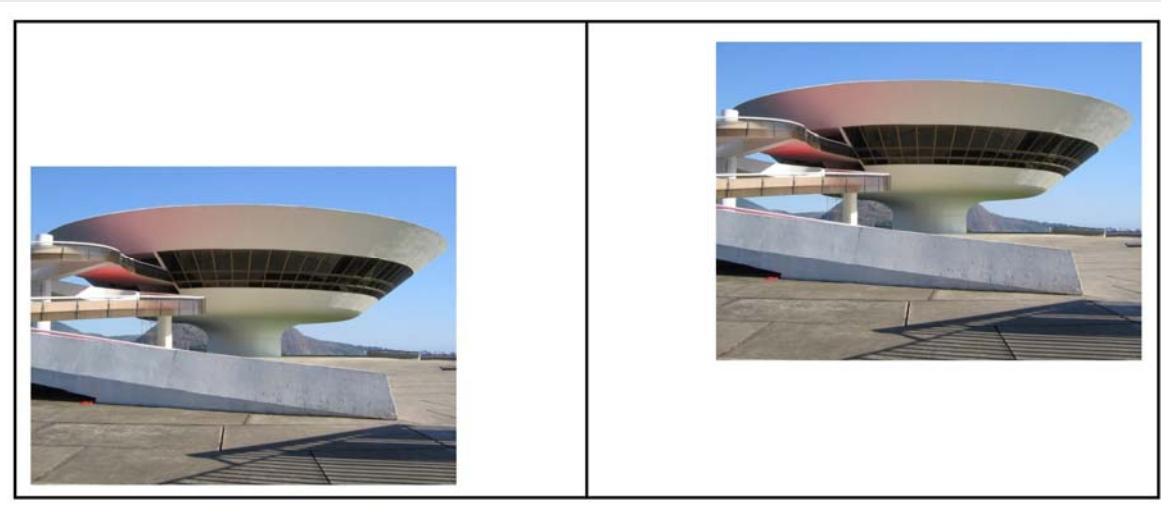


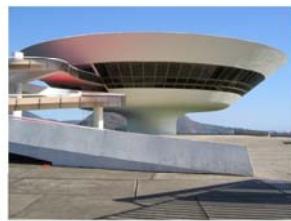
Figura 4.13 – Exemplo de translação da imagem. (a)  
Imagen Original. (b) Imagen Transladada.

$$\begin{bmatrix} x_d \\ y_d \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & T_x \\ 0 & 1 & T_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_o \\ y_o \\ 1 \end{bmatrix}$$

(4.3)



(a)



(b)



(c)

$$\begin{bmatrix} x_d \\ y_d \\ 1 \end{bmatrix} = \begin{bmatrix} S_x & 0 & 0 \\ 0 & S_y & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_o \\ y_o \\ 1 \end{bmatrix}$$

(4.4)

Figura 4.14 – Exemplo de ampliação e redução da imagem. (a) Imagem Original. (b) Imagem Ampliada 2 vezes. (c) Imagem Reduzida pela metade



$$\begin{bmatrix} x_d \\ y_d \\ 1 \end{bmatrix} = \begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_o \\ y_o \\ 1 \end{bmatrix} \quad (4.5)$$

Figura 4.15 – Exemplo de Rotação de 90º no sentido horário

## Rotação em duas passadas:

$$x_d = x_o \cos \theta - y_o \sin \theta$$

$$y_d = x_d \tan \theta + y_o \cos \theta$$

(4.6)

$$y_d = x_o \sin \theta + y_o \cos \theta$$

$$x_d = x_o \cos \theta - y_d \tan \theta$$

(4.7)

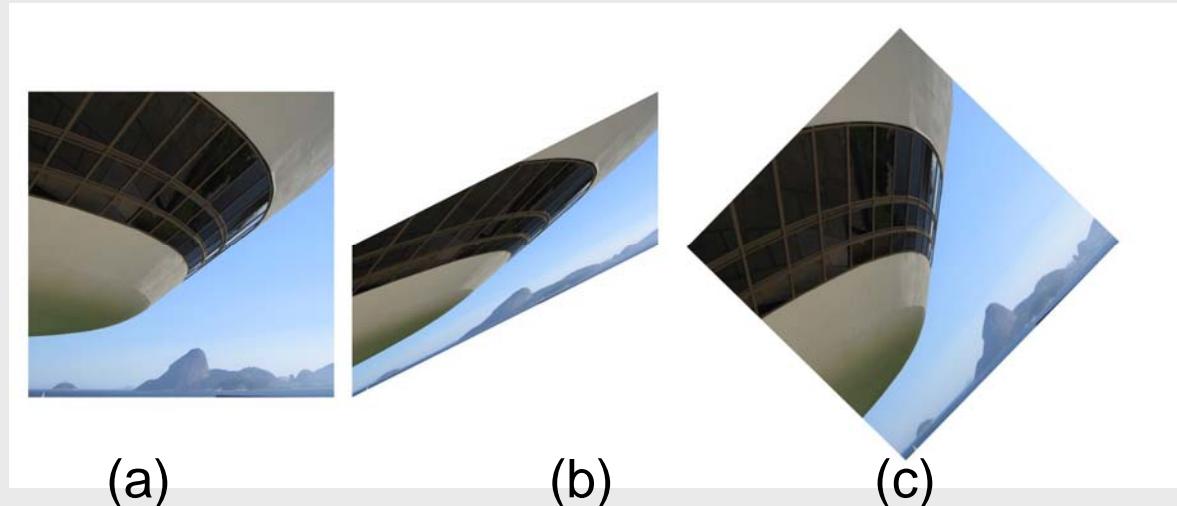


Figura 4.16 - Rotação de 45 graus da imagem. (a) Imagem original. (b) 1<sup>a</sup> passada. (c) Resultado final (2<sup>a</sup> passada).

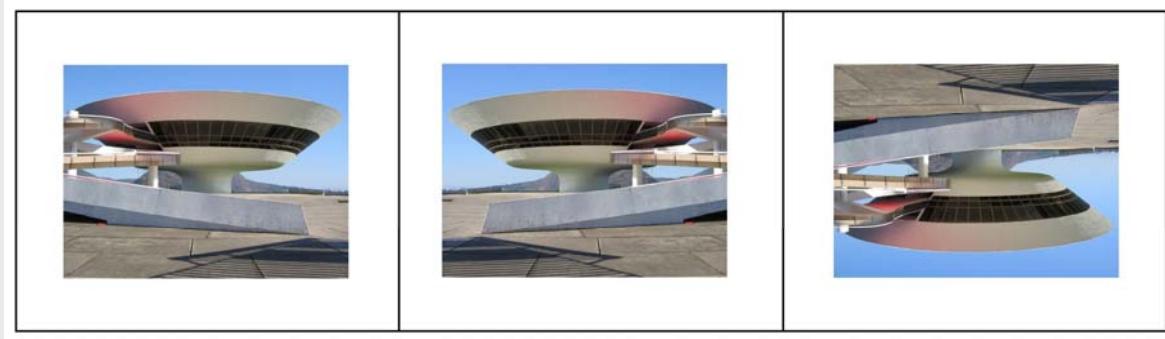
# Espelhamento ou reflexão

$$\begin{bmatrix} x_d \\ y_d \\ 1 \end{bmatrix} = \begin{bmatrix} -1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_o \\ y_o \\ 1 \end{bmatrix}$$

(4.8)

$$\begin{bmatrix} x_d \\ y_d \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_o \\ y_o \\ 1 \end{bmatrix}$$

(4.9)



(a)

(b)

(c)

Figura 4.17 – Exemplo de espelhamento. (a) Imagem Original. (b) Flip Horizontal. (c) Flip Vertical.

# Deformações e *Morphing*

Deformação: considera que a imagem está por segmentos de reta com seus respectivos vértices e altera a forma dos objetos a partir de mudanças de posição dos segmentos envolventes.

Morphing: considera o processo de deformação aliado à decomposição de suas cores.

# Deformações

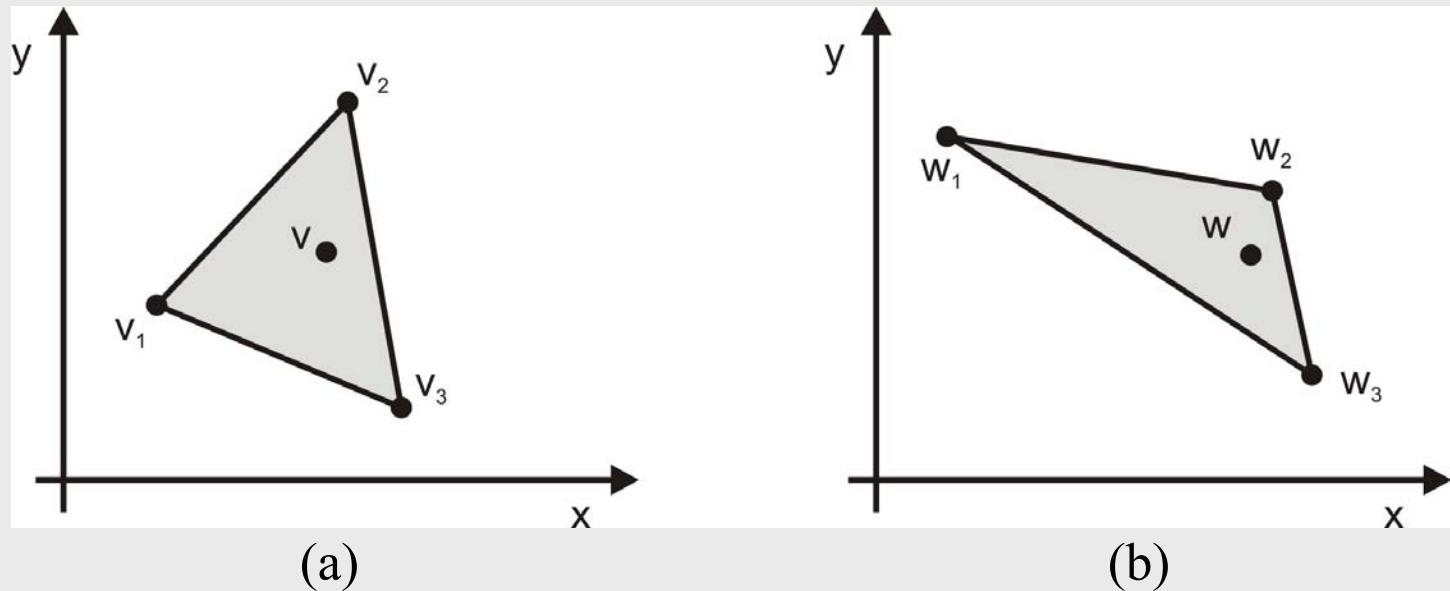


Figura 4.18 - Deformação simples de uma região triangular com pontos de vértice não-colineares. (a)  $v = c_1v_1 + c_2v_2 + c_3v_3$ . (b)  $w = c_1w_1 + c_2w_2 + c_3w_3$

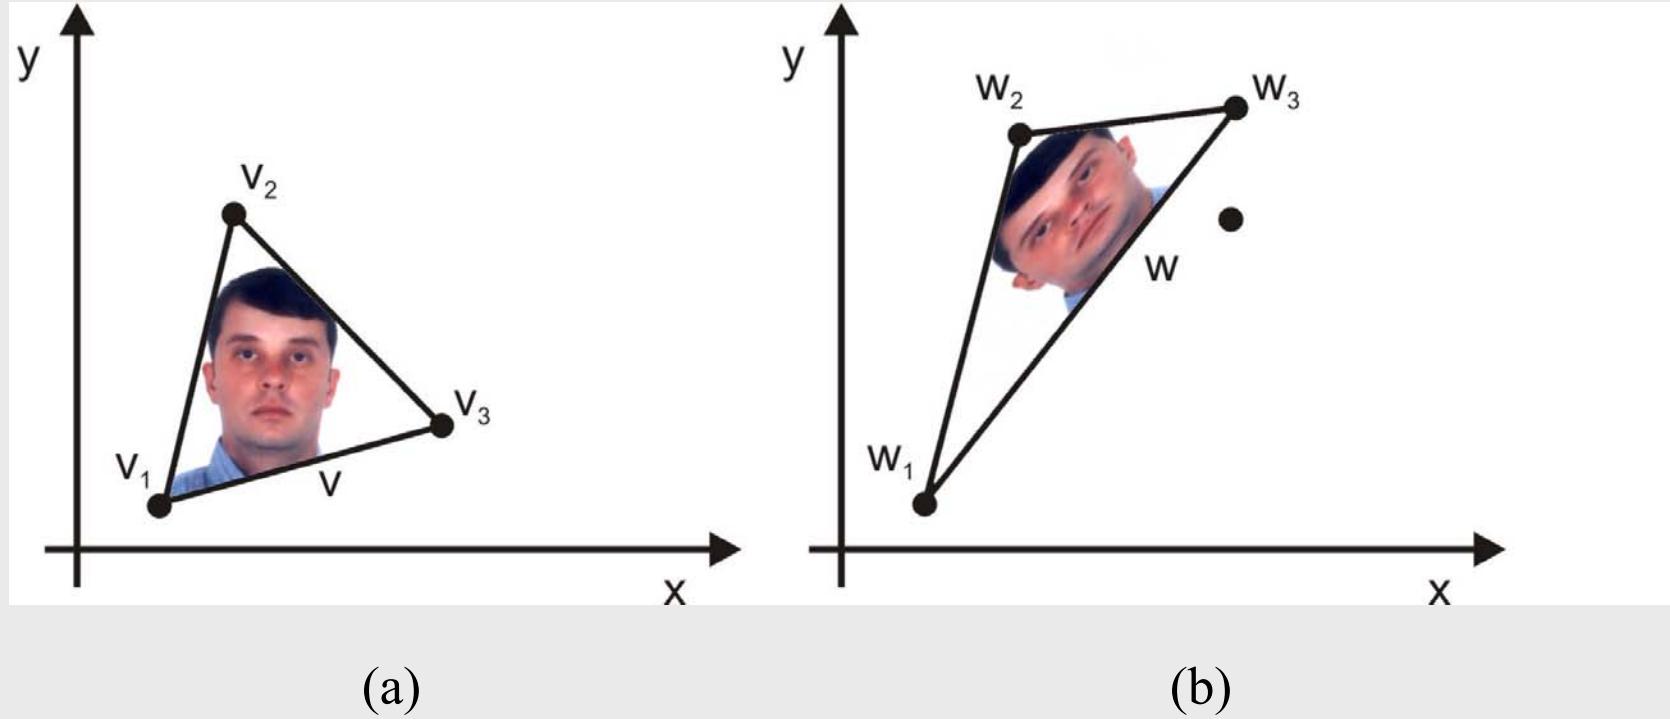


Figura 4.19 - Triângulo inicial com uma imagem. (a) Imagem original:  $v = c_1v_1 + c_2v_2 + c_3v_3$ . (b) Imagem transformada:  $w = c_1w_1 + c_2w_2 + c_3w_3$ .

Pode-se repartir uma imagem em várias regiões triangulares e deformar cada região de uma maneira diferente:

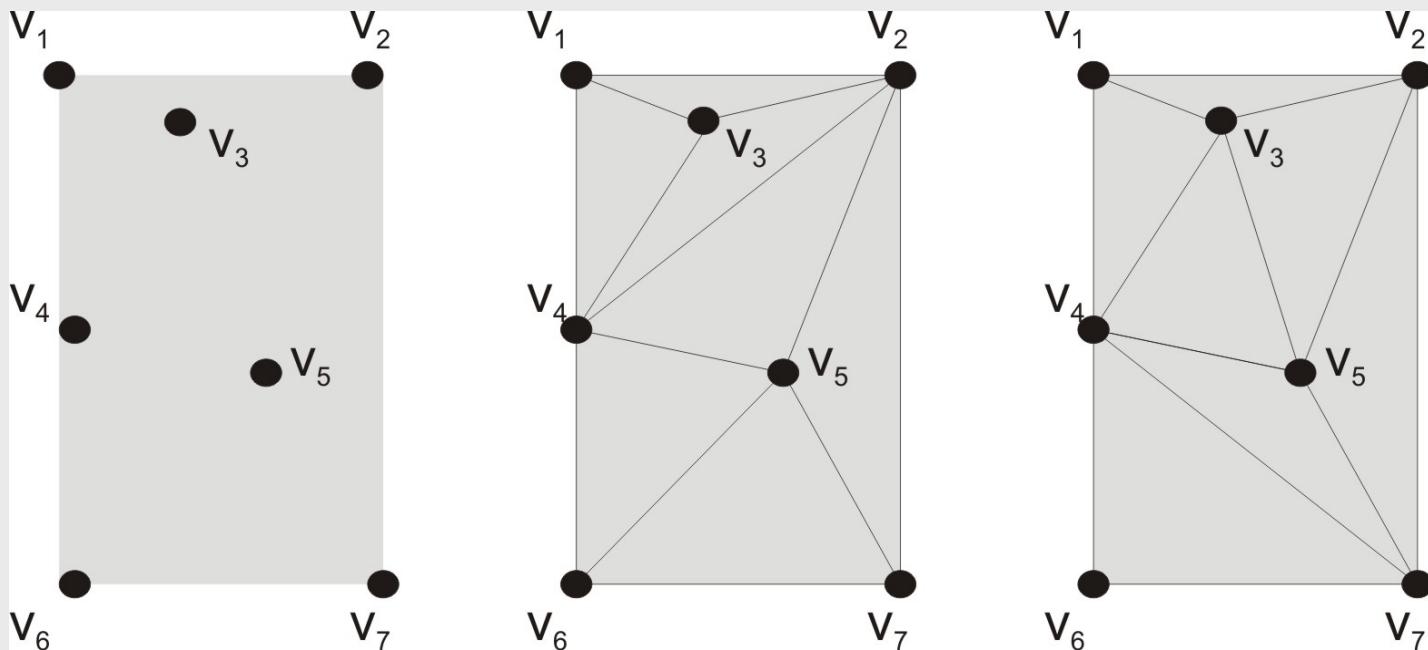


Figura 4.20 – Fazendo Triangulações

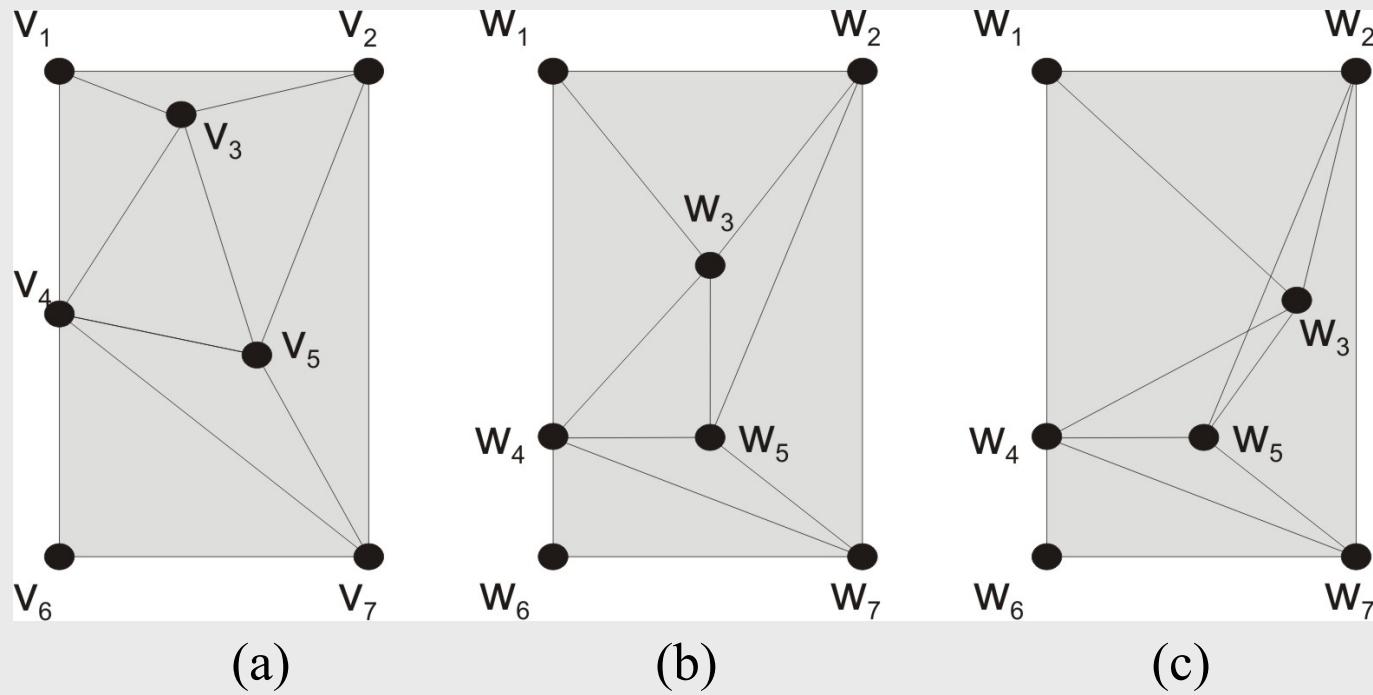


Figura 4.21 – Deformações por movimento de pontos dos vértices permitida(b) e não permitida (c)

# Deformações Dependentes do Tempo

É um conjunto de deformações geradas quando os pontos de vértice da imagem inicial são movidos continuamente ao longo do tempo desde suas posições originais até posições finais especificadas.

$$u_i(t) = (1 - t)v_i + t w_i \quad (4.15)$$

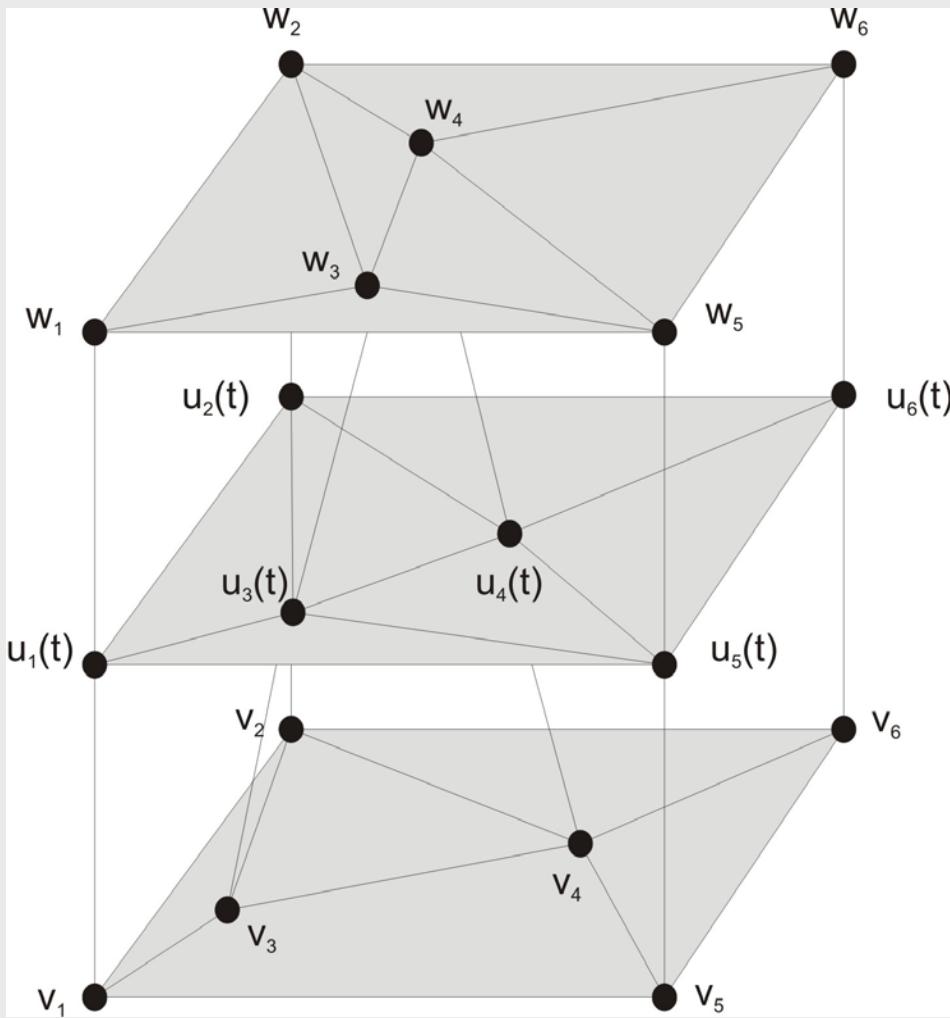


Figura 4.22 – Triangulação dependente do tempo de uma região

# **Morphing**

O termo *morph* tem como origem a palavra grega *morhos* que significa forma, sendo a ciência que estuda as formas chamada de *Morfologia*. *Morphing* é uma redução da palavra *metamorfose*.

O *morphing* envolve simultaneamente dois tipos de transformação:

- (a) de deformação (*warping*);
- (b) de tons (*cross-dissolve ou decomposição cruzada*).

$$\begin{aligned}
 novo\_red &= (r\_origem + r\_destino) / 2 \\
 novo\_green &= (g\_origem + g\_destino) / 2 \\
 novo\_blue &= (b\_origem + b\_destino) / 2
 \end{aligned} \tag{4.16}$$

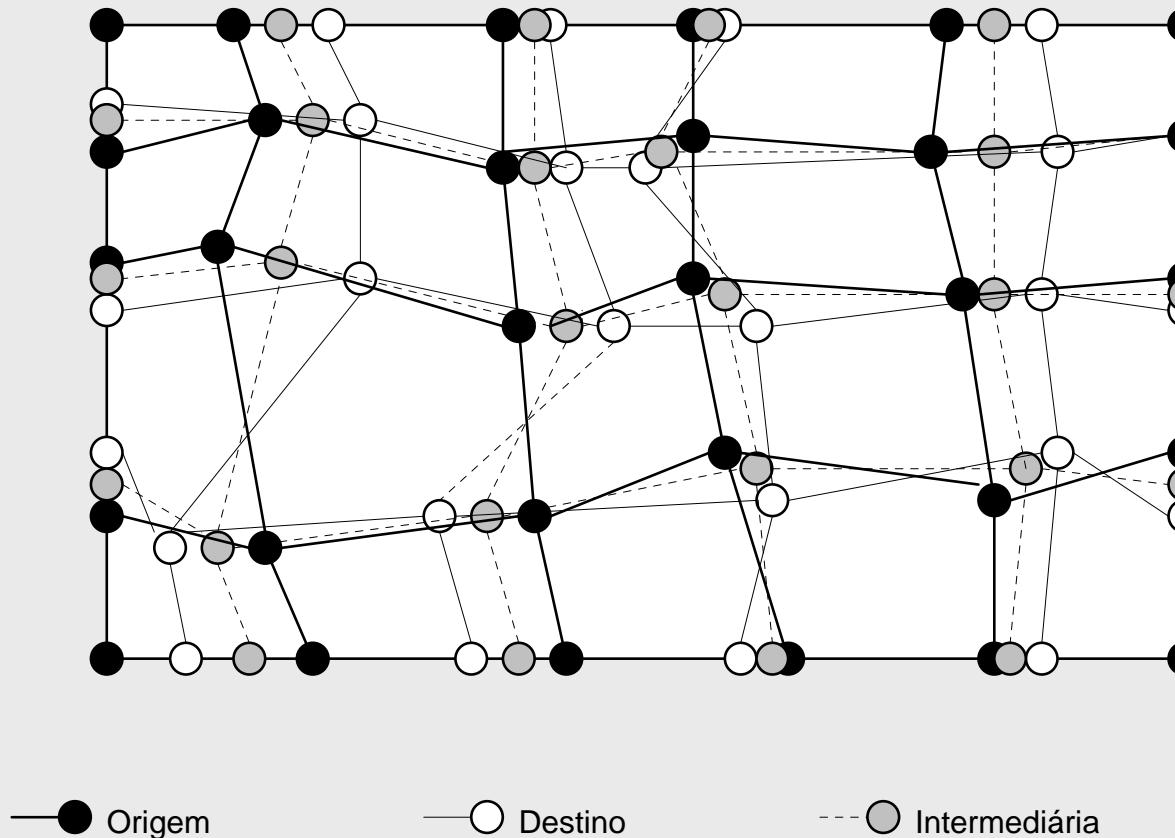


Figura 4.23 - Transformação de *pixels* origem em destino.

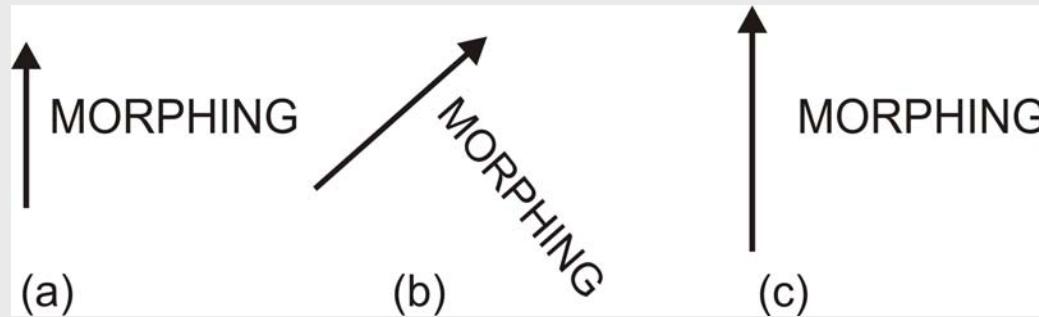


Figura 4.24 - Efeitos decorrentes de alterações em uma única linha de controle.

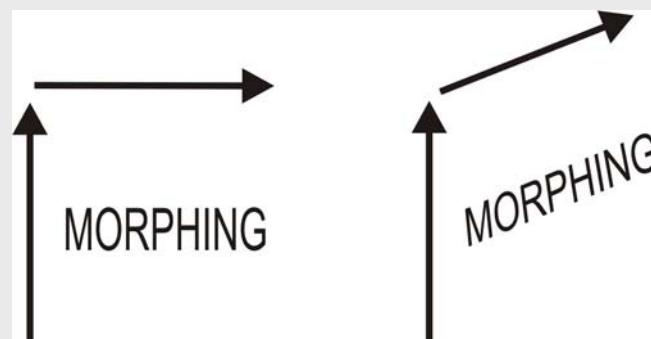


Figura 4.25 - Efeito de duas linhas de controle.

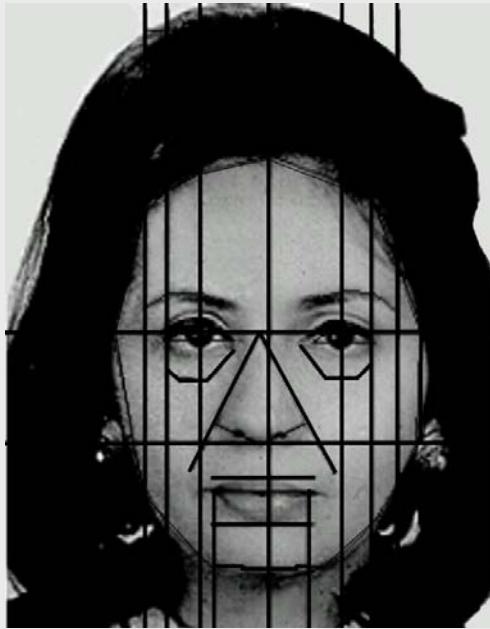


Figura 4.26 - Segmentos de Controle e linhas auxiliares.

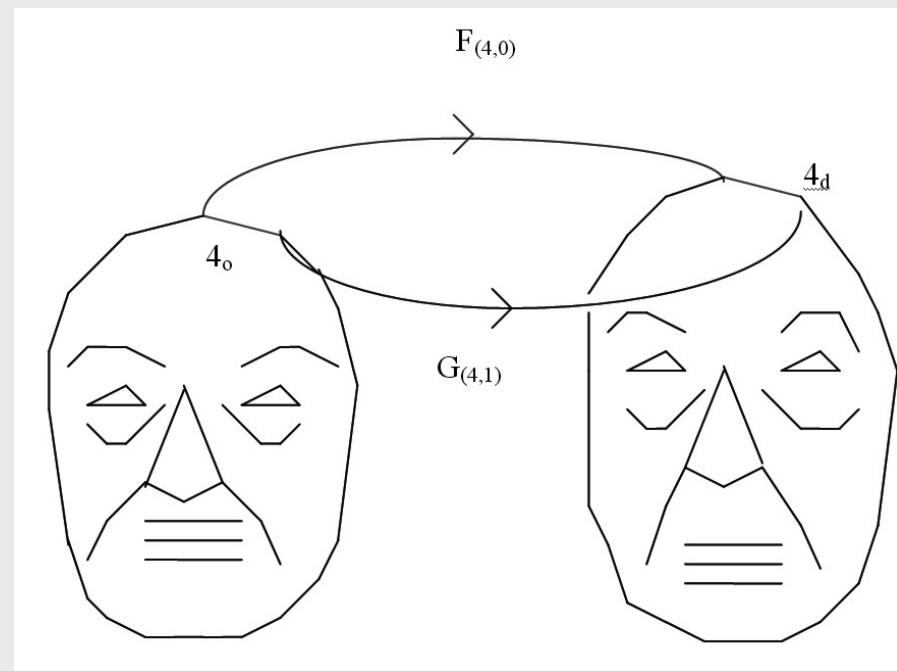


Figura 4.27 - Exemplo de interpolação de segmentos.

# Filtragem de Imagens

# **Filtragem de Imagens**

**5.1. Filtragem no Domínio da Frequência**

**5.2. Filtragem no Domínio Espacial**

# Objetivo

Melhorar a qualidade das imagens através da:

- ampliação do seu contraste;
- eliminação de padrões periódicos ou aleatórios;
- melhoria no seu foco e acentuação de características.

# Classificação

- Domínio ou espaço em que atuam: da freqüência ou espacial.
- Tipo de freqüência: passa ou elimina baixas freqüências; passa ou elimina altas freqüências; e passa ou elimina faixas de freqüências.
- Linearidade: lineares ou inversíveis ou não lineares.
- Tipo de aplicação: suavização; contraste; adaptativos; globais; janelados; ou, locais.

# Filtragem no Domínio da Frequência

Filtragem Passa Baixa

Filtragem Passa Alta

Outros filtros no domínio de freqüência

Imagens de Impressão Digital no Domínio Fourier

Filtro de Gabor

# Filtragem no Domínio da Frequência

- 1- A imagem é **transformada do domínio espacial para o da freqüência** (transformada de Fourier).
- 2- Operações de filtragem são realizadas nessa imagem.
- 3- Realiza-se o processo inverso, onde a imagem no domínio da freqüência é **transformada para o domínio espacial**.



Figura 5.1 - Esquema de processamento no domínio da freqüência usando a transformada de imagens

# Transformada de Fourier

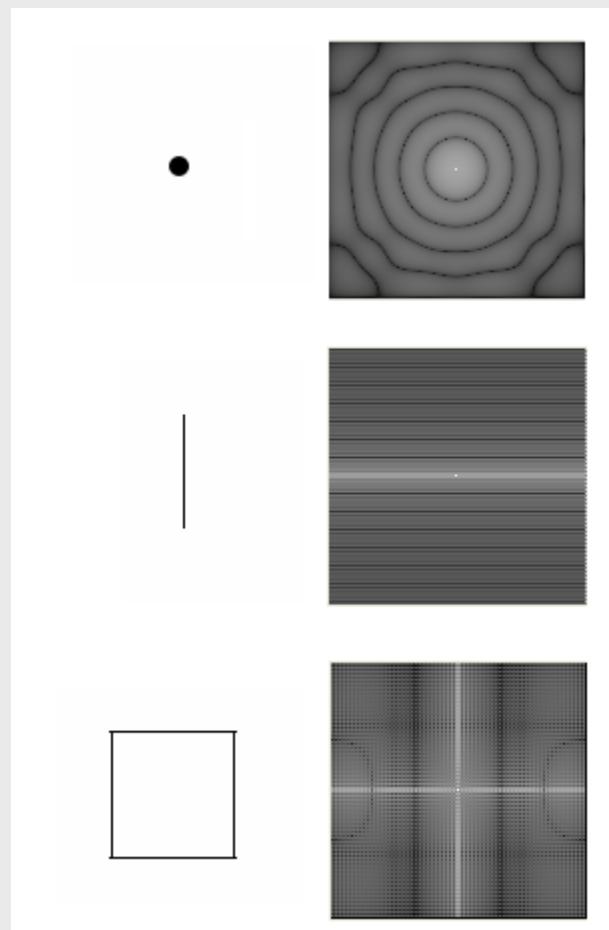


Figura 5.2- Algumas imagens representadas como funções bidimensionais e seus espectros de Fourier.

A transformada de Fourier de uma função contínua  $f(x)$  de uma variável real  $x$  pode ser definida como:

$$F(u) = \int_{-\infty}^{\infty} f(x) \exp[-j2\pi ux] dx \text{ onde } j = \sqrt{-1} \quad (5.1)$$

A partir de  $F(u)$ , pode-se obter  $f(x)$  através da transformada inversa de Fourier:

$$f(x) = \int_{-\infty}^{\infty} F(u) \exp[j2\pi ux] du \quad (5.2)$$

Essas duas equações são chamadas de par de transformada de Fourier e podem existir se forem integráveis e se  $f(x)$  for contínua.

A transformada de Fourier de uma função é uma função complexa:

$$F(u) = R(u) + jI(u) \quad (5.3)$$

para obter-se o espectro de Fourier e o ângulo de fase da função apresenta-se a equação (5.3) na forma exponencial:

$$F(u) = |F(u)|e^{j\theta(u)} \quad (5.4)$$

Tem-se o espectro de Fourier, o ângulo de fase e o espectro da potência ao quadrado:

$$|F(u)| = [R^2(u) + I^2(u)]^{1/2} \quad (5.5)$$

$$\phi(u) = \tan^{-1}[I(u)/R(u)] \quad (5.6)$$

$$P(u) = R^2(u) + I^2(u) \quad (5.7)$$

Transformada de Fourier para uma função bidimensional:

$$F(u, v) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) \exp[-j2\pi(ux + vy)] dx dy \quad (5.9)$$

$$f(x, y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} F(u, v) \exp[j2\pi(ux + vy)] du dv \quad (5.10)$$

Tem-se o espectro de Fourier, o ângulo de fase e o espectro da potência ao quadrado:

$$|F(u, v)| = [R^2(u, v) + I^2(u, v)]^{1/2} \quad (5.12)$$

$$\phi(u, v) = \tan^{-1}[I(u, v) / R(u, v)] \quad (5.13)$$

$$P(u, v) = R^2(u, v) + I^2(u, v) \quad (5.14)$$

# Processamento de imagens no domínio de Fourier

- 1- A imagem  $I(x,y)$  é transformada para o **domínio de Fourier** (transformada discreta).
- 2- A imagem no domínio de Fourier é representada por  $F(u,v)$  e é convoluída com o filtro  $H(u,v)$ .
- 3- Ao produto  $F(u,v) H(u,v)$  é aplicada a inversa da transformada de Fourier para retornar ao **domínio espacial**, onde se tem a imagem processada  $I'(x,y)$ .

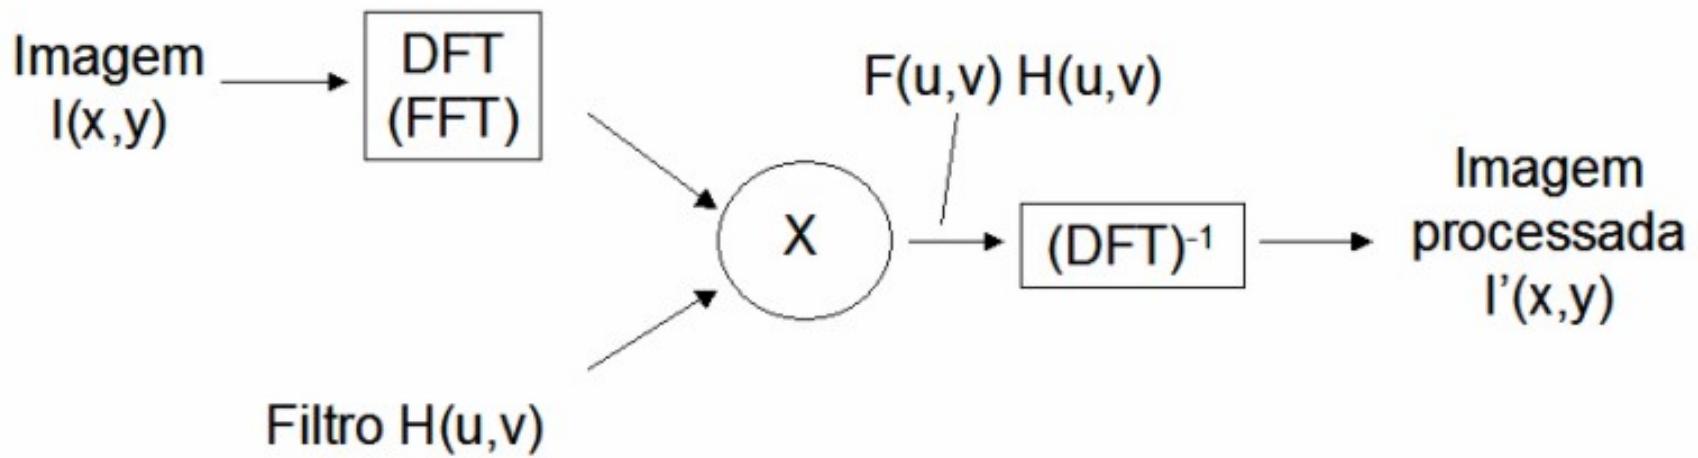


Figura 5.5 - Esquema ilustrando os passos da filtragem no domínio de Fourier

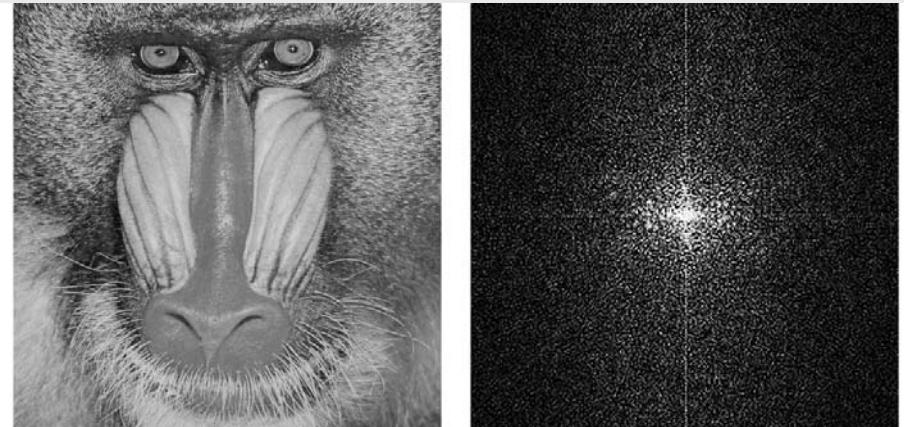


Figura 5.6 - Imagem Baboon e seu espectro de Fourier.

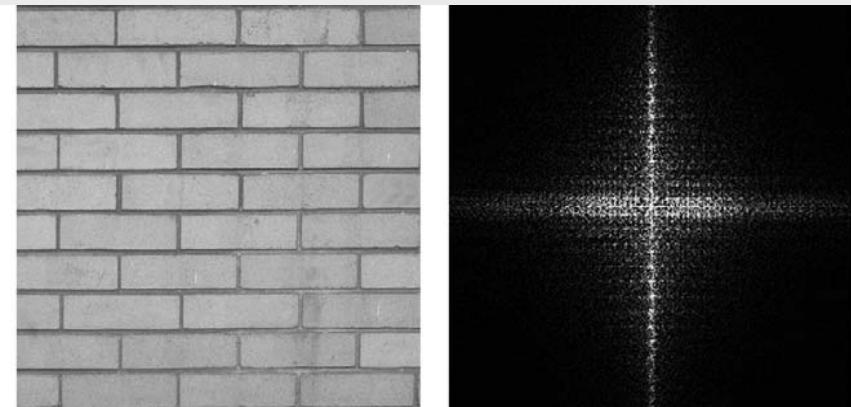


Figura 5.7 - Imagem Brick e seu espectro de Fourier.

# Filtragem Passa Baixa

- Os detalhes da imagem que geram altas freqüências. (ex: bordas, lados e outras transições abruptas de nível de cinza).
- Utilizando um filtro passa baixa obtém-se uma imagem menos nítida ou suavizada.
- Tem-se uma perda de detalhes que são os componentes de altas freqüências.

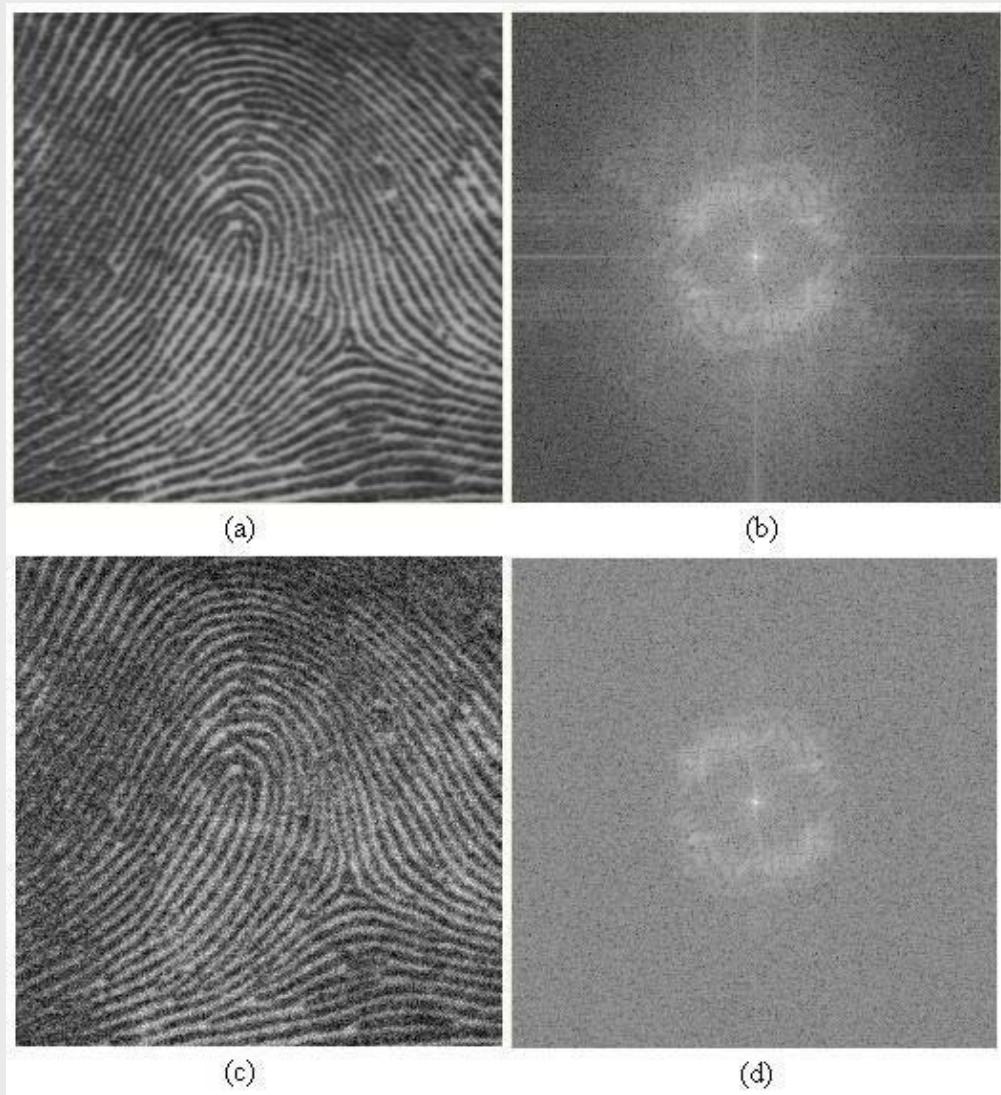


Figura 5.11 - Comparação do espectro de Fourier de imagens de impressão digital sem ruído (a) (b) e com ruído (c) (d).

## Filtro passa baixa ideal:

$$H(u,v) = 1 \text{ se } u^2 + v^2 < r^2$$

$$H(u,v) = 0 \text{ se } u^2 + v^2 \geq r^2$$

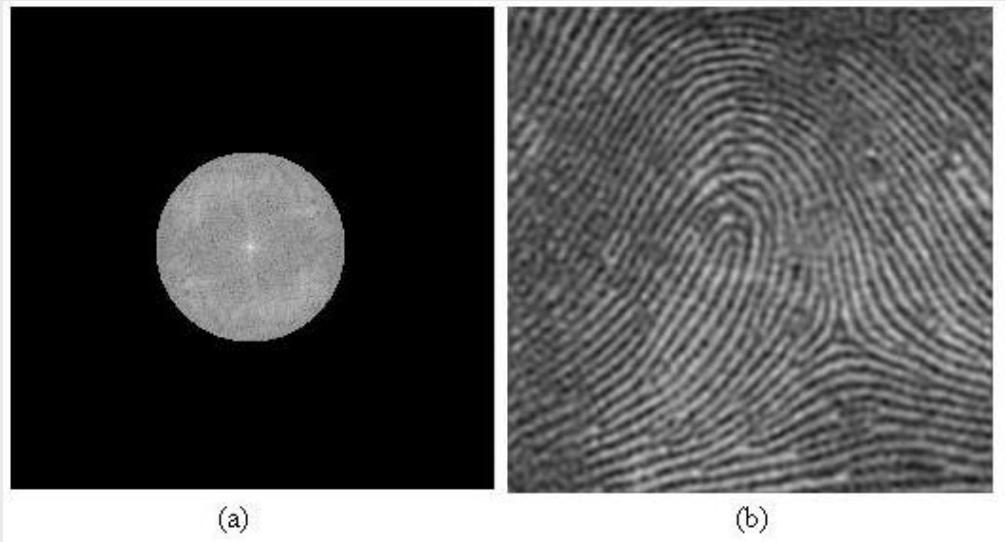


Figura 5.12 - Resultado da filtragem passa baixa

# Filtragem Passa Alta

Na filtragem passa alta, os componentes de alta freqüência da transformada de Fourier não são alterados, enquanto os de baixa freqüência são removidos.

Isto faz com que os detalhes finos da imagem sejam enfatizados.

## Filtro passa alta ideal:

$$H(u, v) = 0 \text{ se } u^2 + v^2 < r^2$$

$$H(u, v) = 1 \text{ se } u^2 + v^2 \geq r^2$$

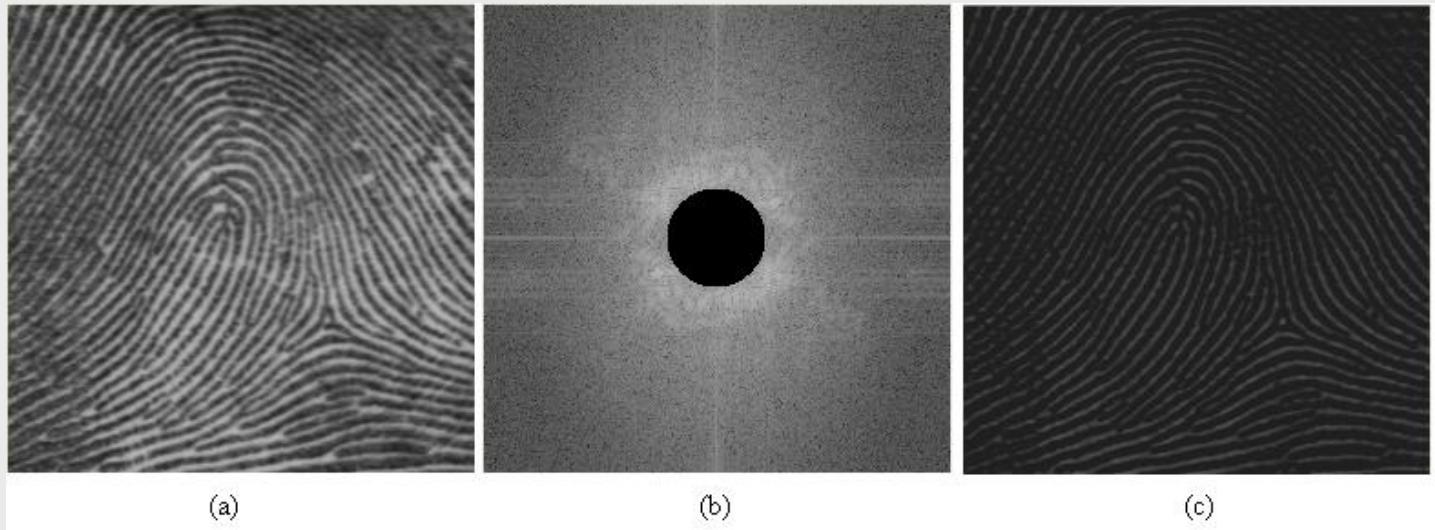


Figura 5.13 - Resultado da filtragem passa alta.

# Outros filtros no domínio de freqüência

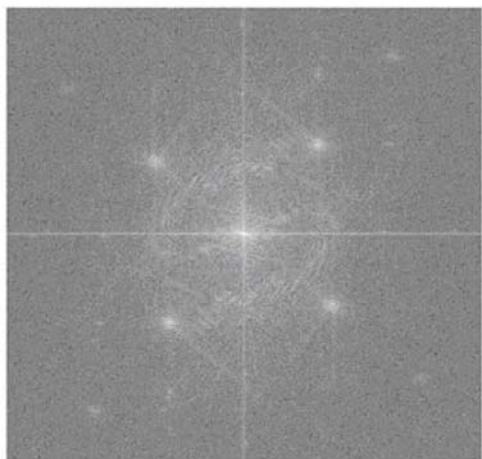


Figura 5.14 - Espectro de Fourier da imagem.

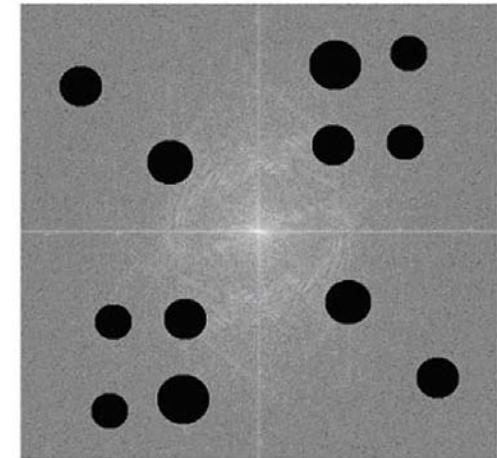
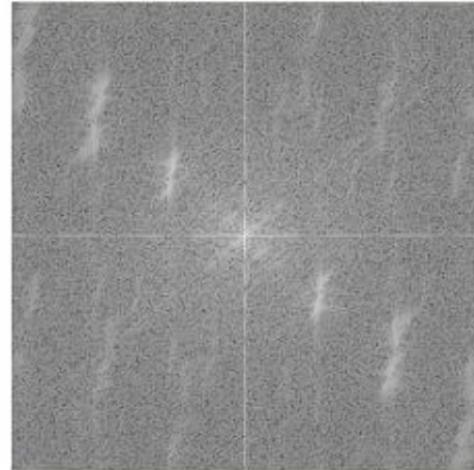


Figura 5.15 - Resultado da filtragem utilizando filtro circular não centrado na origem.



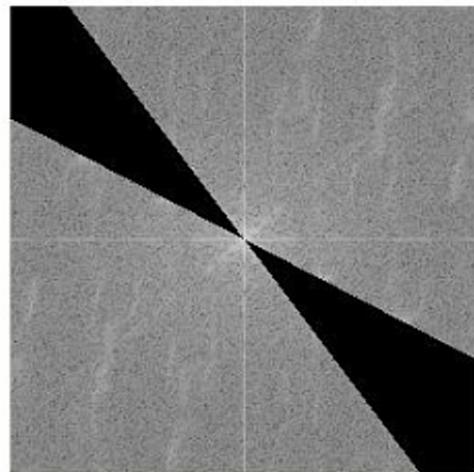
(a)



(b)



(c)

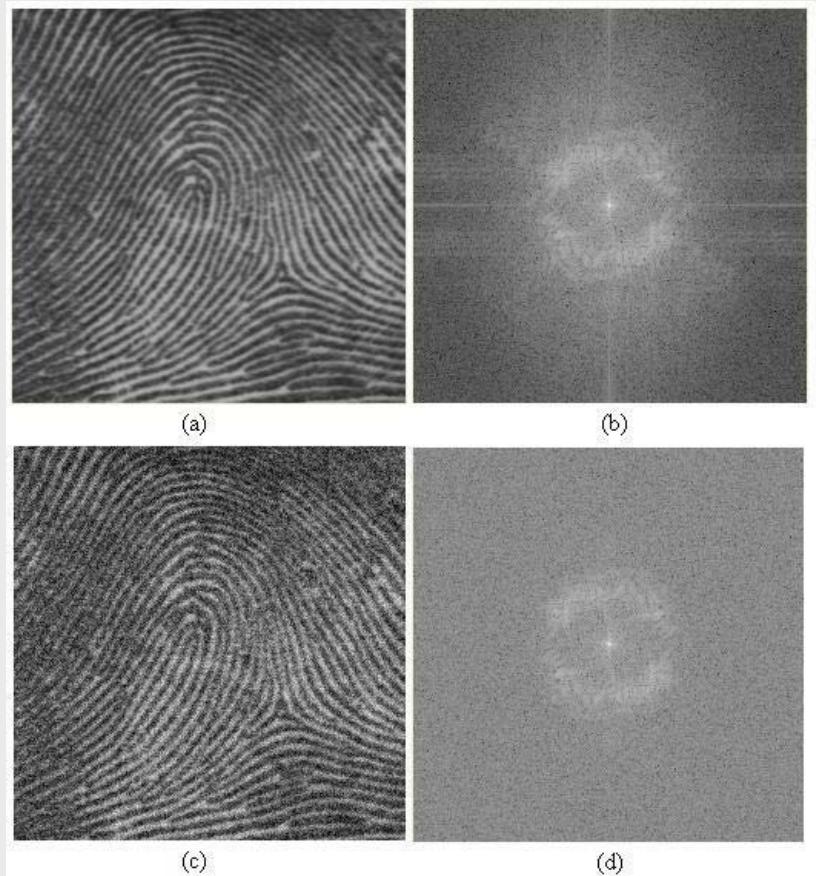


(d)

Figura 5.16 - Resultado da filtragem utilizando filtro setor angular.

# Imagens de Impressão Digital no Domínio Fourier

Observa-se no espectro de Fourier de uma impressão digital um acúmulo de energia em torno de um anel, devido ao fato das cristas se comportarem como senóides, apresentando freqüências bem definidas.



Nos espectros de Fourier, de partes desta imagem, aparecem dois picos de intensidade simétricos, em relação à origem.

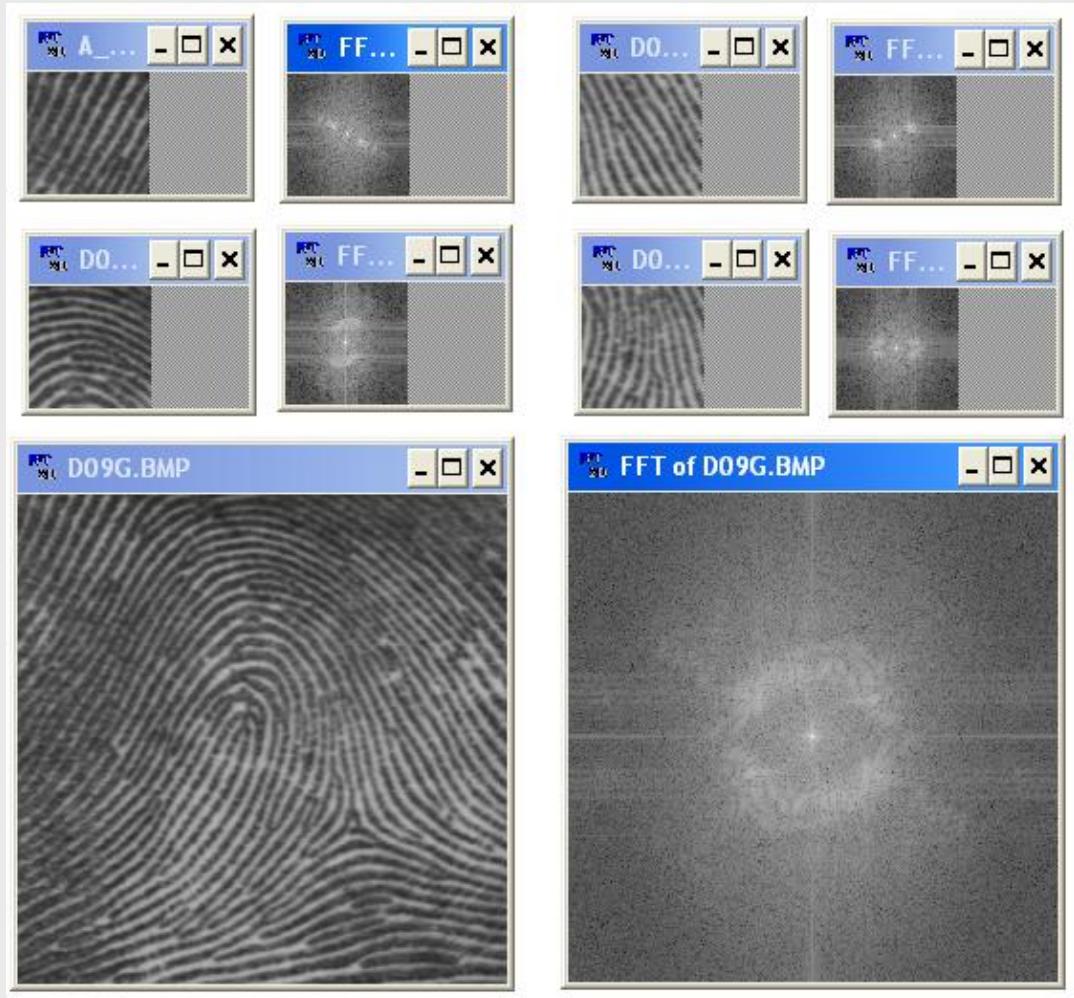
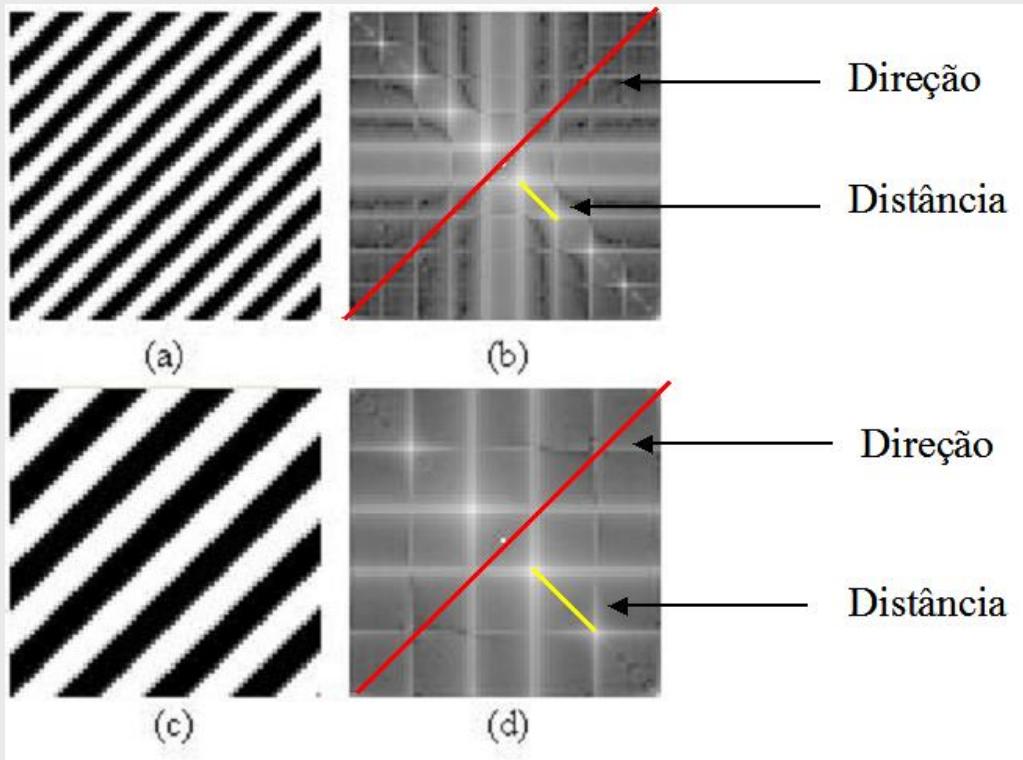


Figura 5.19 - Fragmentos de uma impressão digital e seus espectros de Fourier.



De acordo com a localização desses picos têm-se: a distância e a direção das cristas na região.

Figura 5.20- Imagens sintéticas representando um fragmento de impressão digital e seus espectros de Fourier.

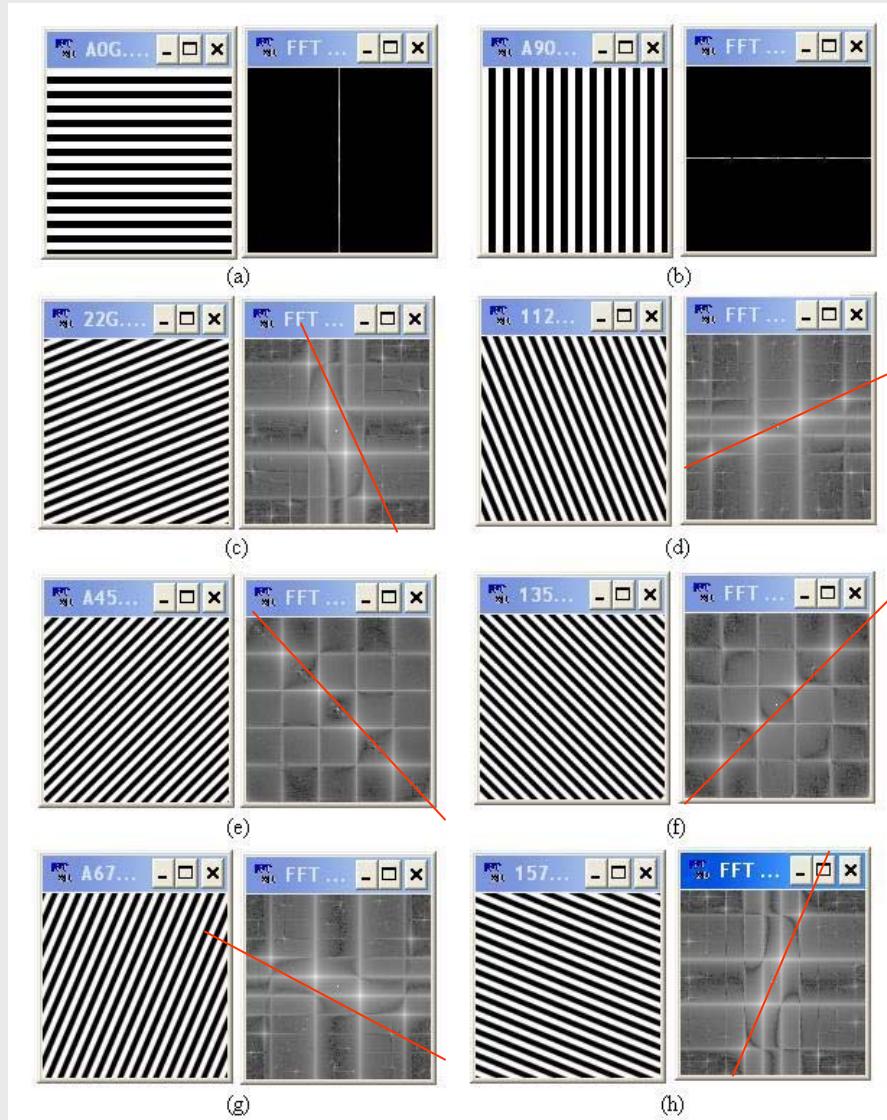


Figura 5.21 - Imagens sintéticas com listras inclinadas e seus espectros de Fourier.

# Filtro de Gabor

- Filtro linear bi-dimensional e não variante ao deslocamento.
- Pode ser entendido como o produto de uma função gaussiana, simétrica em relação à origem e uma função cossenoidal.

## Aplicações:

- Segmentação de imagens
- Reconhecimento de faces
- Reconhecimento de assinaturas
- Melhoria e identificação de impressões digitais

## Forma geral:

$$G(x, y, f, \theta, \sigma) = \exp\left[-\frac{1}{2}\left(\frac{x_\theta^2}{\sigma_x^2} + \frac{y_\theta^2}{\sigma_y^2}\right)\right] \cdot \exp[2\pi j f(x_\theta)] \quad (5.24)$$

Onde:

$$x_\theta = x \cos \theta + y \sin \theta \quad y_\theta = -x \sin \theta + y \cos \theta$$

e  $x, y$  são as coordenadas espaciais da imagem,  $j = \sqrt{-1}$

## Parâmetros:

- 1)  $f$  é a freqüência da onda no plano senoidal;
- 2)  $\theta_k$  é a orientação do filtro;
- 3)  $\sigma_x$  e  $\sigma_y$  é o desvio padrão da função gaussiana ao longo dos eixos  $x$  e  $y$ , respectivamente.

Este filtro pode ser decomposto em componentes reais e imaginários:

$$G_{real}(x, y, f, \theta, \sigma) = \exp\left\{-\frac{1}{2} \cdot \left[ \frac{x_\theta^2}{\sigma_x^2} + \frac{y_\theta^2}{\sigma_y^2} \right]\right\} \cdot \cos(2 \cdot \pi \cdot f \cdot x_\theta) \quad (5.25)$$

$$G_{imag}(x, y, f, \theta, \sigma) = \exp\left\{-\frac{1}{2} \cdot \left[ \frac{x_\theta^2}{\sigma_x^2} + \frac{y_\theta^2}{\sigma_y^2} \right]\right\} \cdot \sin(2 \cdot \pi \cdot f \cdot x_\theta) \quad (5.26)$$

sendo  $G_{complexo} = G_{real} + j G_{imag}$

$$G_{real}(x, y, f, \theta, \sigma) = W(x, y, \theta, \sigma) \cdot V(x, f) \quad (5.27)$$

então é possível visualizar a função gaussiana:

$$W(x, y, \theta, \sigma) = \exp\left\{-\frac{1}{2} \cdot \left[ \frac{x_\theta^2}{\sigma_x^2} + \frac{y_\theta^2}{\sigma_y^2} \right]\right\} \quad (5.28)$$

e a função cossenoidal:

$$V(y, f) = \cos(2 \cdot \pi \cdot f \cdot x_\theta) \quad (5.29)$$

Como a função:

$$G_{real}(x, y, f, \theta, \sigma)$$

é obtida pelo produto de uma gaussiana por uma cossenoidal de freqüência  $f$ , então pode ser representada no domínio da freqüência e sua transformada de Fourier pode ser obtida pela convolução da transformada de Fourier dessas duas funções.

O resultado dessa convolução é um **filtro passa banda**, que realça as senóides com freqüências em torno de  $f$ , suprimindo seus ruídos.

Uma das dificuldades para utilização do filtro de Gabor é a escolha ou obtenção de seus parâmetros.

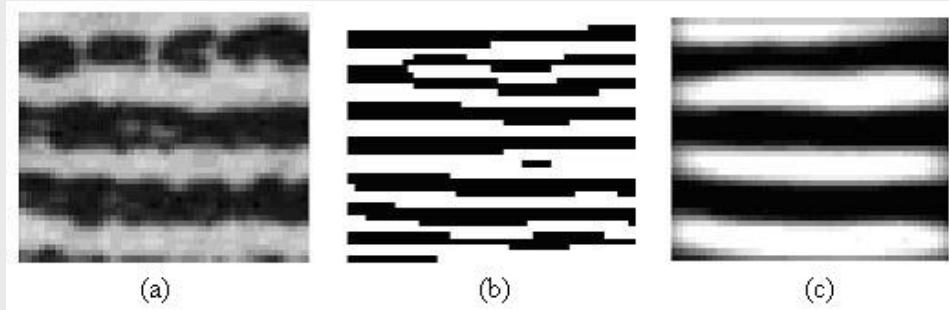


Figura 5.23 - Resultado de uma imagem de impressão digital filtrada por um filtro de Gabor com o parâmetro  $f$  incorreto e com parâmetro  $f$  correto.

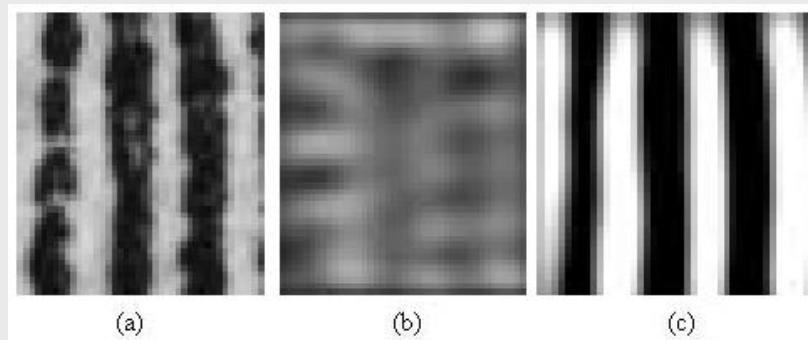


Figura 5.24 - Resultado de uma imagem de impressão digital filtrada por um filtro de Gabor com o parâmetro  $\theta$  incorreto e com parâmetro correto.

# **Filtragem no Domínio Espacial**

**5.2.1. Filtros Lineares e Não Lineares**

**5.2.2. Patamares e Descontinuidades nas Intensidades da Imagem**

**5.2.3. Filtros Passa Baixa – Filtros de Suavização**

**5.2.4. Filtros Passa-Alta ou de Acentuação**

**5.2.5. Filtro alto reforço**

## 5.2. Filtragem no Domínio Espacial

Os métodos de filtragem que trabalham no domínio espacial operam diretamente sobre os *pixels*, normalmente utilizando operações de convolução com máscaras.

O uso de máscaras nas imagens no domínio espacial é usualmente chamado de filtragem espacial e as máscaras são chamadas de filtros espaciais.

$$g(x_i, y_i) = T[f(x_i, y_i))] \quad (5.30)$$

Onde:

$f(x_i, y_i)$  é a imagem de entrada a ser filtrada,

$g(x_i, y_i))$  é a imagem na saída, processada, e,

$T$  é um operador sobre  $f$ , definido em alguma vizinhança do *pixel* de posição  $(x_i, y_i)$ .

## Convolução:

$$g[x, y] = \sum_{i=1}^n \sum_{j=1}^m f[x - i, y - j] \cdot h[i, j] \quad (5.31)$$

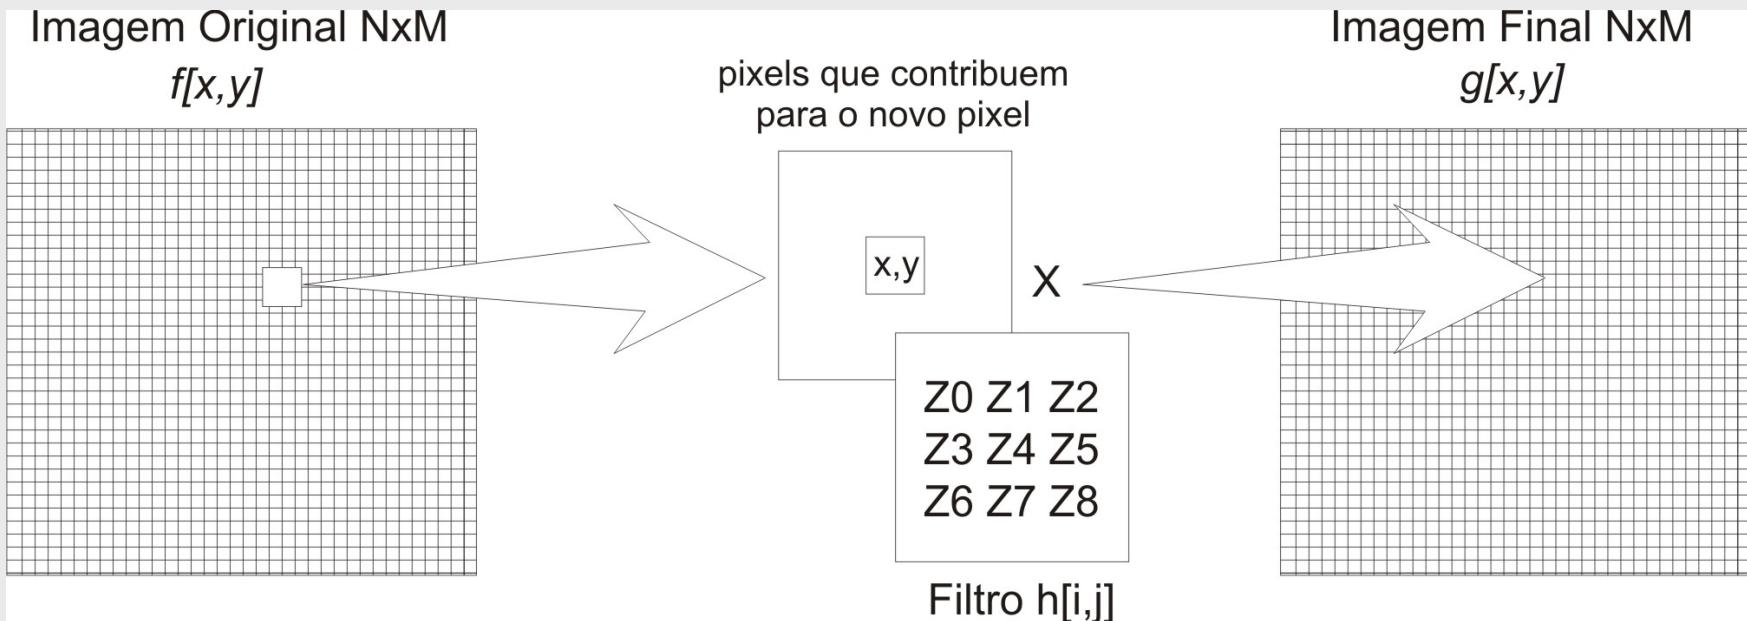


Figura 5.34 - Esquema do processo de convolução por filtragem espacial usando uma máscara  $n \times m$ .

$$g(x,y) = T[f(x,y)] = \quad \quad \quad (5.32)$$

$$\begin{aligned} g(x,y) &= Z_1 f(x-1, y-1) + Z_2 f(x , y-1) + Z_3 f(x+1, y-1) + \\ &\quad Z_4 f(x-1, y) + Z_5 f(x , y) + Z_6 f(x+1, y) + Z_7 f(x-1, y+1) \\ &\quad + Z_8 f(x, y+1) + Z_9 f(x+1, y+1) \end{aligned}$$

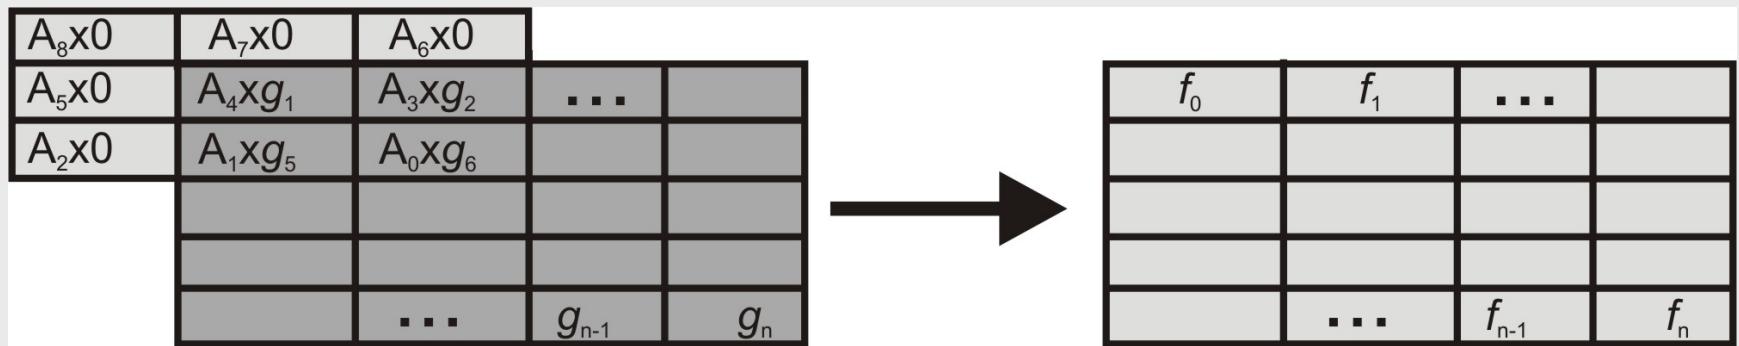


Figura 5.35. Processo de convolução com máscara e o resultado.

# Filtros Lineares e Não Lineares

Filtros lineares: usam máscaras que realizam somas ponderadas das intensidades de *pixels* ao longo da imagem. Se pesos diferentes forem usados em partes diferentes da imagem, o filtro linear é considerado espacialmente variante.

Filtros não-lineares: qualquer filtro que não é uma soma ponderada de *pixels*.

# Patamares e Descontinuidades nas Intensidades da Imagem

O objetivo principal da acentuação de contornos é enfatizar detalhes dos limites de objetos de modo a permitir sua identificação e análise posterior.

- Contorno: identificados por mudanças locais de intensidade significativas na imagem, ocorrendo tipicamente na separação de duas regiões diferentes.
- Regiões ou objetos: identificados por patamares mais ou menos constantes de tons e cores.
- Fronteira: ocorre onde a função de intensidade da imagem,  $f(x_i, y_i)$ , varia bruscamente, consistindo em limites de regiões cujos valores de cor apresentam grandes diferenças.

## Descontinuidades:

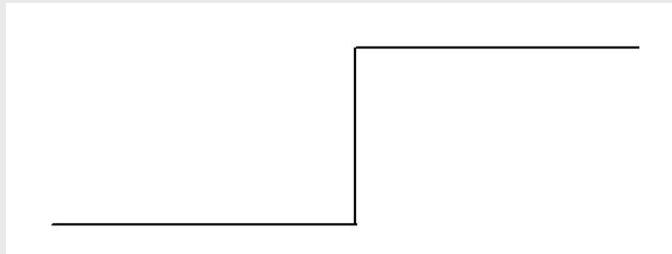


Figura 5.36. Descontinuidade do tipo degrau.

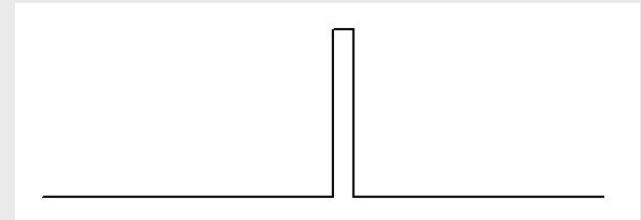


Figura 5.37. Descontinuidade do tipo pico.

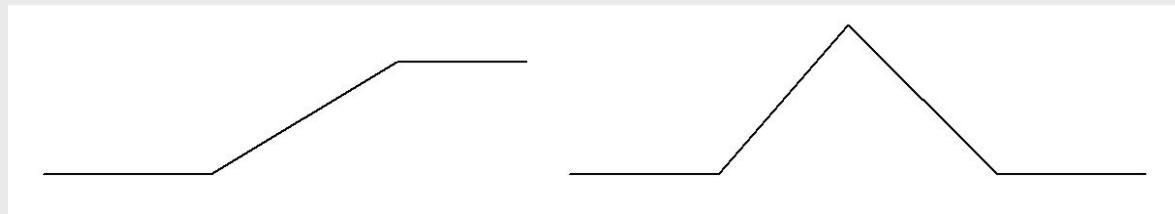


Figura 5.38. Modelos de descontinuidade em rampa.

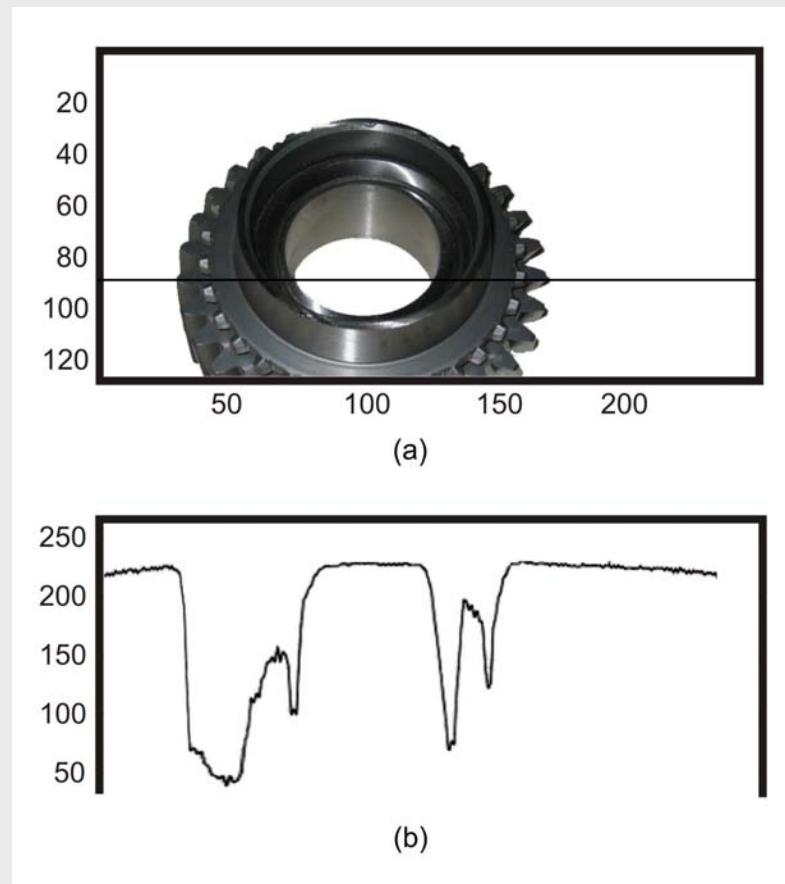


Figura 5.39. Exemplo de variação de intensidade ao longo da linha 80 da imagem Engrenagem.

# Filtros Passa Baixa – Filtros de Suavização

Objetivo:



- **Suavizar** a imagem pela **redução das variações nos de níveis de cinza** que dão à aparência de “serrilhado” nos patamares de intensidade.
- Atenuar as **altas freqüências**, que correspondem às transições abruptas.
- Minimizar ruídos.

## 5.2.3.1. Filtro de Média

Máscara de convolução  $n \times n$  com todos seus coeficientes iguais a 1 e depois dividindo-se o valor obtido pelo número de *pixels* da máscara ( $n^2$ )

$$Z = \frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

(5.33)

$$Z = \frac{1}{25} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix}$$

(5.34)

$$Z = \frac{1}{49} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 & 1 & 1 \end{bmatrix}$$

(5.35)

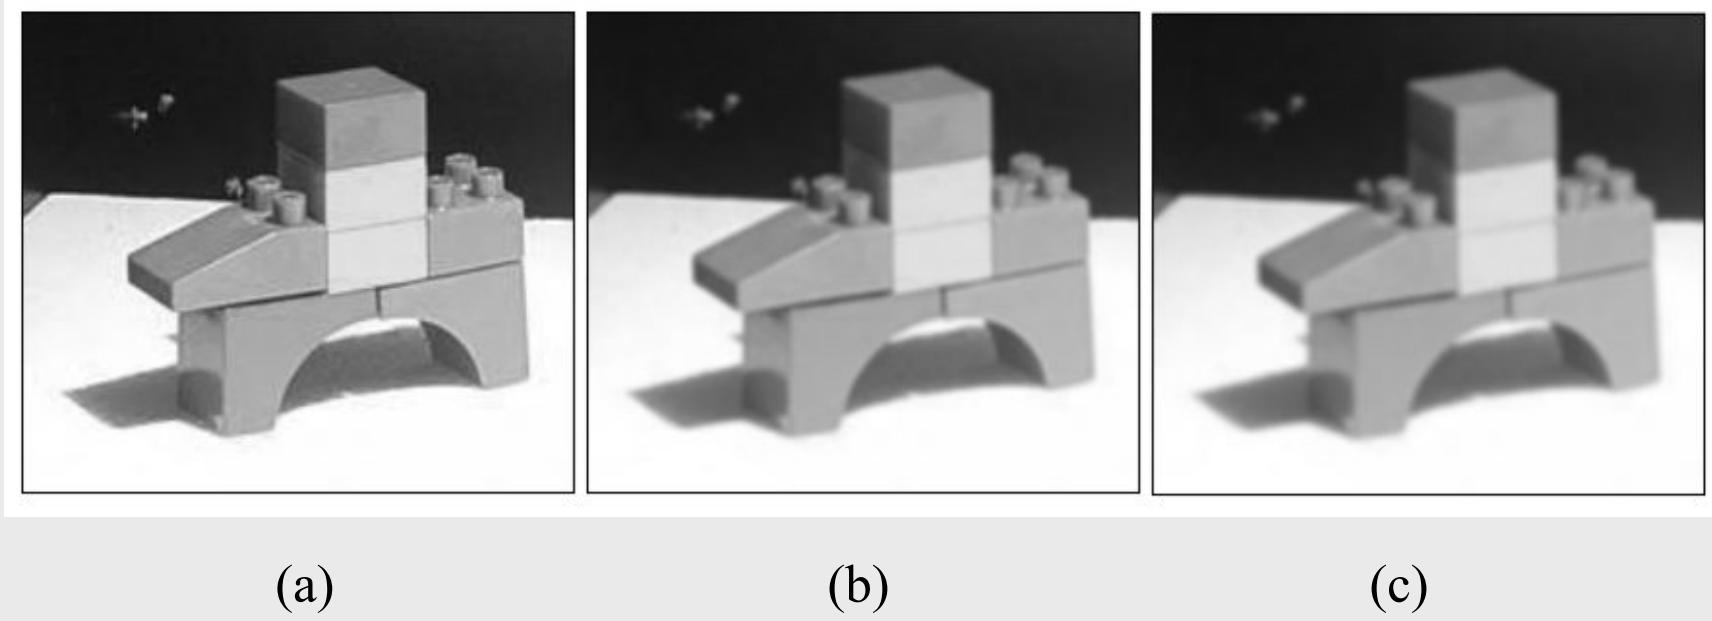


Figura 5.40 – Imagem Blocos original (a) e o resultado da aplicação do filtro de média com máscara  $3 \times 3$  (b) e  $5 \times 5$  (c) (Silva, 2004).

# Filtro Gaussiano

O filtro de suavização Gaussiano é baseado em uma aproximação digital da função gaussiana. O Filtro Gaussiano em 1-D é descrito por:

$$G(x) = \frac{1}{\sigma \sqrt{2\pi}} e^{\frac{-x^2}{2\sigma^2}}$$

(5.36)

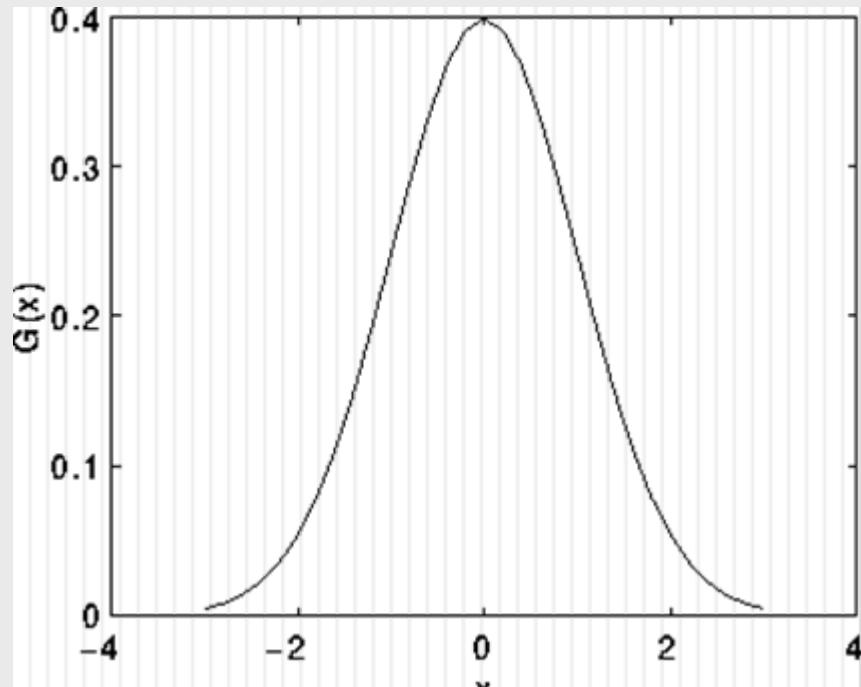


Figura 5.41 - Forma 1D da função Gaussiana com média igual a zero e desvio padrão igual a um.

Em 2-D sua forma é dada por:

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{(x^2 + y^2)}{2\sigma^2}}$$

(5.31)

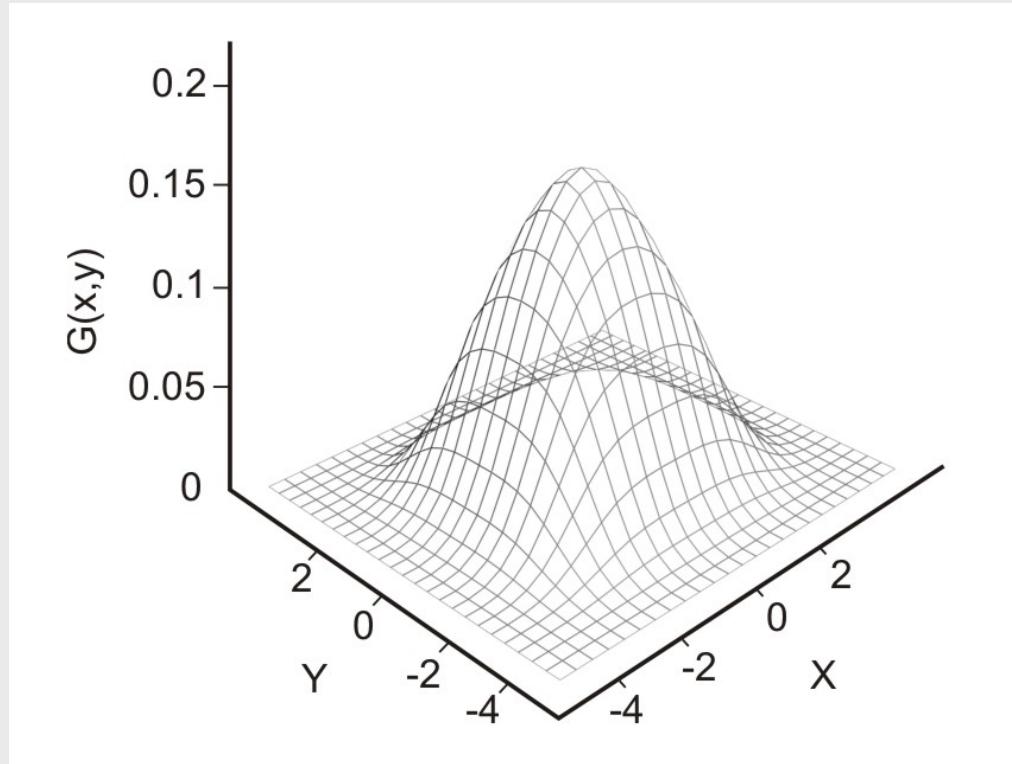


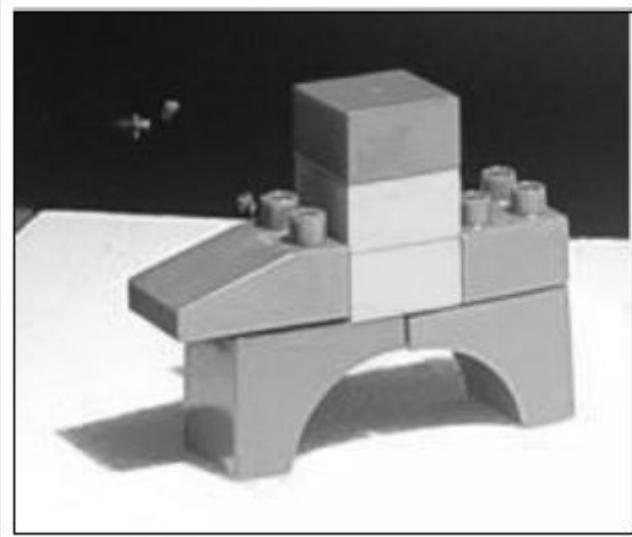
Figura 5.42 – Representação da função Gaussiana em 2D com média em  $(0,0)$  e desvio padrão  $\sigma = 1$ .

Uma forma aproximada da Gaussiana para  $\sigma = 1,0$  é apresentada no kernel 5x5 da eq. 5.32:

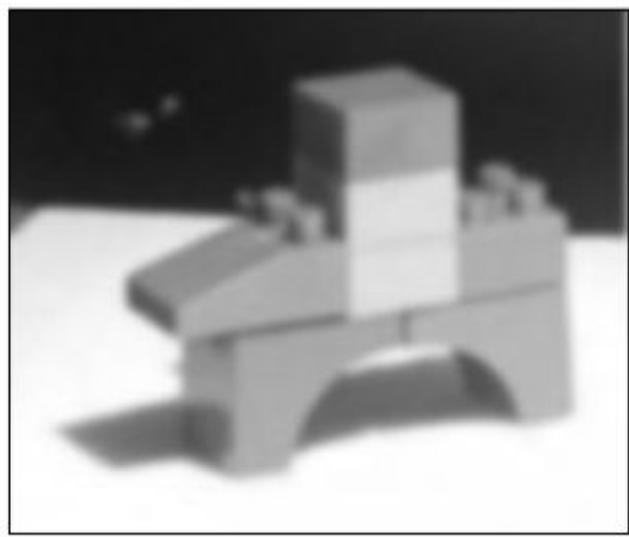
$$Z = \frac{1}{273} \begin{bmatrix} 1 & 4 & 7 & 4 & 1 \\ 4 & 16 & 26 & 16 & 4 \\ 7 & 26 & 41 & 26 & 7 \\ 4 & 16 & 26 & 16 & 4 \\ 1 & 4 & 7 & 4 & 1 \end{bmatrix} \quad (5.38)$$

A forma discreta 3x3 aproximada da função Gaussiana pode ser observada na eq. 5.33:

$$Z = \frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix} \quad (5.39)$$



(a)



(b)

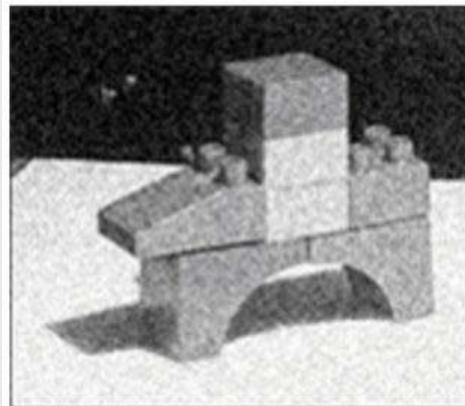
Figura 5.43 – Resultado da aplicação do filtro Gaussiano (b)  
à imagem Blocos (a) (Silva, 2004).

# Filtro de Mediana

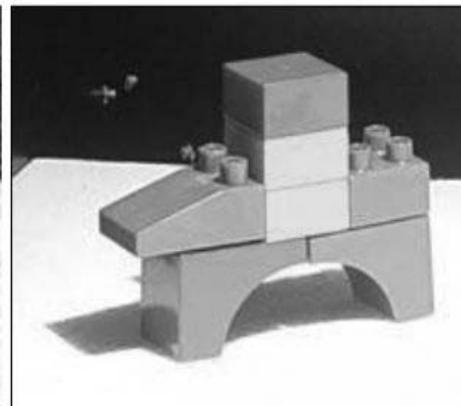
Ordena a intensidade dos *pixels* dentro da área da máscara em ordem crescente ou decrescente, alocando ao *pixel* da imagem correspondente à posição central da máscara, o valor da intensidade do *pixel* que corresponde à posição intermediária do respectivo intervalo ordenado.

## Aplicações:

- ruído é impulsivo (do tipo não contínuo, consistindo em pulsos irregulares de grandes amplitudes),
- ruído do tipo *sal e pimenta* (representando descontinuidades abruptas e isoladas na imagem).



(a)



(b)

Figura 5.45 – Resultado da aplicação do filtro de mediana (b) na imagem Blocos destruída com ruído impulsivo (a) (Silva, 2004).

# Filtros de Ordem e de Moda

**Filtro de ordem:** as intensidades dos pontos da vizinhança do *pixel*  $f(x,y)$ , dentro de uma janela da imagem, são ordenadas e é tomado o valor máximo ou o valor de uma ordem qualquer desta ordenação, como novo valor para  $g(x,y)$ .

**Filtro de moda:** as intensidades dos pontos da vizinhança do *pixel*  $(x,y)$ , dentro de uma janela da imagem, são ordenadas e é tomado como novo valor para  $f(x,y)$ , o valor  $g(x,y)$  mais freqüente da vizinhança.

# Filtro de Média dos $k$ Vizinhos Selecionados

- É um híbrido do método de filtragem pela média.
- Utiliza a diferença absoluta entre o valor de cada elemento da máscara de filtragem e o ponto central para selecionar os  $k$  elementos que participarão do cálculo da média.

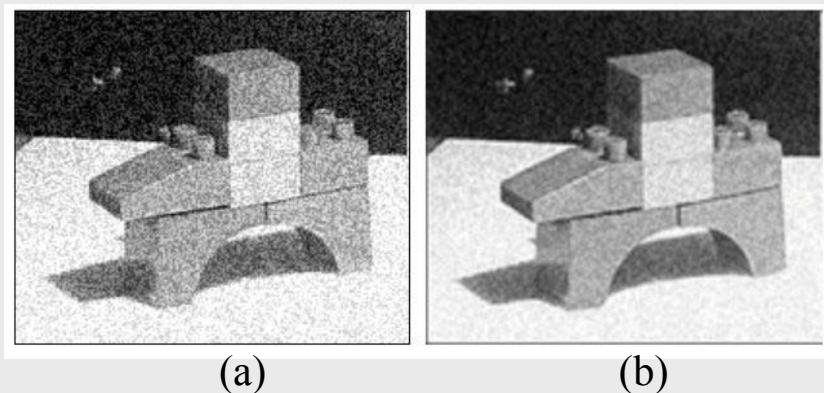


Figura 5.46. Resultado da aplicação do filtro de média dos  $k$  vizinhos (b) sobre a imagem Blocos degradada (a) (Silva, 2004)

# Filtros Passa-Alta ou de Acentuação

- Atenuam ou eliminam as baixas freqüências, realçando as altas freqüências.
- Usados para realçar os detalhes na imagem (*intensificação ou “sharpening”*).
- Destacam características como bordas, linhas, curvas e manchas.
- Tornam mais nítidas as transições entre regiões diferentes (como os contornos), realçando o contraste.

Um filtro passa-alta ideal, no domínio de freqüência  $(u,v)$ , é descrito pela seguinte relação:

$$H(u,v) = \begin{cases} 0 & \text{se } D(u,v) \leq D_0 \\ 1 & \text{se } D(u,v) > D_0 \end{cases} \quad (5.41)$$

onde é a freqüência de corte e  $D(u,v)$  é a distância do ponto  $(u,v)$  à origem do plano de freqüência, isto é:

$$D(u,v) = \sqrt{(u^2 + v^2)} \quad (5.42)$$

# Filtros Gradiente ou Derivada de Imagens

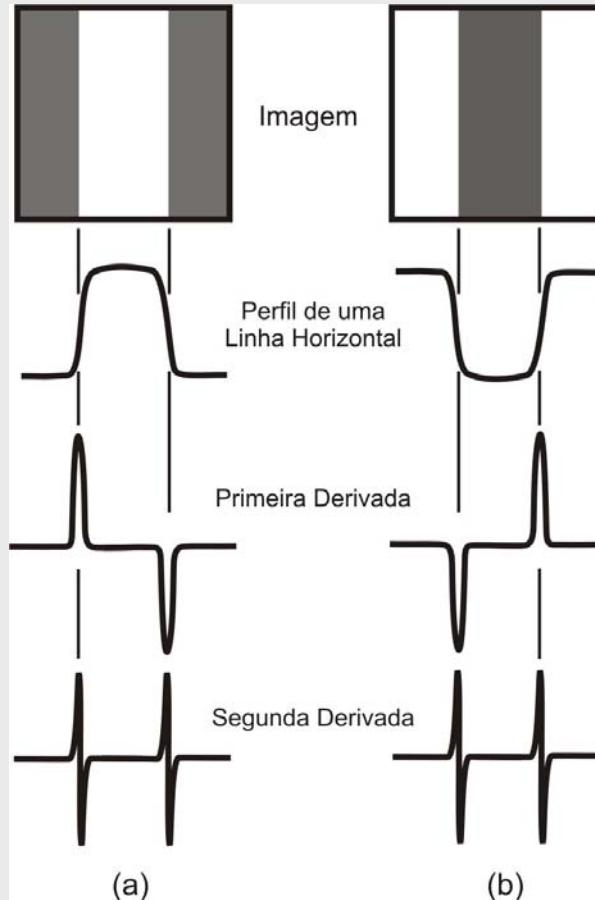


Figura 5.47 - Derivadas de uma Imagem.

O gradiente de uma função de duas variáveis  $f(x,y)$ , nas coordenadas  $(x,y)$  é definido por:

$$\nabla f = \begin{vmatrix} G_x \\ G_y \end{vmatrix} = \begin{vmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{vmatrix} \quad (5.43)$$

a magnitude deste vetor é:

$$|\nabla f| = \left[ G_x^2 + G_y^2 \right]^{1/2} \quad (5.44)$$

A direção do vetor gradiente também é uma característica importante para muitas aplicações, ela é dada por:

$$\alpha(x,y) = \text{arc tang} \frac{G_y}{G_x} \quad (5.46)$$

O gradiente pode ser aproximado por:

$$\nabla[f(x, y)] \approx \left\{ [f(x, y) - f(x+1, y)]^2 + [f(x, y) - f(x, y+1)]^2 \right\}^{1/2} \quad (5.47)$$

que pode ser aproximada usando a diferença na direção  $y$  e na direção  $x$  combinadas como:

$$\nabla f \approx \left[ (Z_5 - Z_8)^2 + (Z_5 - Z_6)^2 \right]^{1/2} \quad (5.48)$$

$$Z = \begin{bmatrix} Z_1 & Z_2 & Z_3 \\ Z_4 & Z_5 & Z_6 \\ Z_7 & Z_8 & Z_9 \end{bmatrix} \quad (5.49)$$

Pode-se também considerar:

$$\nabla f \approx |Z_5 - Z_8| + |Z_5 - Z_6| \quad (5.50)$$

# Filtro e Operador de Sobel

Aplicação de duas máscaras:

$$Z_h = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \quad (5.62)$$

$$Z_v = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \quad (5.63)$$

Considerando  $Z_1$  a  $Z_9$  os tons de cinza em torno do ponto onde o contorno será avaliado este filtro é dado por:

$$G_x = (Z_7 + 2Z_8 + Z_9) - (Z_1 + 2Z_2 + Z_3) \quad (5.64)$$

$$G_y = (Z_3 + 2Z_6 + Z_9) - (Z_1 + 2Z_4 + Z_7) \quad (5.65)$$

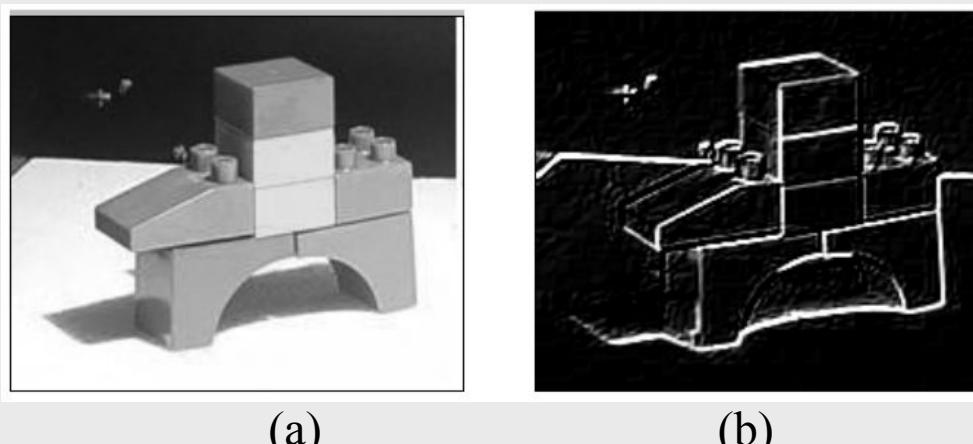


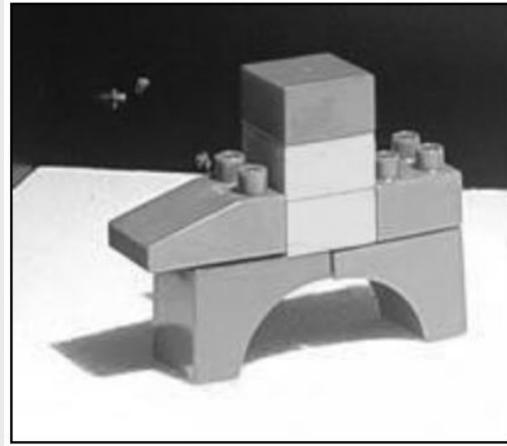
Figura 5.48 – Imagem original (a) e o resultado da aplicação do filtro de Sobel (b).

# Filtro de Roberts

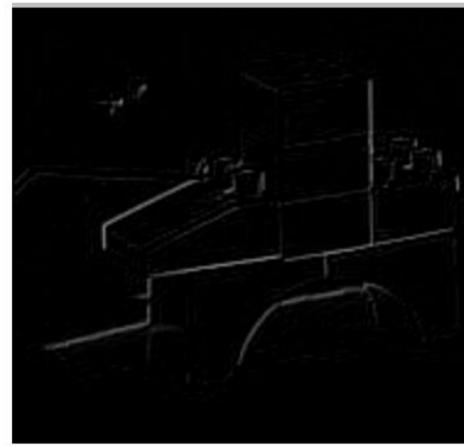
O filtro de Roberts pode ser representado pelas seguintes máscaras de convolução:

$$G_x = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \quad (5.69)$$

$$G_y = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \quad (5.70)$$



(a)



(b)

Figura 5.49 – Imagem Blocos original (a) e o resultado da aplicação do filtro de Roberts (b).

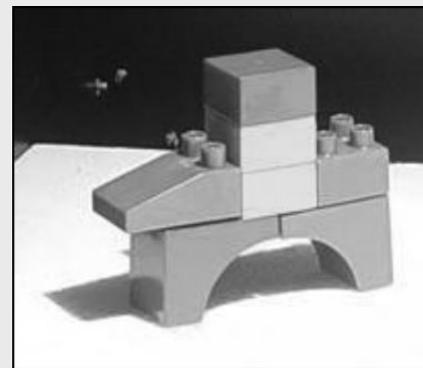
# O filtro de Prewitt

O filtro de Prewitt tem o mesmo conceito do de Sobel (sem o peso para o *pixel* mais central) e de Roberts (sua máscara abrange uma área de 3 x 3):

$$\nabla f = \left| (Z_7 + Z_8 + Z_9) - (Z_1 + Z_2 + Z_3) \right| \dots + \left| (Z_3 + Z_6 + Z_9) - (Z_1 + Z_4 + Z_7) \right| \quad (5.71)$$

$$G_x = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} \quad (5.72)$$

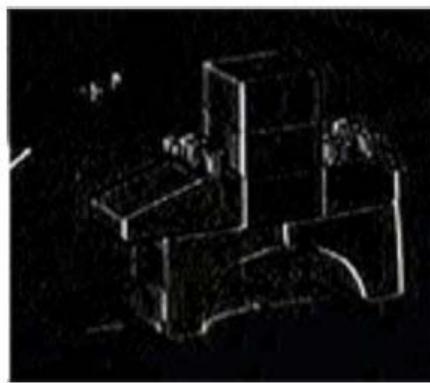
$$G_y = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} \quad (5.73)$$



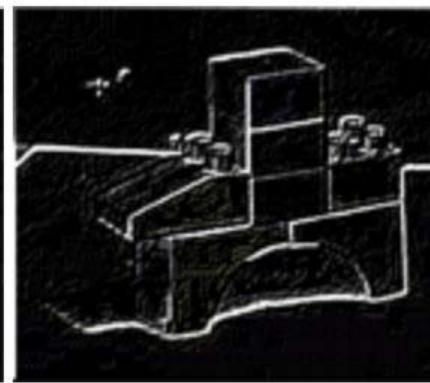
(a)



(b)



(c)



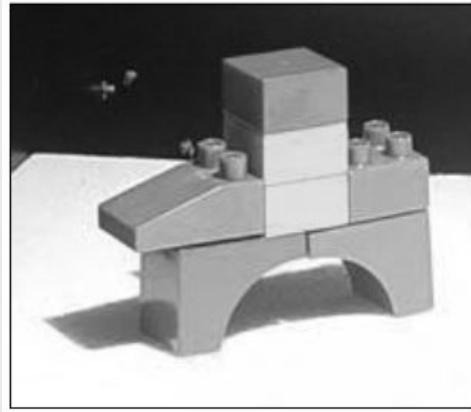
(d)

Figura 5.50 - Aplicação do operador gradiente na imagem Blocos original (a), com detecção de contorno no sentido horizontal (b), no sentido vertical (c) e o resultado da soma dos sentidos vertical e horizontal (d) .

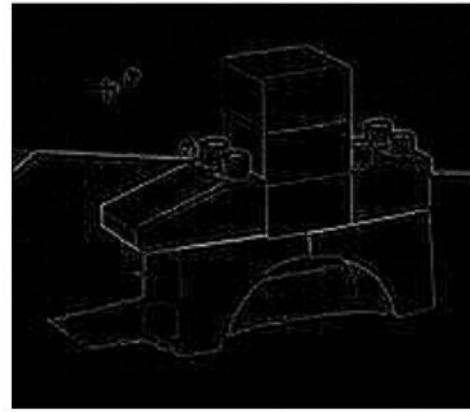
# Filtro Laplaciano

O Laplaciano de uma função bidimensional é a derivada de segunda ordem definida como:

$$\nabla^2 f(x, y) = \frac{\partial^2}{\partial x^2} f(x, y) + \frac{\partial^2}{\partial y^2} f(x, y) \quad (5.74)$$



(a)



(b)

Figura 5.51 – Imagem Blocos original (a) e o resultado da aplicação do filtro Laplaciano (b).

# Filtro LoG ou Laplaciano do Gaussiano

O filtro LoG (*Laplacian of Gaussian*) ou Filtro Laplaciano do Gaussiano é representado por:

$$LoG(x, y) = -\frac{1}{\pi \sigma^4} \left[ 1 - \frac{x^2 + y^2}{2\sigma^2} \right] e^{-\frac{x^2 + y^2}{2\sigma^2}} \quad (5.78)$$

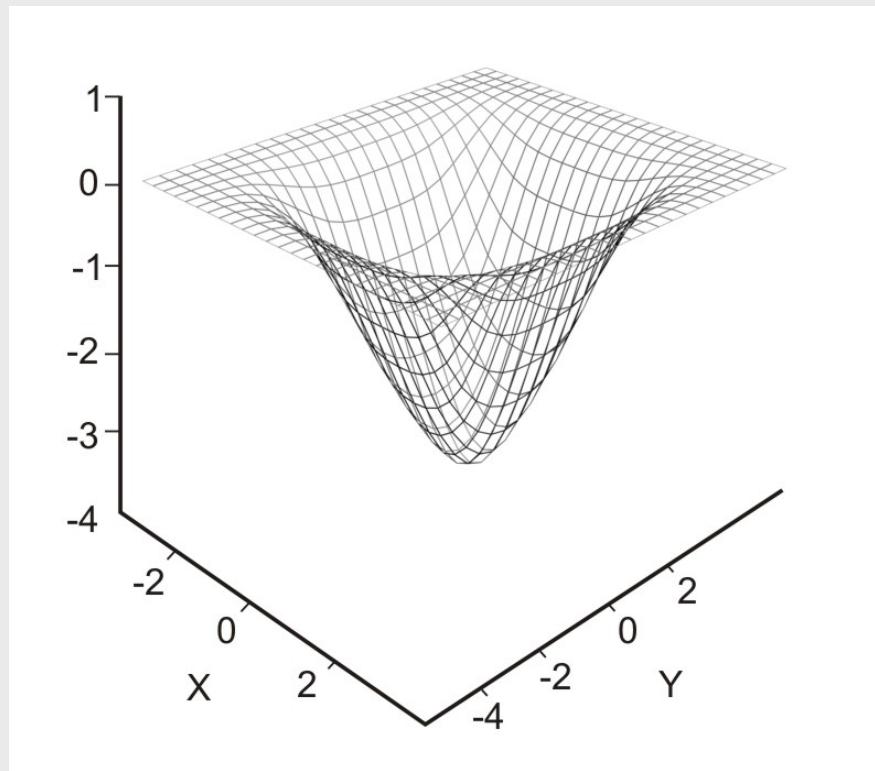


Figura 5.26 - Forma em 2-D do filtro Laplaciano do Gaussiano (LoG).

Para uma Gaussiana com  $\sigma = 1.4$  esta função pode ser aproximada na forma digital.

$$Z = \begin{bmatrix} 0 & 1 & 1 & 2 & 2 & 2 & 1 & 1 & 0 \\ 1 & 2 & 4 & 5 & 5 & 5 & 4 & 2 & 1 \\ 1 & 4 & 5 & 3 & 0 & 3 & 5 & 4 & 1 \\ 2 & 5 & 3 & -12 & -24 & -12 & 3 & 5 & 2 \\ 2 & 5 & 0 & -24 & -40 & -24 & 0 & 5 & 2 \\ 2 & 5 & 3 & -12 & -24 & -12 & 3 & 5 & 2 \\ 1 & 4 & 5 & 3 & 0 & 3 & 5 & 4 & 1 \\ 1 & 2 & 4 & 5 & 5 & 5 & 4 & 2 & 1 \\ 0 & 1 & 1 & 2 & 2 & 2 & 1 & 1 & 0 \end{bmatrix} \quad (5.79)$$

# Canny

Filtro de convolução de primeira derivada, que suaviza o ruído e localiza bordas, combinando um operador diferencial com um filtro Gaussiano.

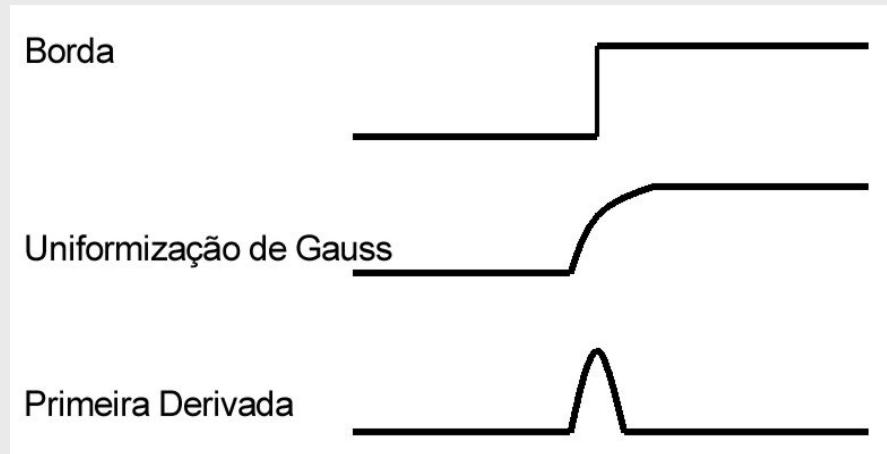


Figura 5.54 - Processo de detecção de bordas por Canny

Convoluindo a imagem com  $G'(x)$  obtem-se uma imagem  $I$  que mostrará as bordas, mesmo na presença de ruído.

$$G'(x) = \frac{-x}{\sqrt{2\pi\sigma^3}} e^{\frac{-x^2}{2\sigma^2}} \quad (5.82)$$

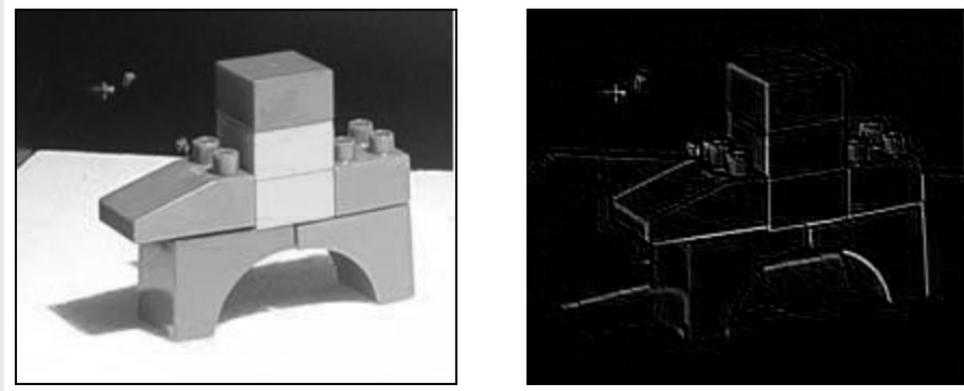


Figura 5.55 – Resultado da aplicação do filtro Canny (b) a imagem original (a).

# Outros Filtros de Ampliação de Contraste

Tabela 5.3 - Exemplo de filtros direcionais.

<b>Norte</b>	$\begin{bmatrix} 1 & 1 & 1 \\ 1 & -2 & 1 \\ -1 & -2 & -1 \end{bmatrix}$	<b>Nordeste</b>	$\begin{bmatrix} 1 & 1 & 1 \\ -1 & -2 & 1 \\ -1 & -1 & -1 \end{bmatrix}$
<b>Oeste</b>	$\begin{bmatrix} 1 & 1 & -1 \\ 1 & -2 & -1 \\ 1 & 1 & -1 \end{bmatrix}$	<b>Noroeste</b>	$\begin{bmatrix} 1 & 1 & 1 \\ 1 & -2 & -1 \\ 1 & -1 & -1 \end{bmatrix}$
<b>Sudeste</b>	$\begin{bmatrix} 1 & -1 & -1 \\ 1 & -2 & -1 \\ 1 & 1 & 1 \end{bmatrix}$	<b>Sudeste</b>	$\begin{bmatrix} 1 & -1 & -1 \\ 1 & -2 & -1 \\ 1 & 1 & 1 \end{bmatrix}$
<b>Sul</b>	$\begin{bmatrix} -1 & -1 & -1 \\ 1 & -2 & 1 \\ 1 & 1 & 1 \end{bmatrix}$	<b>Leste</b>	$\begin{bmatrix} -1 & 1 & 1 \\ -1 & -2 & 1 \\ -1 & 1 & 1 \end{bmatrix}$

# Comparando os Diversos Filtros de Realce

Tabela 5.4 – Resumo das máscaras para realce.

Operador	Vertical	Horizontal
<b>Roberts</b>	$\begin{bmatrix} 0 & 0 & -1 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$	$\begin{bmatrix} -1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$
<b>Sobel</b>	$\begin{bmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{bmatrix}$	$\begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$
<b>Prewit</b>	$\begin{bmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{bmatrix}$	$\begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix}$
<b>Laplaciano</b>		$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix}$

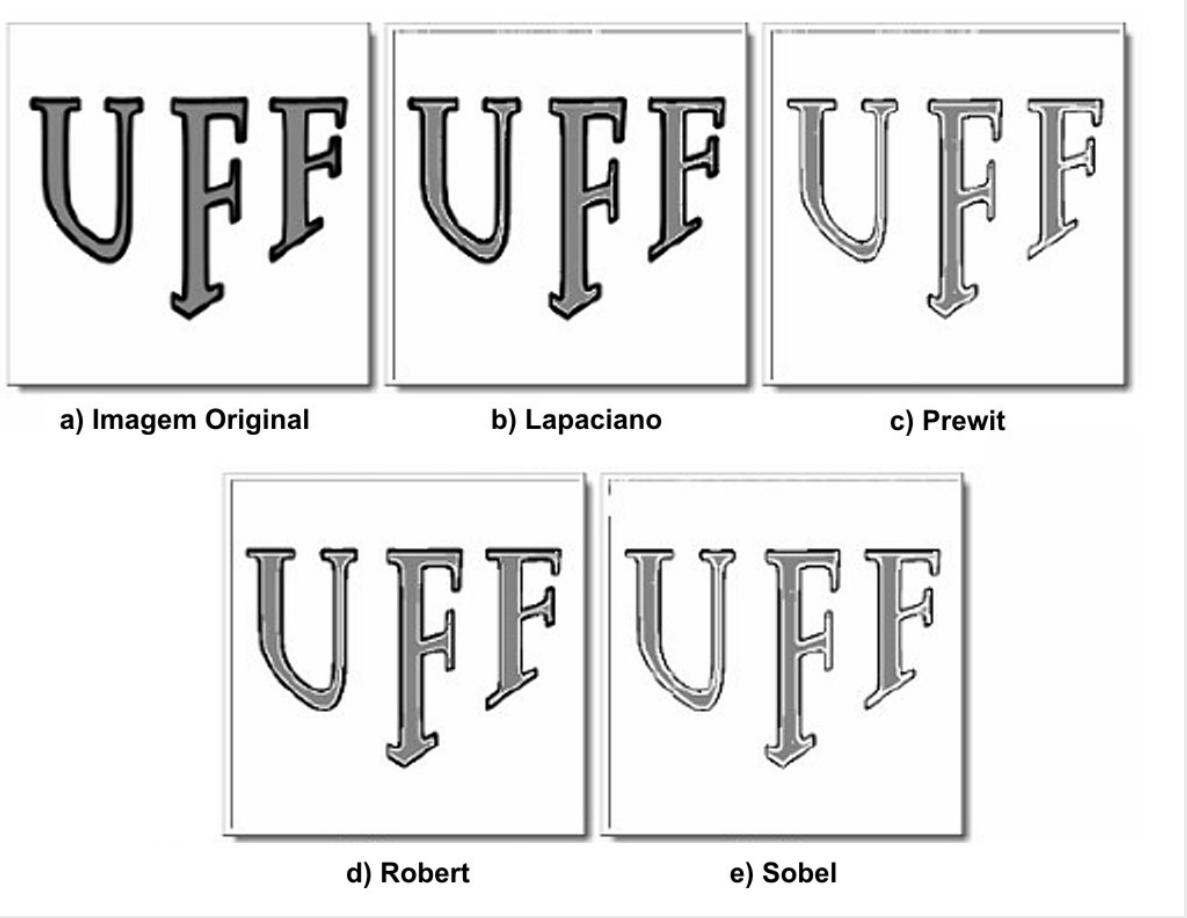


Figura 5.57 – Exemplo de aplicação de diferentes operadores de detecção de borda.

# Filtros passa-banda ou elimina faixa

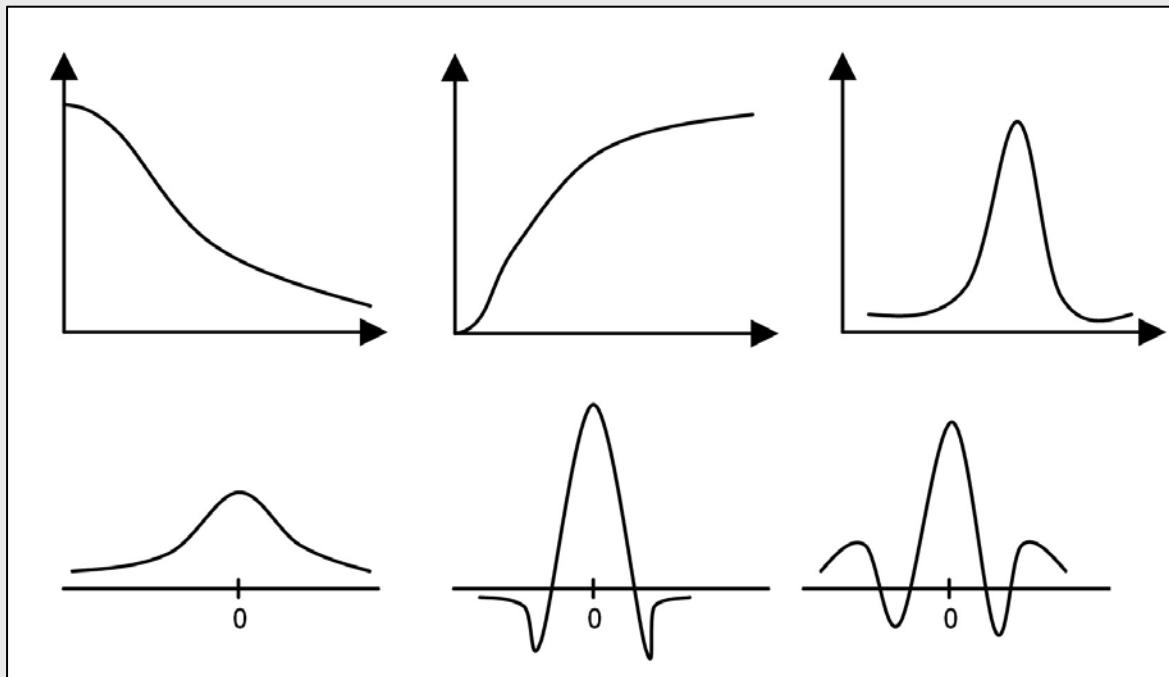


Figura 5.58. Filtros passa-baixa, passa-alta e passa-faixa em freqüência (acima) e no espaço (abaixo).

# Filtro alto reforço

No filtro “alto reforço” ou técnica de ênfase em alta freqüência tem-se:

$$\text{Alto-Reforço} = (A) \text{ Original} - \text{Passa-baixa}$$

$$\text{Alto-Reforço} = (A - 1) \text{ Original} + (\text{Original} - \text{Passa-Baixa})$$

$$\text{Alto-Reforço} = (A-1) \text{ original} + \text{Passa-Alta}$$

Onde A é um fator de amplificação  $A$ .

# **Extração de Características e Reconhecimento de Padrões e Objetos**

**6.1. Segmentação**

**6.2. Tipos de características**

**6.3. Descritores de forma**

**6.4. Reconhecimento de Padrões em Imagens**

**6.5. Conclusão**

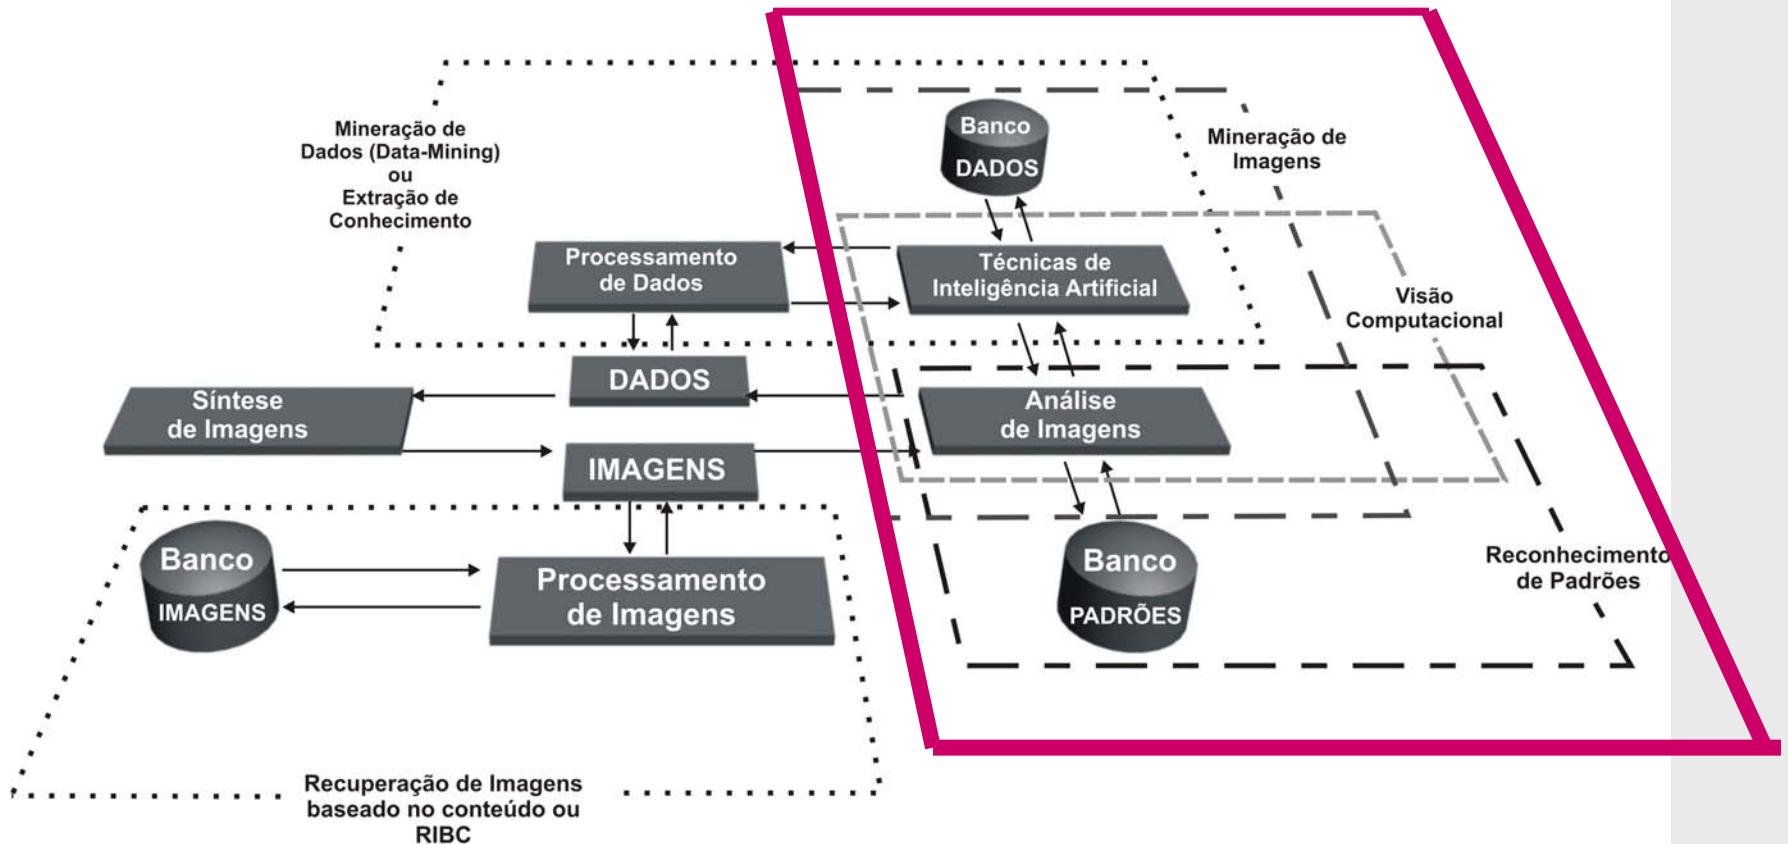


Figura 1.2. Interação entre as diversas áreas, como a mineração em banco de dados, a Visão de Computacional e a Inteligência Artificial.

**Padrão**, em reconhecimento de imagens, se refere a qualquer elemento que possa ser definido **quantitativamente** mesmo que sujeito a variações.

O reconhecimento pode ser feito por **diferenciação** ou por **classificação** (ou mesmo ambos).

As **classes padrão** que se deseja reconhecer são formadas a partir de **características** que serão extraídas da imagem.

Utilizam-se **descritores** para caracterizar o objeto/padrão. Cada tipo de descritor será mais adequado a **determinado aspecto** como: forma, dimensões, cor, textura, etc.



Figura 6.1 – Estapas de um sistema de reconhecimento de padrões.

# Segmentação

O processo de segmentação consiste em dividir uma imagem em regiões que possuem o mesmo conteúdo no contexto de uma aplicação.

A segmentação pode ser baseada em:

- descontinuidades;
- similaridades dos diferentes aspectos da imagem.

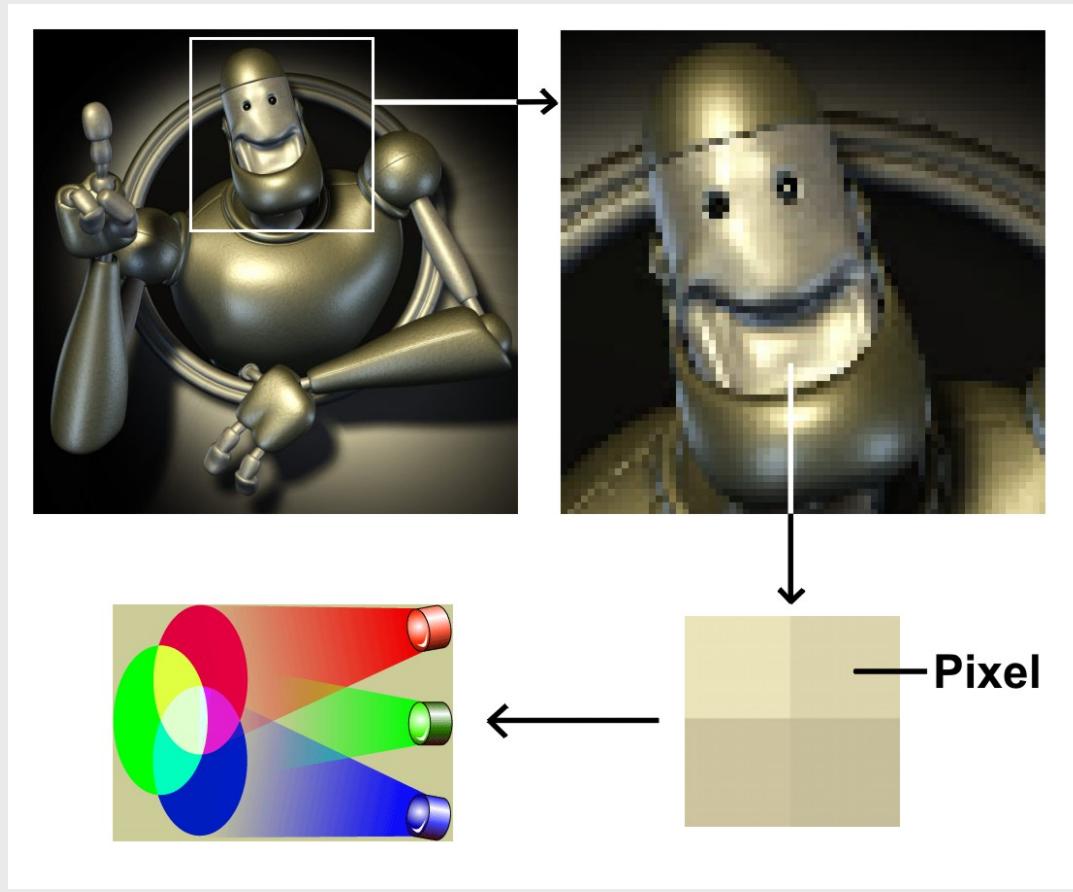
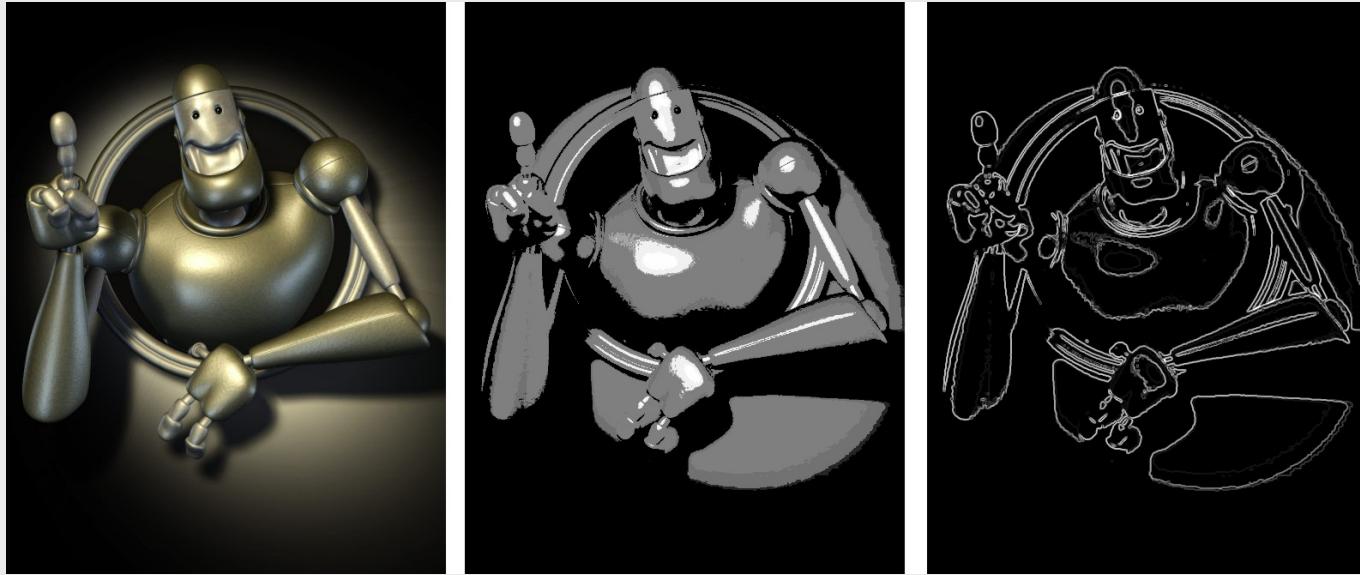


Figura 6.2 – Em imagem coloridas têm-se 3 cores associada a cada *pixel* da imagem.



(a)

(b)

(c)

Figura 6.3 - Imagem original (a) e sua segmentação baseada em semelhança de cores (b) e em fronteiras ou bordas (c).

# **Segmentação**

**6.1.1. Segmentação Baseada em Regiões**

**6.1.2 - Outras Técnicas de Segmetação**

**6.1.3. Propriedades do *Pixel***

**6.1.4 Rotulação**

# Segmentação Baseada em Regiões

## Premissas:

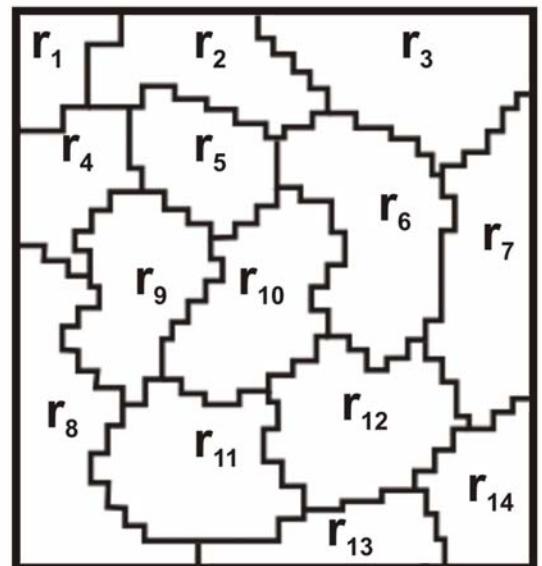
- (1) a região deve ser homogênea considerando algum fator de tolerância e algumas características predefinidas;
- (2) só se consideram regiões fechadas aquelas delimitadas por fronteiras contínuas que separam seu interior dos outros segmentos;
- (3) as características devem ser adequadas para indicar univocamente a região; e
- (4) o conjunto de todas as regiões deve formar a imagem.

# Técnicas de segmentação baseadas em crescimento de regiões

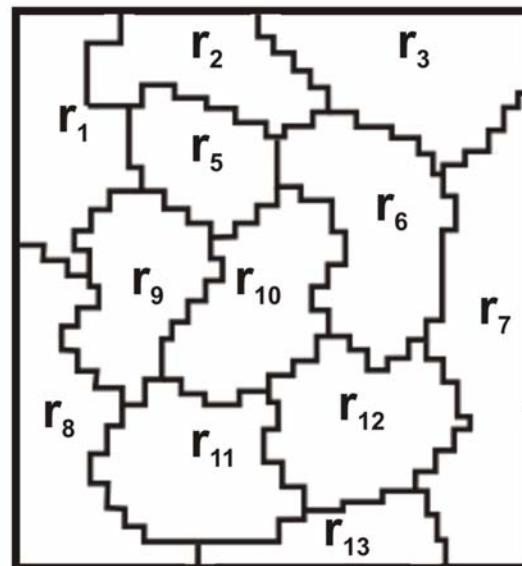
- O processo de segmentação se inicia a partir de um *pixel* ou um conjunto de *pixels* (denominado de “*semente*”).
- Para cada semente avalia-se o predicado dos *pixels* vizinhos (ou região).
- A agregação das regiões é feita quando o critério de similaridade ou de decisão do predicado for verdadeiro.

# Técnicas de segmentação baseadas em divisão e fusão de regiões

- Subdivide uma imagem em quatro blocos e verifica se os *pixels* atendem a algum critério de homogeneidade.
- Os blocos que atenderem ao critério não serão mais divididos.
- O bloco que não atender será subdividido em blocos menores.
- Realiza a junção dos blocos vizinhos homogêneos.



(a)



(b)



(c)



(d)

Figura 6.4 - Processo de divisão e fusão de regiões baseado em *quadtrees*.

# Técnicas de segmentação baseadas em “clusterização”



Figura 6.5 - Esquema funcional de um algoritmo de “clusterização” (Nunes, 2006).

# Algoritmo K-Means

- Algoritmo de classificação não-supervisionada.
- O critério a ser minimizado é definido em função da distância dos elementos em relação aos centros dos agrupamentos.
- Usualmente, este critério é a soma residual dos quadrados das distâncias, geralmente a distância Euclidiana.
- Quanto menor for este valor, mais homogêneos serão os objetos dentro de cada grupo e melhor será a partição.

# Algoritmo K-Means

Abaixo é apresentado um algoritmo básico:

- (1) Determinar as posições iniciais dos  $k$  centróides dos *clusters*.
- (2) Alocar cada elemento ao cluster do centróide mais próximo.
- (3) Recalcular os centros dos *clusters* a partir dos elementos alocados.
- (4) Repetir os passos de 2 a 4 segundo algum critério de convergência.

# Segmentação baseada em janelas (*windows*)

- Comum em análises de imagens multiresolução ou texturas.
- O método pode ser generalizado para qualquer número de predicados e técnica de decisão mais complexas quanto aos limiares das regiões.

# Outras Técnicas de Segmentation

Outras técnicas:

- (1) filtragem no domínio espacial;
- (2) filtragem no domínio da freqüência;
- (3) transformação para um espaço de medida específico;
- (4) baseadas em Morfologia Matemática; e,
- (5) contornos ativos.

# **Propriedades do Pixel**

**6.1.3.1. Vizinhança em Pixel (Vizinhança-4 e Vizinhança-8)**

**6.1.3.2. Medidas de Distância**

**6.1.3.3. Conectividade (Propriedade de um pixel está conectado a outro)**

# Vizinhança em *Pixel* (Vizinhança-4 e Vizinhança-8)

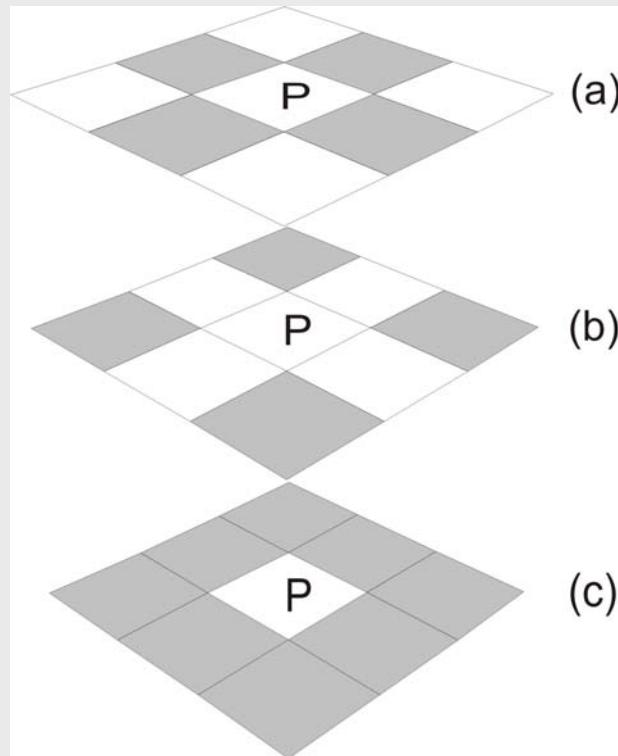


Figura 6.6 – Conceitos de (a) *vizinhança-4* de  $p$ ,  
(b) *vizinhança-D* de  $p$ , (c) *vizinhança-8* de  $p$ .

Para criar uma vizinhança onde todos os vizinhos fossem eqüidistantes seria necessário mudar a grade regular quadrada para uma grade hexagonal.

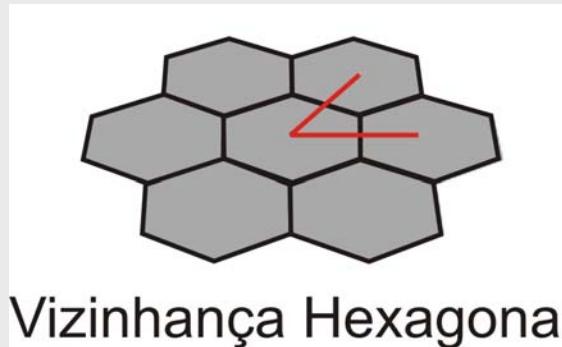


Figura 6.7 – Vizinhança de um pixel numa grade hexagonal.

# Medidas de Distância

Distância *city-block*, *Manhattan* ou quarteirão para e distância Euclidiana para  $r = 2$  :

$$D(X_i, X_j) = \left[ \sum_{l=1}^n |x_{il} - x_{jl}|^r \right]^{\frac{1}{r}} \quad (6.2)$$

A distância Euclidiana,  $D$  para  $r=n=2$ , entre  $p$  e  $q$ :

$$D_e(p, q) = \sqrt{(x - s)^2 + (y - t)^2} = D_2(p, q) \quad (6.3)$$

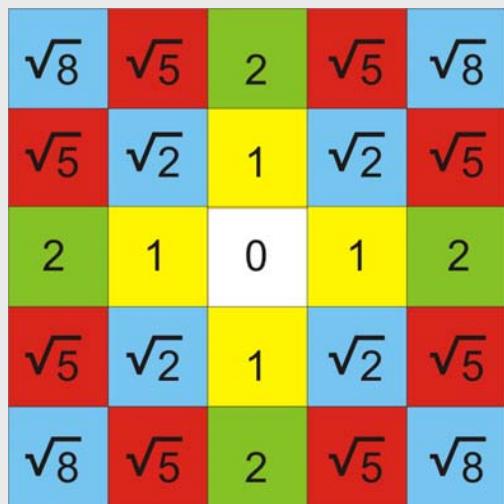


Figura 6.8 – Distância Euclidiana  $\leq \sqrt{8}$  do *pixel* central (Nunes, 2006).

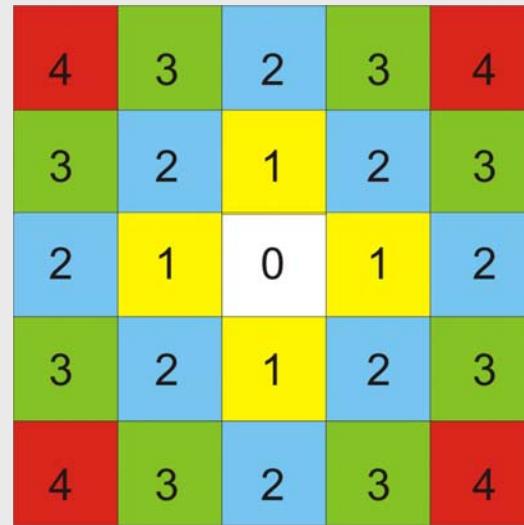


Figura 6.9 – Distância D1 (Nunes, 2006).

# Coneectividade (Propriedade de um pixel está conectado a outro)

Dois *pixels* estão conectados se:

- são adjacentes ( $N_4(p)$  ou  $N_8(p)$ ); e,
- seus atributos (níveis de cinza, texturas ou cores) são similares.

## Níveis de conectividade:

§ **Conectividade de 4:** dois *pixels*  $p$  e  $q$  tem conectividade 4 se seus atributos são iguais e se  $q$  está no conjunto  $N_4(p)$ .

**Conectividade de 8:** dois *pixels*  $p$  e  $q$  tem conectividade 8 se seus atributos são iguais e se  $q$  está no conjunto  $N_8(p)$ .

**Conectividade de m (mista):** dois *pixels*  $p$  e  $q$  têm conectividade mista se seus atributos são iguais e se:  $q$  está no conjunto  $N_4(p)$  ou  $q$  está no conjunto  $N_D(p)$  e o conjunto  $N_4(p) \cap N_4(q) =$

Distribuição dos Pixels	$N_8$				Vizinho de $m$				$N_4$			
0	1	1	0	1	0	1	1	0	0	1	1	1
0	1	0	0	1	0	1	0	0	0	1	0	0
0	0	1	0	0	1	0	1	0	0	0	1	1

Figura 6.11 – Exemplo da variação do caminho com o tipo de adjacência.

# Rotulação

A rotulação é fundamental para a segmentação e contagem de regiões e objetos.

A cada região ou componente conexo é atribuído um valor único na imagem, usualmente denominado de rótulo (*label*).

# **Tipos de características**

## **6.2.1 - Análise de Componentes Principais (PCA)**

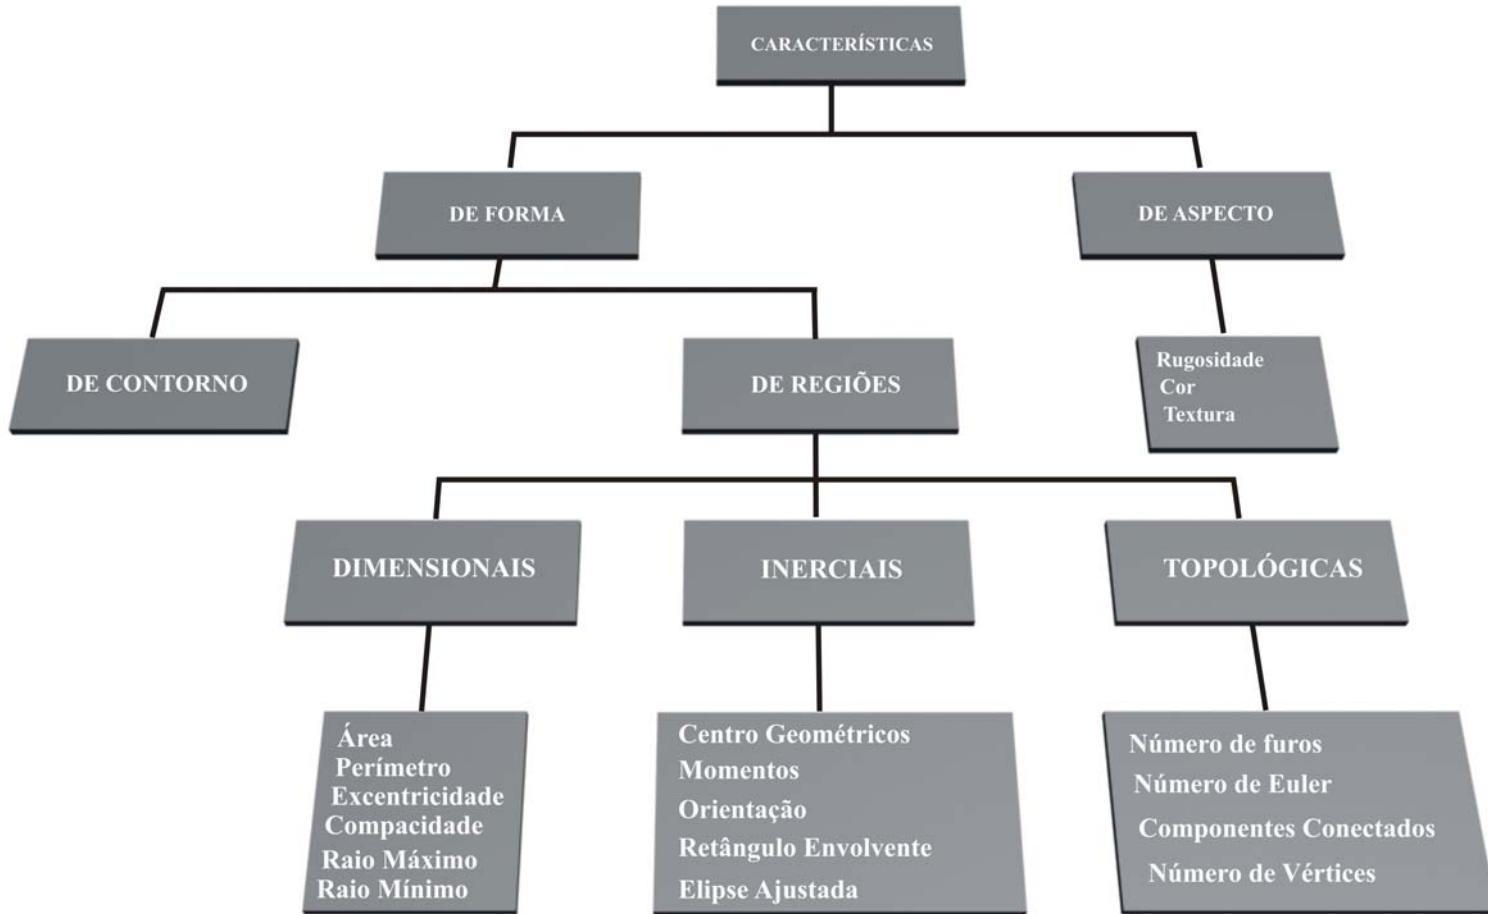


Figura 6.12 - Tipos de características.

# Análise de Componentes Principais (PCA)

- Também chamada de **Transformada Discreta de Karhunen-Loève** (KLT) ou ainda **Transformada Hotelling**.
- A **componente principal** é o arranjo que melhor representa a distribuição dos dados sendo que a **componente secundária** é perpendicular à componente principal.
- É útil quando os vetores de características têm muitas dimensões ou quando uma representação gráfica não é possível.

# Matriz de covariância

A matriz de covariância para  $M$  amostras de vetores em um conjunto qualquer, com vetor médio  $m_x$  pode ser calculada de acordo com:

$$C_x = \frac{1}{M} \sum_{i=1}^M x_i x_i^T - m_x m_x^T \quad (6.6)$$

O vetor médio pode ser calculado:

$$m_x = \frac{1}{M} \sum_{i=1}^M x_i \quad (6.7)$$

# Autoespaços , autovetores e autovalores

Um vetor  $v$  é um **autovetor** de uma matriz quadrada  $M$  se  $M v$  (multiplicação da matriz  $M$  pelo vetor  $v$ ) resulta num múltiplo de  $v$ , ou seja, em  $\lambda v$  ( ou na multiplicação de um escalar pelo vetor).

Nesse caso,  $\lambda$  é o chamado **autovalor** de  $M$  associado ao autovetor  $v$ .

- Se uma matriz  $n \times n$  tem  $n$  autovalores linearmente independentes então ela é **diagonalizável**.

Se uma matriz é diagonalizável então ela tem  $n$  autovalores linearmente independentes que serão os seus elementos da diagonal principal.

Para diagonalizar uma matriz  $M$ :

- 1- Encontrar seus autovetores linearmente independente:  $v_1, v_2, \dots, v_n$ .
- 2- Formar uma Matriz  $P$  com estes vetores como colunas.
- 3- O produto  $P^{-1} M P$  será uma matriz diagonal, com elementos iguais aos autovalores na diagonal principal.

# Transformada de Hotelling

Transformada de Hotelling:

$$y = A(x - m_x) \quad (6.26)$$

Estabelece um novo sistema de coordenadas cuja origem será o centróide do conjunto de pontos e cujos eixos estarão na direção dos autovetores de  $C_x$ .

# Análise de Componentes Principais para Imagens Coloridas

(1) Gera-se a matriz  $\Sigma$ :

$$\Sigma = cov ([R \ G \ B]) \quad (6.29)$$

(2) Com a matriz de covariância  $\Sigma$ , pode-se, então, calcular seus autovalores e autovetores:

$$[T, \ aut] = eig (\Sigma) \quad (6.30)$$

(3) Gera-se um novo espaço chamado de [P1, P2, P3].

$$\begin{bmatrix} P_1(i) \\ P_2(i) \\ P_3(i) \end{bmatrix} = \begin{bmatrix} t_{1,1} & t_{1,2} & t_{1,3} \\ t_{2,1} & t_{2,2} & t_{2,3} \\ t_{3,1} & t_{3,2} & t_{3,3} \end{bmatrix} \begin{bmatrix} R(i) \\ G(i) \\ B(i) \end{bmatrix} \quad (6.31)$$

# PCA em Reconhecimento de Padrões

Pode-se dizer que uma imagem é um padrão de  $h \times w$  características ou um vetor no espaço  $(hxw)$  dimensional, o qual é chamado de “espaço de imagens”, representado por  $I$ .

Dada uma imagem, pode-se construir sua representação como um vetor através de uma leitura coluna a coluna da imagem, colocando o valor de cada *pixel* da imagem em um vetor coluna  $x$ .

# Transformada de Hotelling e PCA na reconstrução

Outra aplicação importante se relaciona à reconstrução de  $x$ , dado  $y$ , por:

$$y = A(x - m_x) \quad (6.32)$$

A PCA é um método estatístico linear que encontra os autovalores e autovetores da matriz de covariância dos dados, e, com esse resultado pode-se realizar a redução dimensional dos dados e analisar os padrões principais de variabilidade presentes.

# **Descritores de forma**

**6.3.1 - Características Dimensionais**

**6.3.2 - Características Inerciais**

**6.3.3. Características de Contorno**

**6.3.4. Características Topológicas**

**6.3.5. Características de Aspecto**

**6.3.6. Outras características**

# Características Dimensionais

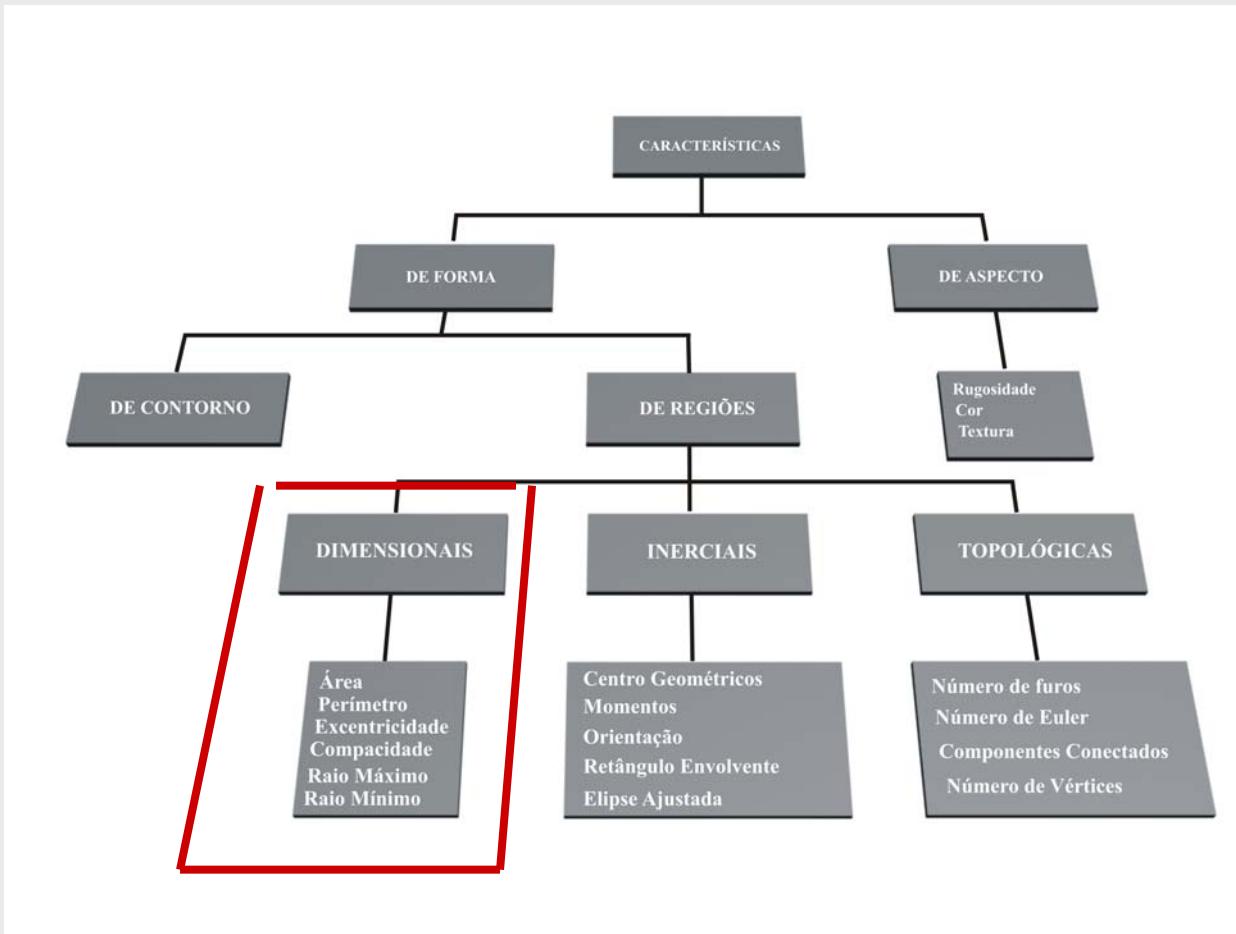


Figura 6.12 - Tipos de características.

# Área e Retângulos envolventes

Exemplos: área, área do menor retângulo que envolve o objeto, área no menor retângulo que envolve o objeto na mesma direção do sistema de eixos da imagem, área da menor corpo convexo que envolva o objeto, e, a deficiência convexa.

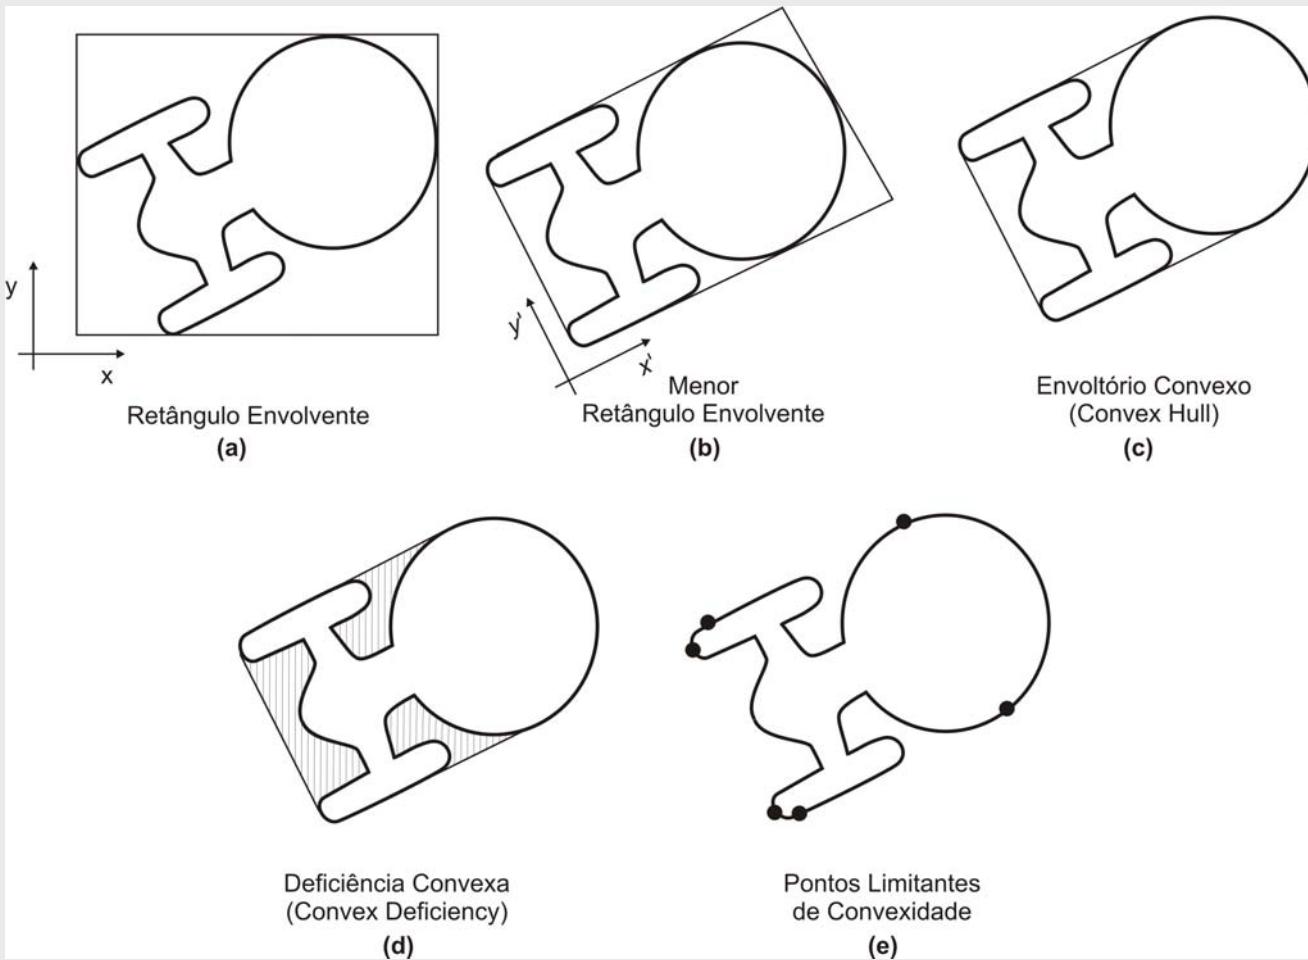


Figura 6.13 - Menor retângulo envolvente (BB), menor retângulo que envolve o objeto na mesma direção do sistema de eixos da imagem (AABB), menor corpo convexo envolvente, e a deficiência convexa.

# Perímetro, Alongamento e Retangularidade

**Perímetro** - número de *pixels* conexos que constituem o contorno da região.

**Alongamento** - relação de lados do menor retângulo que envolve o objeto.

**Retangularidade** - relação entre a área do objeto e área do menor retângulo que o envolve.

# Excentricidade, diâmetro, raio máximo e mínimo do objeto

**Diâmetro de um objeto** - maior distância entre 2 pontos deste objeto.

**Excentricidade** - relação entre dois pontos extremos do objeto que passem pelo **eixo maior** e **eixo ortogonal**.

**Raio máximo e mínimo do objeto** - distâncias máxima e mínima, respectivamente, da borda ao centro geométrico.

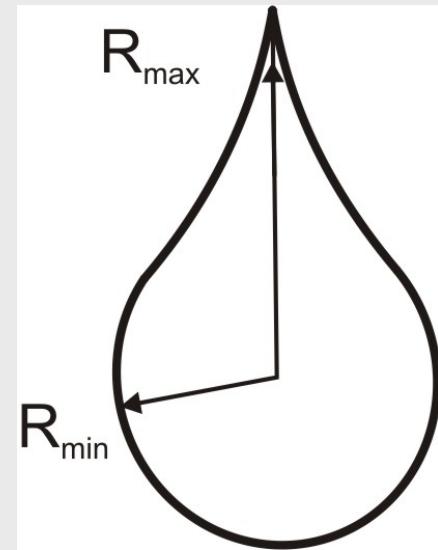


Figura 6.14 - Raios máximo e mínimo de uma imagem representada pelo seu contorno.

# Coeficiente de compacidade e fator de forma

$$\gamma = \frac{P^2}{4\pi A} \quad (6.34)$$

# *Bit quads*

$$A = \frac{1}{4}nQ_1 + \frac{1}{2}nQ_2 + \frac{7}{8}nQ_3 + nQ_4 + \frac{3}{4}nQ_D \quad (6.35)$$

$$P = nQ_2 + \frac{1}{\sqrt{2}}[nQ_1 + nQ_3 + 2nQ_D] \quad (6.36)$$

$$\varepsilon = \frac{1}{4}[nQ_1 - nQ_3 + 2nQ_D] \quad (6.37)$$

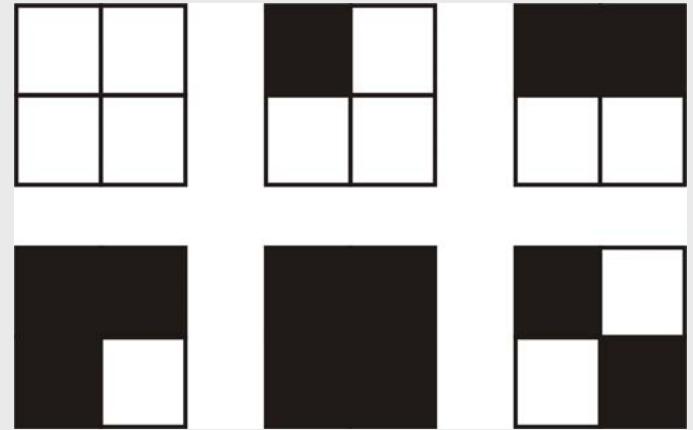


Figura 6.15 - Forma visual dos *Bitquads*.

# Características Inerciais

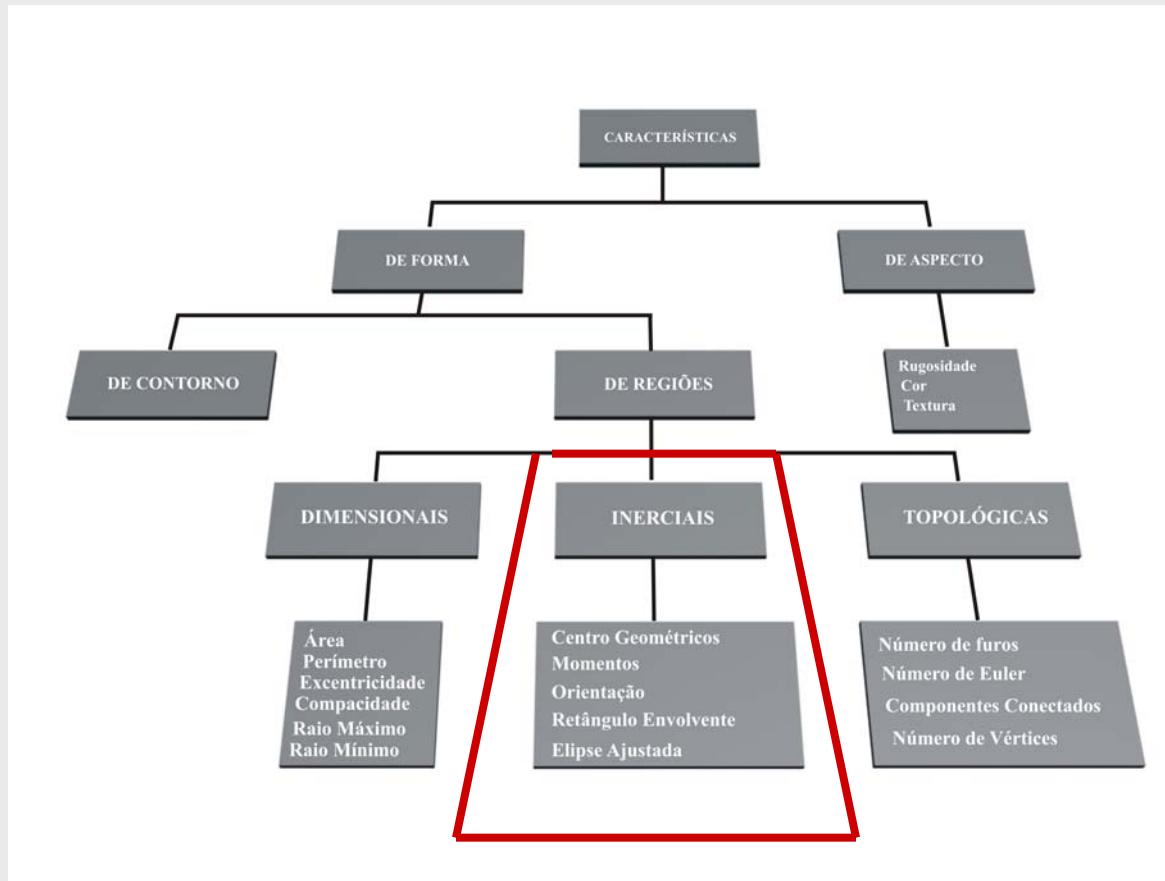


Figura 6.12 - Tipos de características.

# Momentos Geométricos

Momentos invariantes de ordem  $(p + q)$  de objetos contínuos em uma imagem binarizada:

$$m_{pq} = \sum_{k=1}^n B(i_k, j_k) (i_k)^p (j_k)^q \quad p, q = 0, 1, 2, \dots \quad (6.39)$$

Área:

$$m_{00} = \sum_m \sum_n B(m, n) \quad (6.41)$$

Centróide:

$$\begin{aligned} i_0 &= \sum_{k=1}^n B(i_k, j_k) i_k / \sum_{k=1}^n B(i_k, j_k) = m_{10} / m_{00} \\ j_0 &= \sum_{k=1}^n B(i_k, j_k) j_k / \sum_{k=1}^n B(i_k, j_k) = m_{01} / m_{00} \end{aligned} \quad (6.42)$$

## Momentos centrais :

$$\mu_{pq} = \sum_{k=1}^n B(i_k, j_k) (i_k - i_0)^p (j_k - j_0)^q B(i_k, j_k) \quad (6.43)$$

$$\mu_{0,0} = m_{0,0} \quad (\text{área})$$

$$\mu_{0,1} = \mu_{1,0} = 0 \quad (\text{momentos estáticos})$$

$$\mu_{0,2} = m_{0,2} - i_o m_{0,1} \quad (\text{momentos de inércia})$$

$$\mu_{2,0} = m_{2,0} - i_o m_{1,0} \quad (\text{momentos de inércia})$$

$$\mu_{1,1} = m_{1,1} - j_o m_{1,0} \quad (\text{produto de inércia})$$

## Momentos geométricos invariantes de Hu (1962):

$$\phi_1 = \eta_{2,0} + \eta_{0,2} \quad (6.45)$$

$$\phi_2 = (\eta_{2,0} - \eta_{0,2})^2 + 4\eta_{1,1}^2 \quad (6.46)$$

$$\phi_3 = (\eta_{3,0} - 3\eta_{1,2})^2 + (3\eta_{2,1} - \eta_{0,3})^2 \quad (6.47)$$

$$\phi_4 = (\eta_{3,0} + \eta_{1,2})^2 + (\eta_{2,1} + \eta_{0,3})^2 \quad (6.48)$$

$$\begin{aligned} \phi_5 = & (\eta_{3,0} - 3\eta_{1,2})(\eta_{3,0} + \eta_{1,2}) / [(\eta_{3,0} + \eta_{1,2})^2 - 3(\eta_{2,1} + \eta_{0,3})^2] + \\ & (3\eta_{2,1} - \eta_{0,3})(\eta_{2,1} + \eta_{0,3}) [3(\eta_{3,0} + \eta_{1,2})^2 - (\eta_{2,1} + \eta_{0,3})^2] \end{aligned} \quad (6.49)$$

## Momentos geométricos invariantes de Hu (1962):

$$\phi_6 = (\eta_{2,0} - \eta_{0,2})[(\eta_{3,0} + \eta_{1,2})^2 - (\eta_{2,1} + \eta_{0,3})^2] + 4\eta_{1,1}(\eta_{3,0} + \eta_{1,2})(\eta_{2,1} + \eta_{0,3}) \quad (6.50)$$

$$\phi_7 = (3\eta_{2,1} - \eta_{0,3})(\eta_{3,0} + \eta_{1,2})[(\eta_{3,0} + \eta_{1,2})^2 - 3(\eta_{2,1} + \eta_{0,3})^2] - (\eta_{3,0} - 3\eta_{1,2})(\eta_{2,1} + \eta_{0,3})[3(\eta_{3,0} + \eta_{1,2})^2 - (\eta_{2,1} + \eta_{0,3})^2] \quad (6.51)$$

$\theta$  - orientação dos eixos principais:

$$\tan 2\theta = 2\mu_{1,1} / (\mu_{2,0} - \mu_{0,2}) \quad (6.52)$$

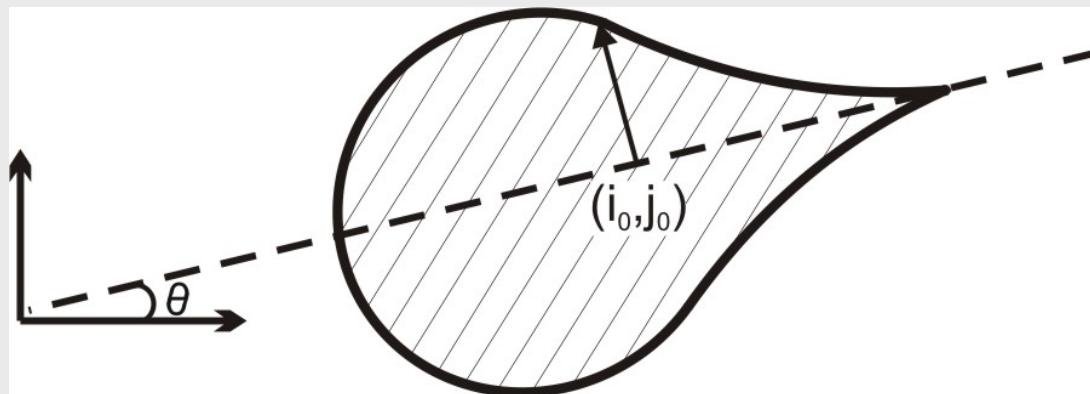


Figura 6.17 – Orientação.

# Retângulos e Elipses ajustados

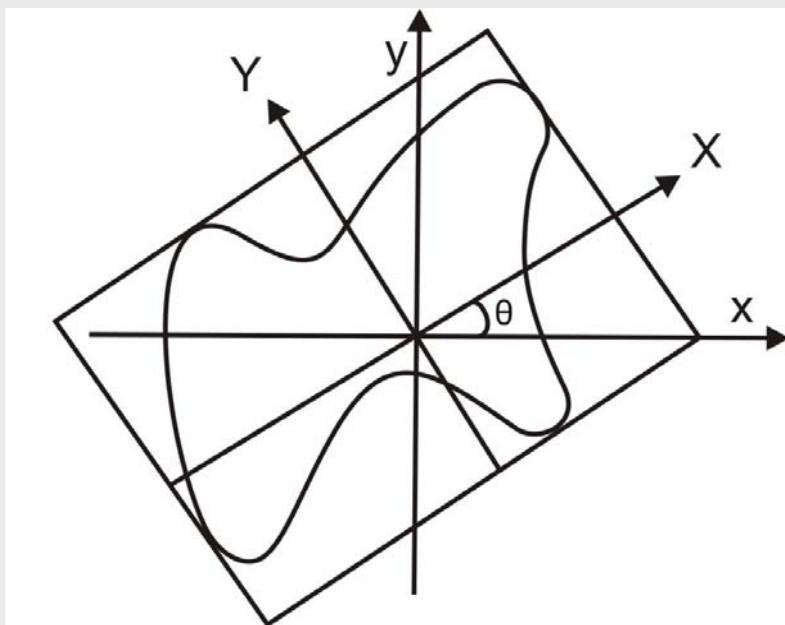


Figura 6.18 - Retângulo  
ajustado.

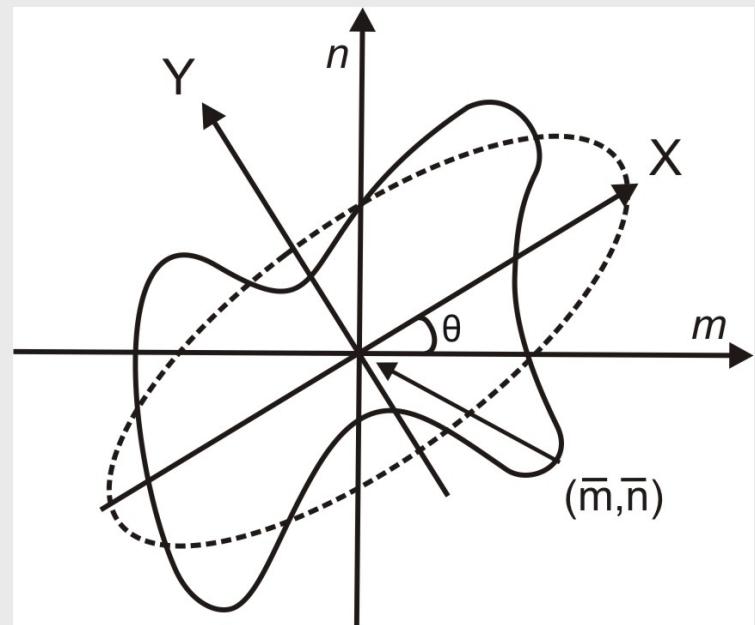


Figura 6.19 - Elipse ajustada.

# Características de Contorno

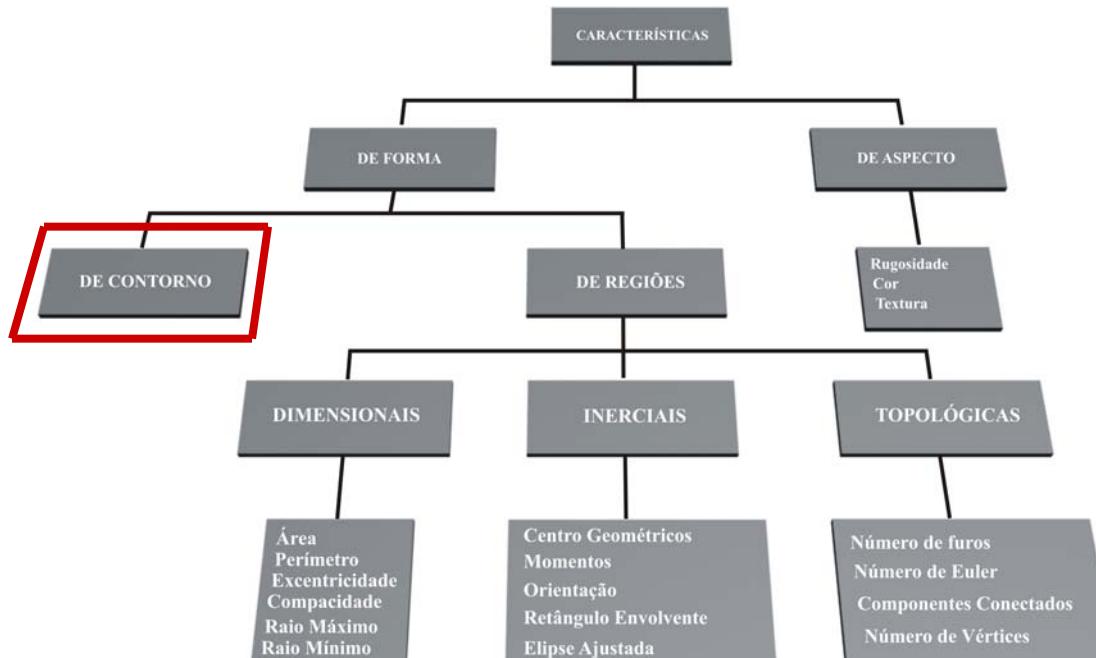


Figura 6.12 - Tipos de características.

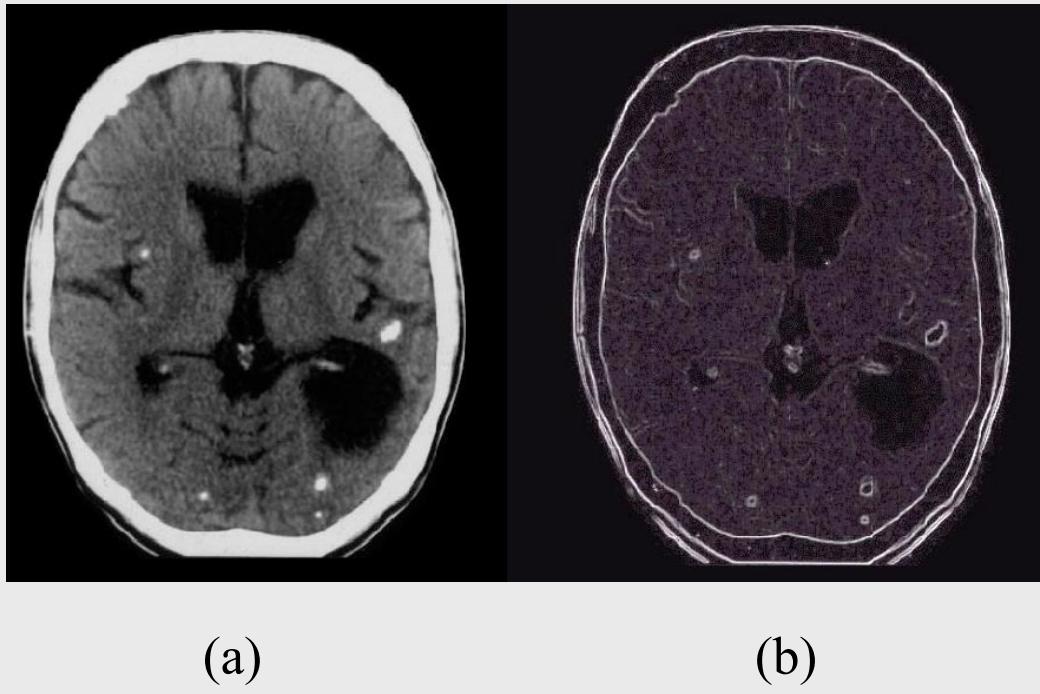


Figura 6.20. Exemplo de aplicação do filtro de gradiente (b) para acentuar o contorno em uma imagem de tomografia (a). Neste exemplo foram realizados procedimentos para ligação de bordas.

# Código da Cadeia

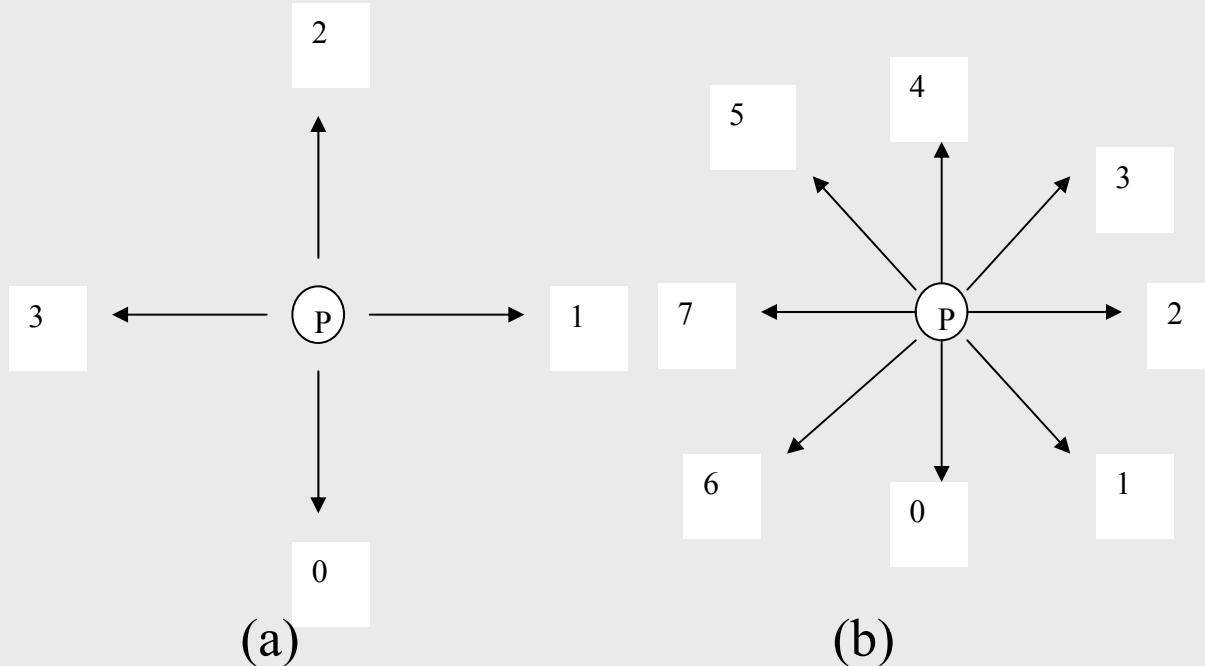


Figura 6.21. – Codificação vizinhança-4 de  $p$ ,  $N_4(p)$  (a) e vizinhança-8 de  $p$ ,  $N_8(p)$  o (b) para o código da cadeia.

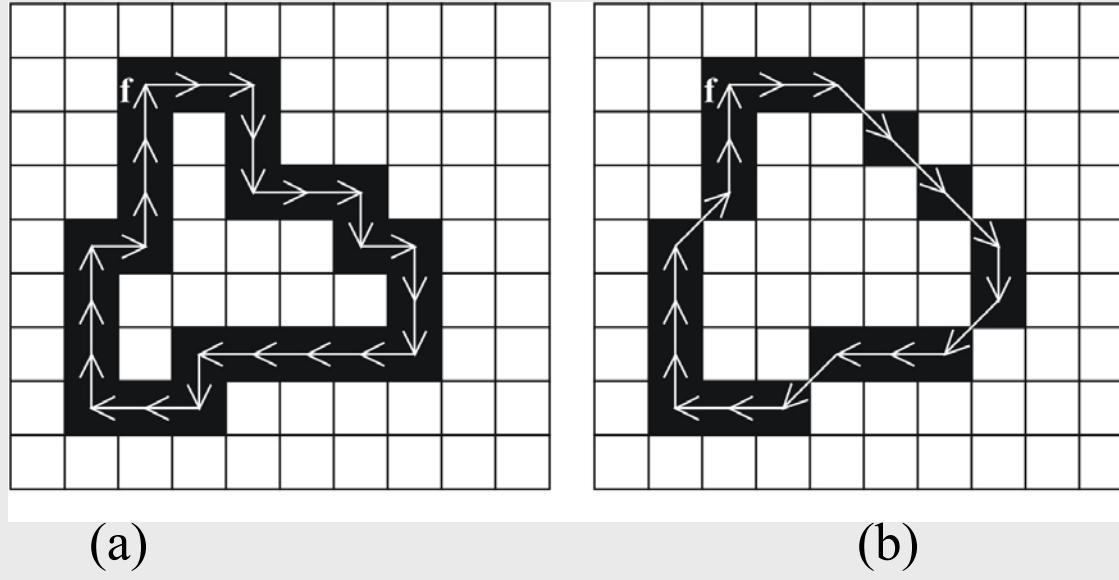
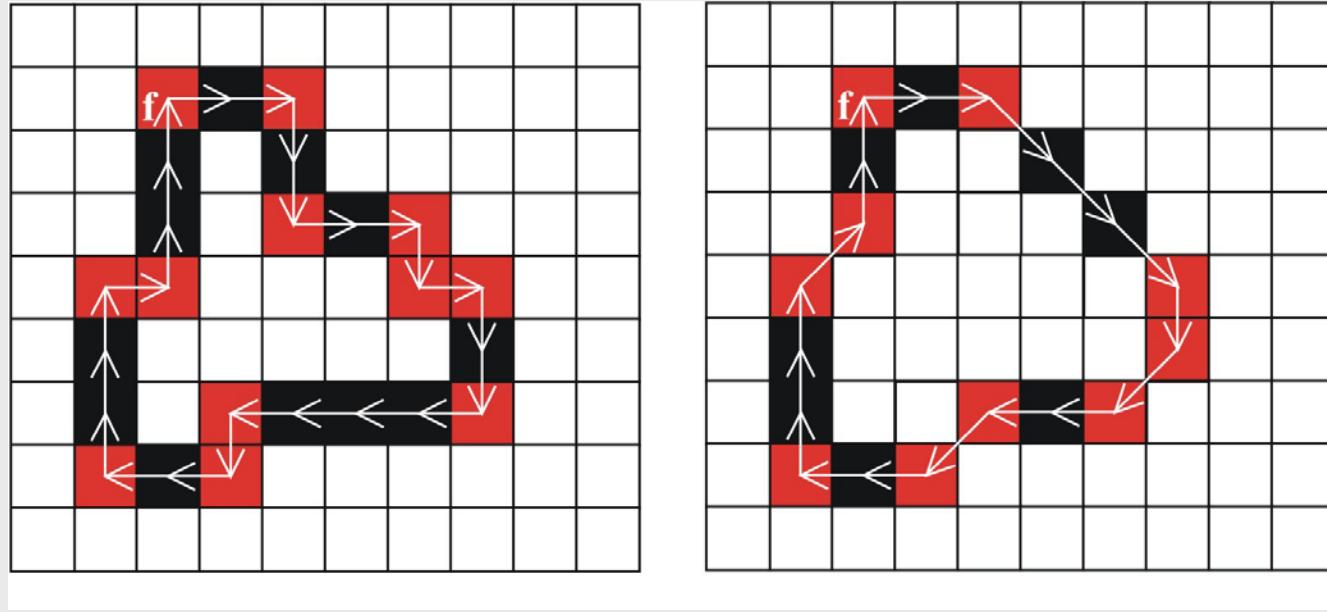


Figura 6.22 . Segmentaos para o código da Cadeia: (a) código para vizinhança-4; (b) código para vizinhança-8 de  $p$  .

$N_4(p)$  é CC = (1,1,0,0,1,1,0,1,0,0,3,3,3,3,0,3,3,2,2,2,1,2,2,2).

$N_8(p)$  é CC = (2,2,1,1,1,0,7,6,6,7,6,6,4,4,4,3,4,4).



(a)

(b)

Figura 6.23 – Pontos onde o código se diferencia do vizinho.

# Assinaturas ou Gráficos

## $r(\square)$

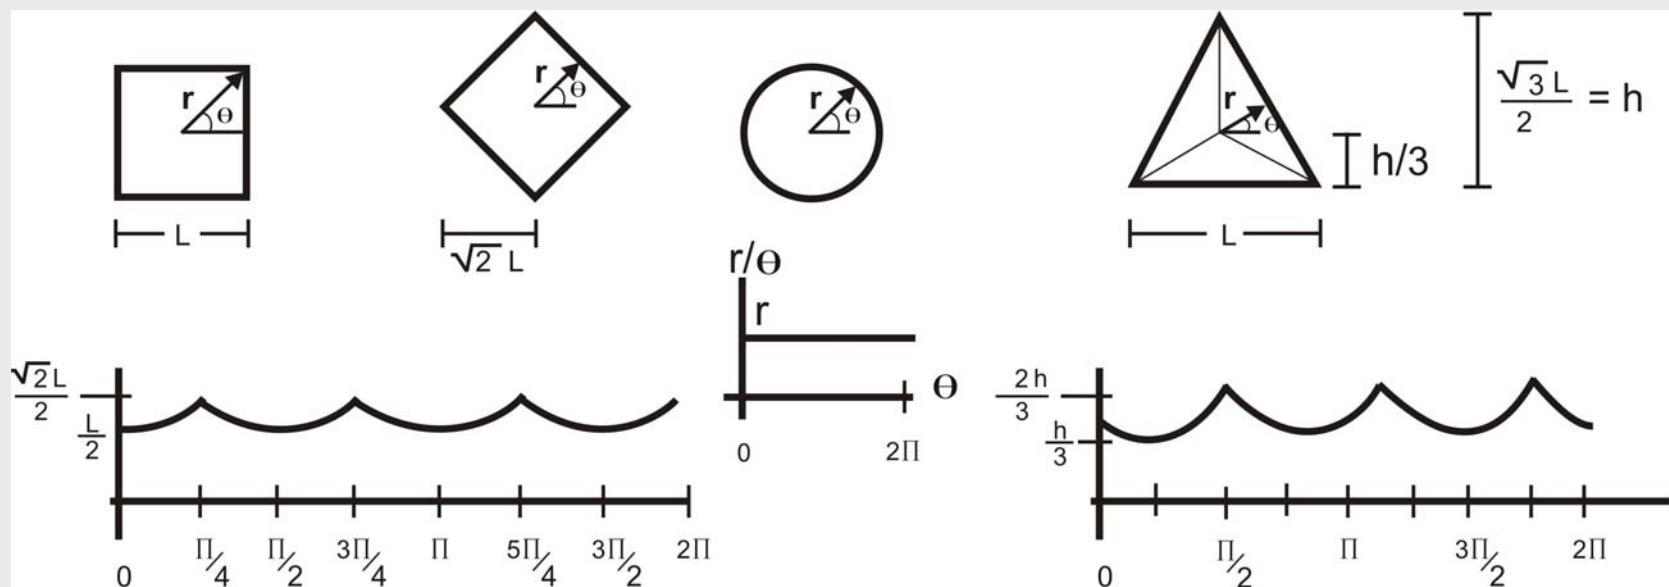


Figura 6.24 – Quatro objetos e suas assinaturas, ou gráficos  $r(\square)$ .

## 6.3.3.3. Transformada de Hough

Transformar a imagem do espaço digital ( $x,y$ ) para uma representação na forma dos parâmetros descritos pela curva que se deseja encontrar na imagem

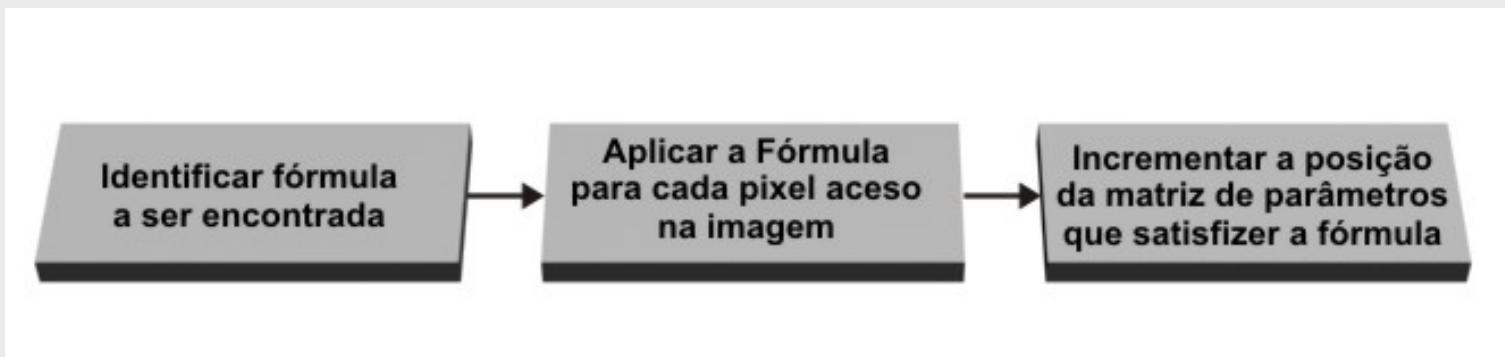
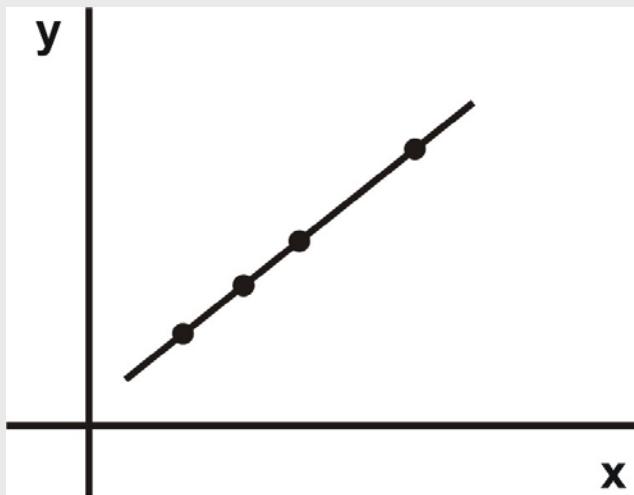


Figura 6.25. Etapas da aplicação da transformada de Hough para qualquer forma geométrica.

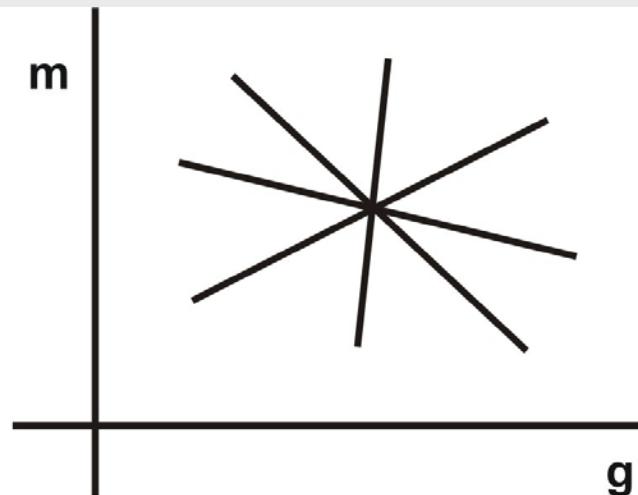
## Retas:

$$y = mx + g$$

(6.58)



espaço (x,y)



espaço de parâmetros(m,g)

Figura 6.26 – Cada ponto no espaço da imagem transforma-se em uma reta no espaço de parâmetro:  $g = -mx + y$ .

## Retas – forma polar:

$$\rho = x \cos \theta + y \sin \theta \quad (6.59)$$

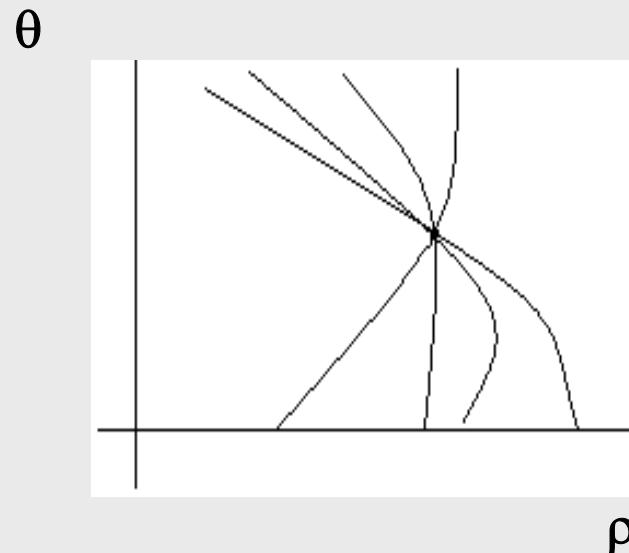
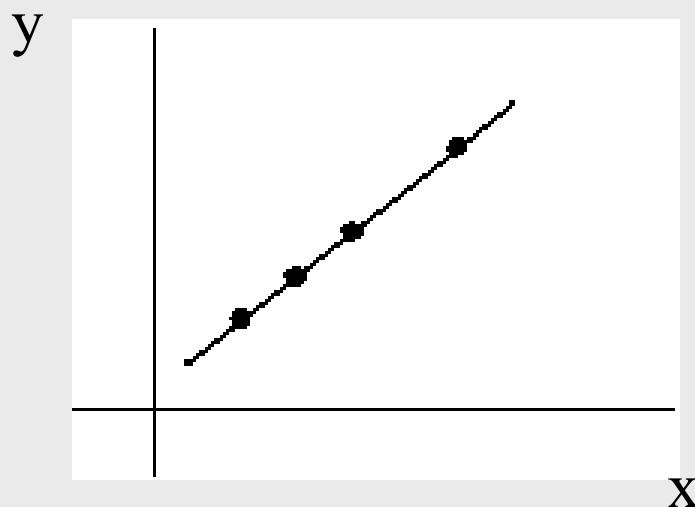


Figura 6.28 - Cada ponto  $P(x,y)$  no espaço da imagem, corresponde a uma senóide  $S(\rho,\theta)$  no espaço de parâmetros.

# Discretização da matriz acumuladora

- Para determinar o tamanho e os limites da matriz acumuladora, devem-se observar todos os parâmetros que compõem o espaço dos parâmetros.
- No caso das retas, é necessário ter a informação dos limites angulares de  $\theta$  e dos valores limite de  $\rho$ .
- Para uma imagem descrita entre os limites  $(0,0)$  e  $(N_1, N_2)$ , o parâmetro  $\rho$  se apresenta em um intervalo de -  $\sqrt{N_1^2 + N_2^2}$  a  $\sqrt{N_1^2 + N_2^2}$ .

# Detecção de formas cônicas

As cônicas (Figura 3.3 do Volume 1) são curvas obtidas pela interseção de um plano com um cone circular.

# Transformada de Hough para formas circulares

Formas circulares:

$$x = x_0 + \rho \cos \theta$$

$$y = y_0 + \rho \sin \theta$$

(6.67)

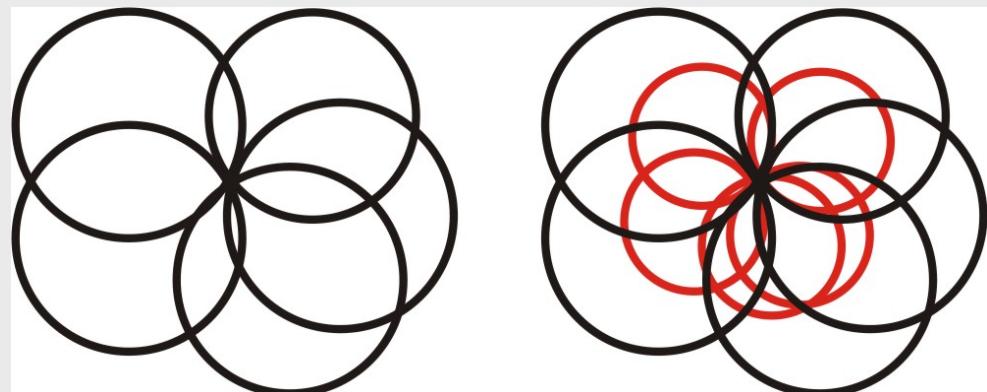


Figura 6.32 – Representação gráfica da transformada de Hough para círculos.

# Transformada de Hough para elipses

Elipses:

$$\rho^2 = \frac{s^2 t^2}{s^2 \sin^2 \tau + t^2 \cos^2 \tau} \quad (6.70)$$

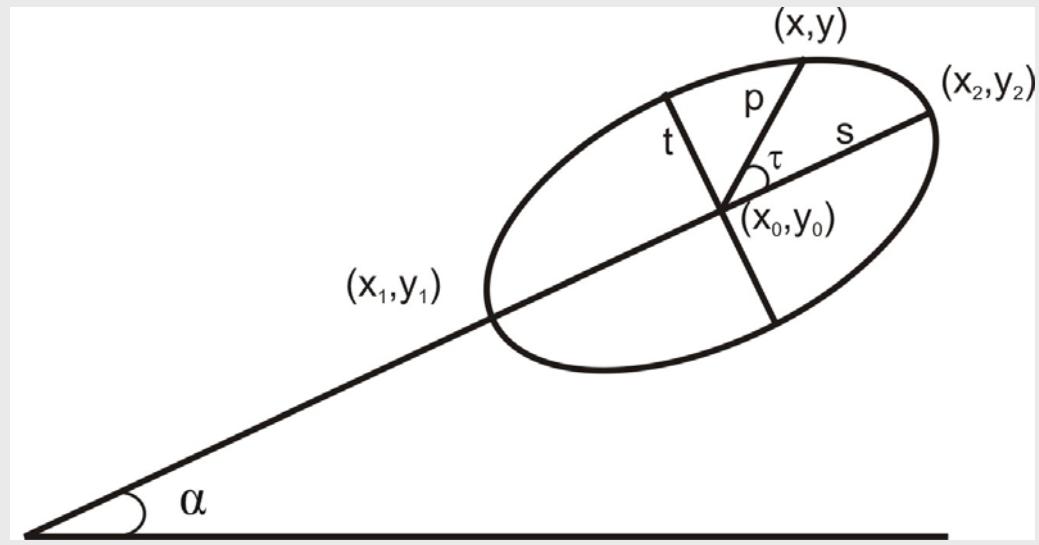


Figura 6.34 - Elipse inclinada com seus cinco parâmetros e coordenadas inicial e final de seu maior eixo.

# Transformada de Hough para parábolas

Paráboas:

$$\rho = \frac{2d}{1 - \cos \beta}$$

(6.84)

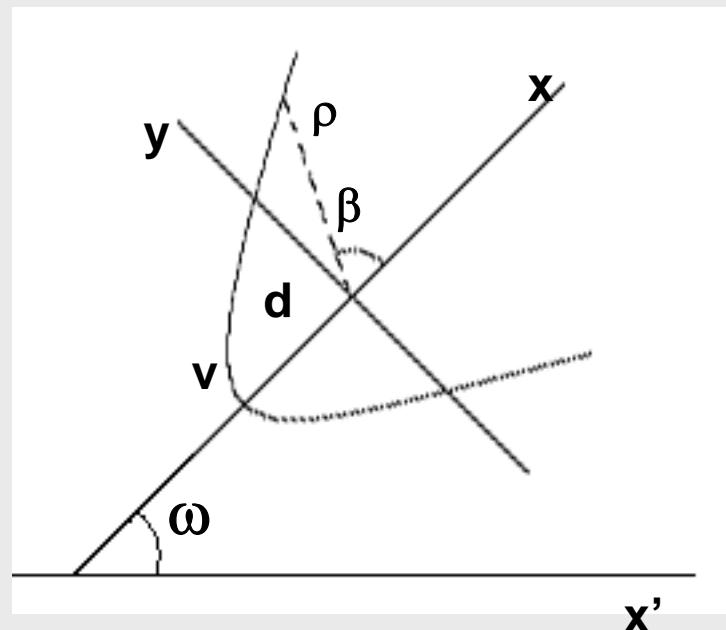


Figura 6.38 - Parábola rotacionada.

# Aproximação poligonal

O objetivo é capturar a essência da forma com o menor número possível de segmentos poligonais.

A fronteira digital pode ser aproximada com mais ou menos precisão por poligonais

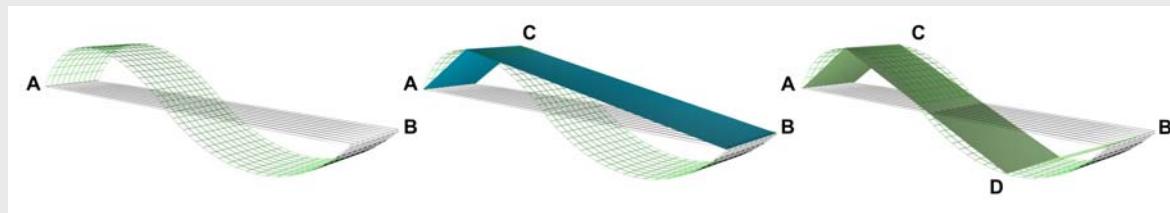


Figura 6.40- Borda original e 3 etapas do algoritmo 2 que a aproxima cor linhas retas. O ponto mais distande passa a ser o limite de cada subdivisão da poligonal.

# Características Topológicas

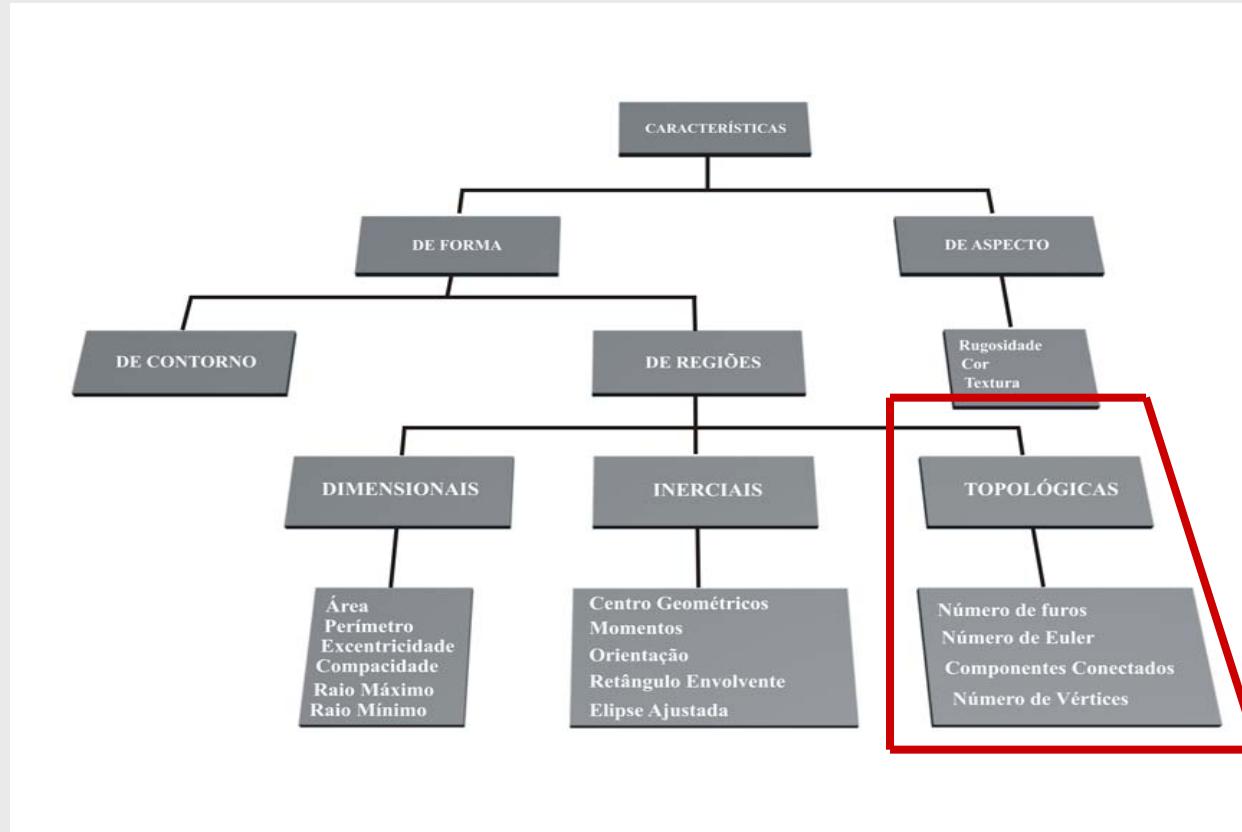


Figura 6.12 - Tipos de características.

Principais descritores topológicos:

- (1) Número de componentes conectados.
- (2) Número de furos.
- (3) Número de Euler.



Figura 6.41 - Distorção “folha de borracha”.

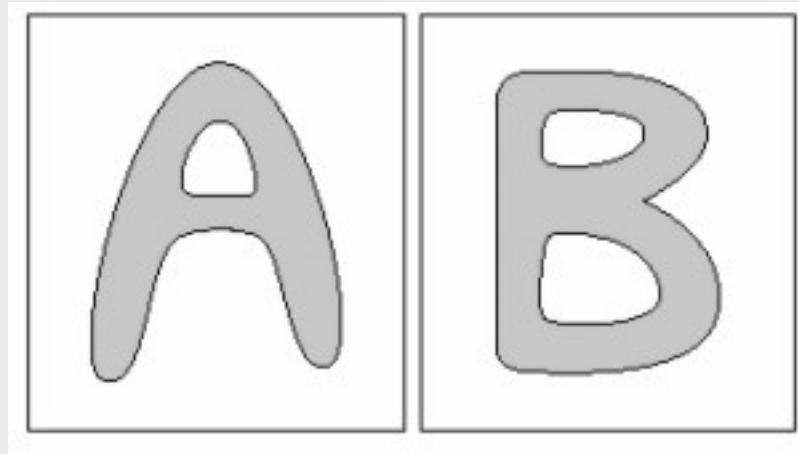


Figura 6.42 – Regiões com número de Euler igual a 0 a -1, respectivamente.

# Características de Aspecto

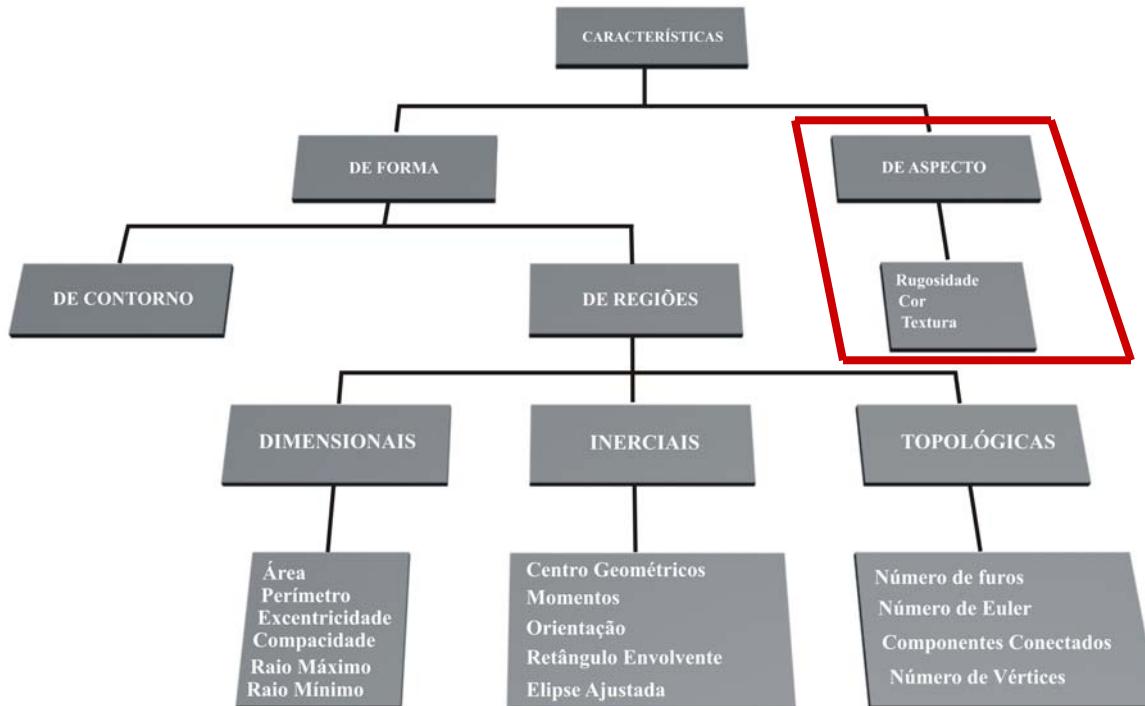


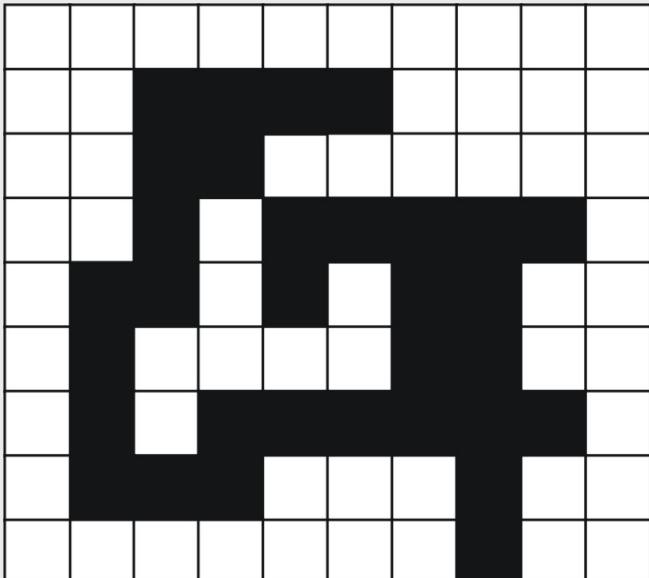
Figura 6.12 - Tipos de características.

# **Outras características**

## **6.3.6.1. Codificação de Corrida**

## **6.3.6.2. Histograma de Projeção**

# Codificação de Corrida



12(0), 4(1), 6(0), 2(1), 8(0), 1(1), 1(0), 5(1),  
2(0), 2(1), 1(0), 1(1), 1(0), 2(1), 3(0), 1(1),  
4(0), 2(1), 3(0), 1(1), 1(1), 1(0), 6(1),  
2(0), 3(1), 3(0), 1(1), 9(0), 1(1), 2(0)

Figura 6.43 – Codificação de Corrida.

# Histograma de Projeção

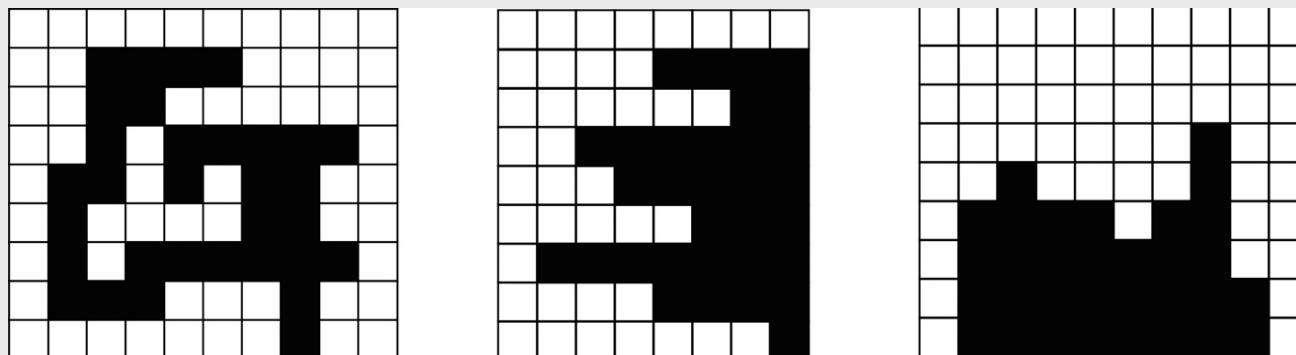


Figura 6.44 - Imagem binária e suas projeções horizontais e verticais.

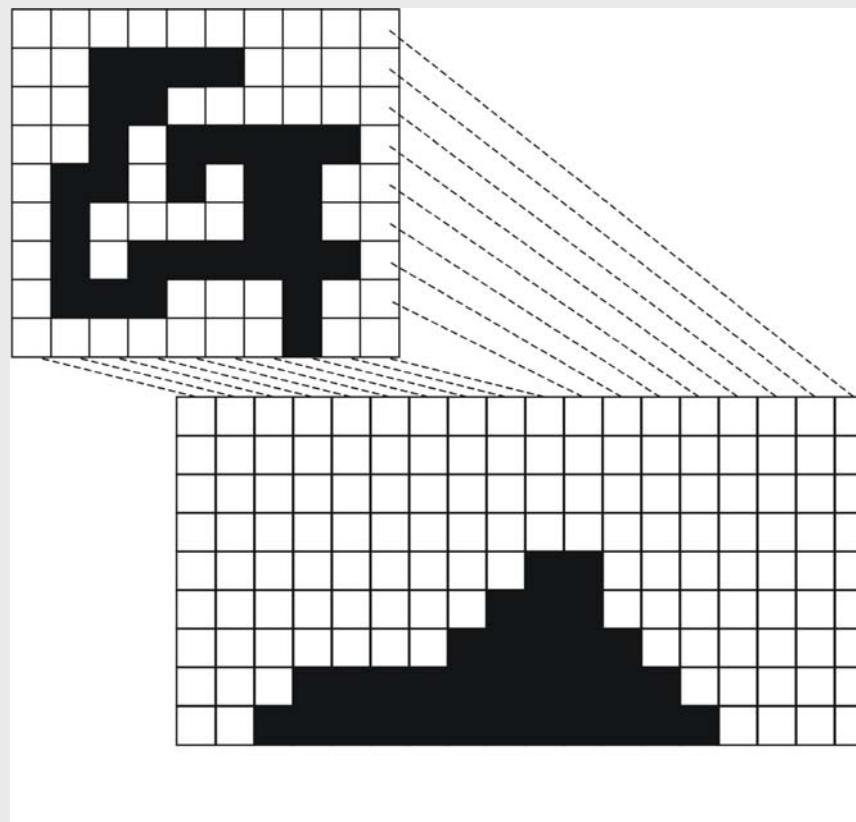


Figura 6.45 - Imagem binária e sua projeção diagonal.

# **Reconhecimento de Padrões em Imagens**

**6.4.1. Reconhecimento de Padrões**

**6.4.2. Classificação Supervisionada**

**6.4.3. Classificação Não Supervisionada**

**6.4.4. Redes Neurais Artificiais**

**6.4.5. Lógica Fuzzy**

# **Reconhecimento de Padrões**

- Abordagem estatística
- Abordagem sintática
- Abordagem neuronal
- Abordagem nebulosa

# Classificação Supervisionada

Etapas:

- Escolha de um conjunto de treinamento.
- Escolha dos parâmetros relevantes a serem medidos.
- Obtenção da função discriminante, que pode ser obtida por método não estatístico (distribuição livre) ou por método estatístico.
- Eliminação dos parâmetros não relevantes.
- Testes com objetos fora do conjunto de treinamento.

# Classificação por Distribuição Livre

Exemplos:

- funções discriminantes;
- vizinhança mais próxima;
- árvore de decisão.

## Funções discriminantes:

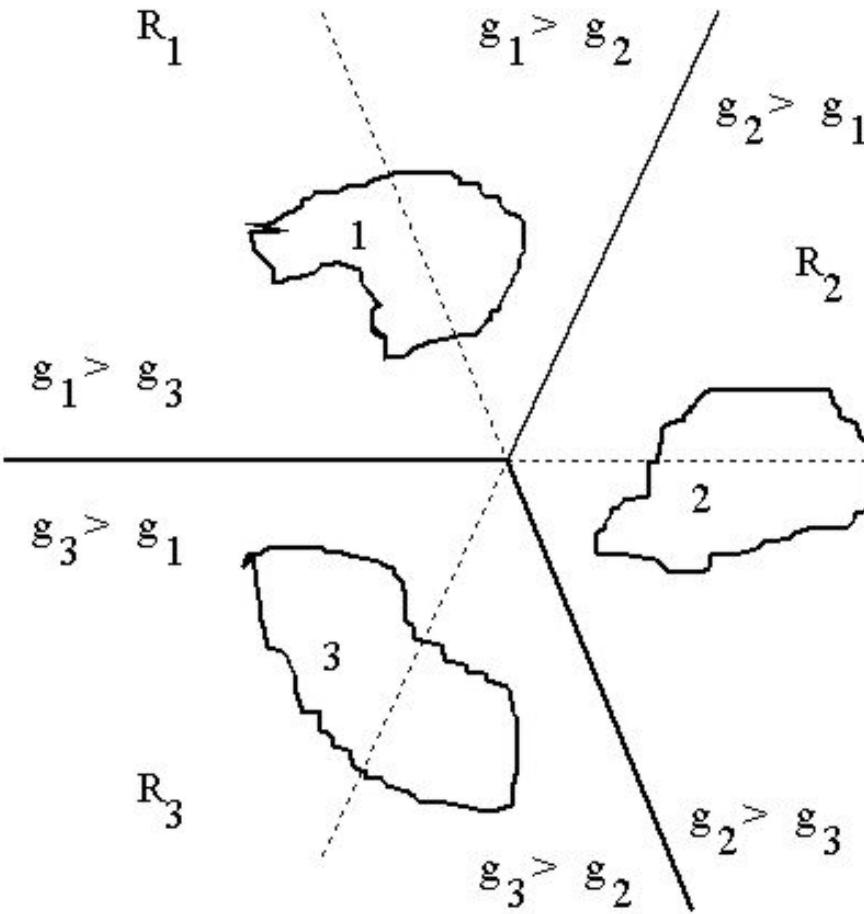


Figura 6.46 (a) - Divisão do espaço de características (problema de três classes) (Duda e Hart, 1973).

## Vizinhança mais próxima:

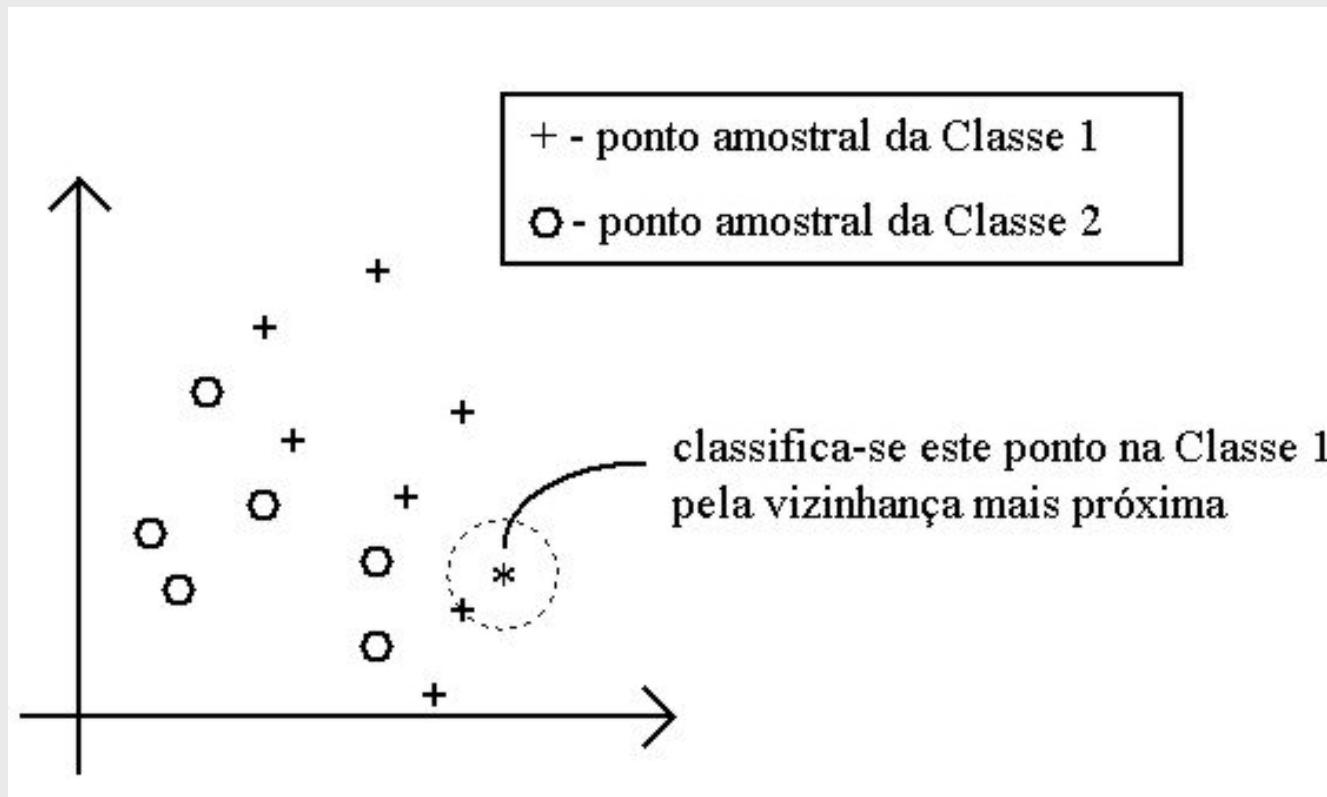


Figura 6.47 - Uma CVMP para duas classes em um espaço amostral [CHEN73].

## Árvore de decisão:

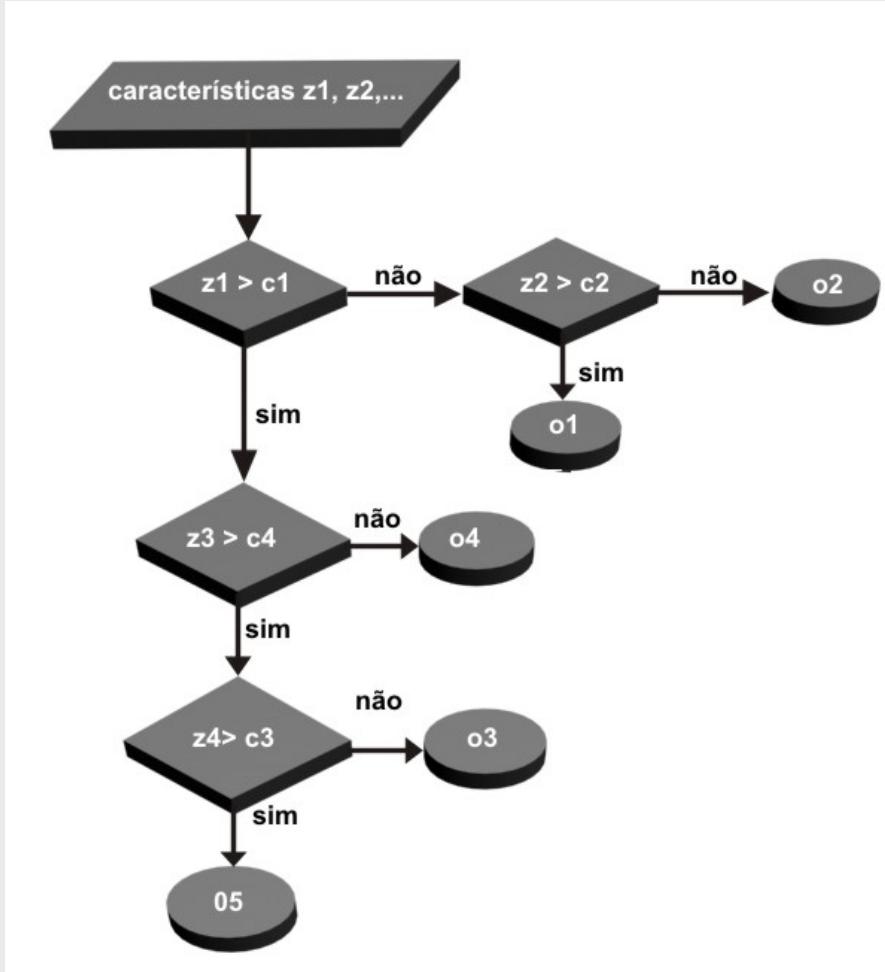


Figura 6.48 - Árvore de decisão.

# Por Distribuição Estatística

Classificador de Risco Mínimo de Bayes (CRMB):

$$\mathfrak{R} \cong \sum_{k=1}^K \int_{R_k} c(x / S_k) p(x) dx \quad (6.92)$$

A regra de decisão que minimiza  $\mathfrak{R}$  é dada por:

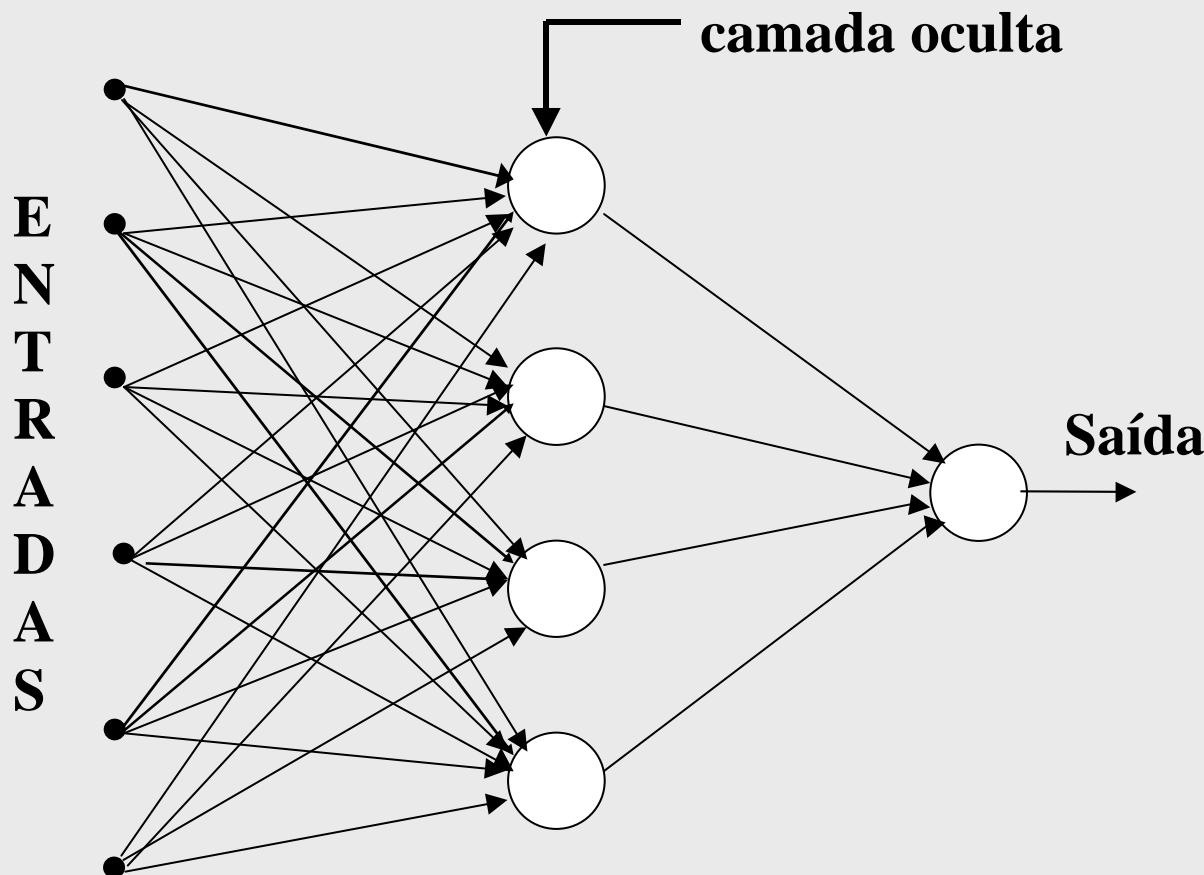
$$\sum_{i=1}^K c_{i,k} P(S_i) p(x / S_i) < \sum_{i=1}^K c_{i,j} P(S_i) p(x / S_i) , \\ \forall j \neq k \Rightarrow x \in S_k \quad (6.94)$$

# Classificação Não Supervisionada

Estabelecem-se *clusters* ou agrupamentos naturais no espaço de características, a partir da medida de diferentes parâmetros dos objetos.

Um *cluster* é um conjunto de pontos no espaço de características, que possuem densidade local máxima se comparada à densidade dos pontos ao redor.

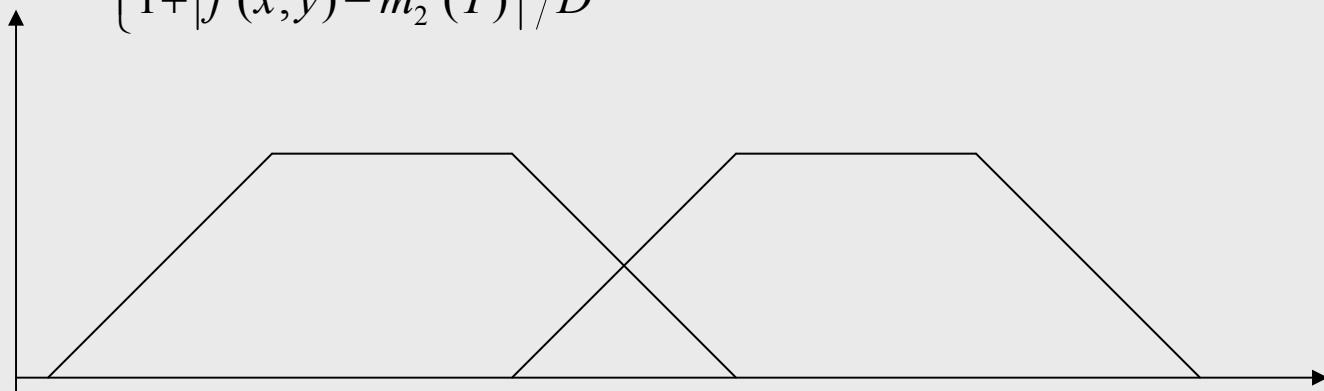
# Redes Neurais Artificiais



# Lógica Fuzzy

Função de pertinência:

$$\mu_I(f(x,y)) = \begin{cases} \frac{1}{1 + |f(x,y) - m_1(T)|/D} & \text{se } f(x,y) \leq T, \\ \frac{1}{1 + |f(x,y) - m_2(T)|/D} & \text{se } f(x,y) > T, \end{cases} \quad (6.97)$$



# **Texturas**

# DEFINIÇÕES

- Padrão visual que possui algumas propriedades de homogeneidade que não resultam simplesmente de uma cor ou intensidade.
- Constituída de elementos mutuamente relacionados: a primitiva de textura dependente de escala.
- Composta de um grande número de elementos similares mais ou menos ordenados.
- Relacionada com coeficientes de uniformidade, densidade, aspereza, regularidade, intensidade, dentre outros, oriundos da probabilidade de ocorrência de variações tonais.

# DEFINIÇÕES

- Descritas por medidas que quantificam suas propriedades de suavidade, rugosidade e regularidade.
- Características estatísticas ou propriedades estruturais locais constantes, com pouca variação ou aproximadamente periódicas.
- Relacionadas à variação de intensidade luminosa em partes das imagens.

# APLICAÇÕES

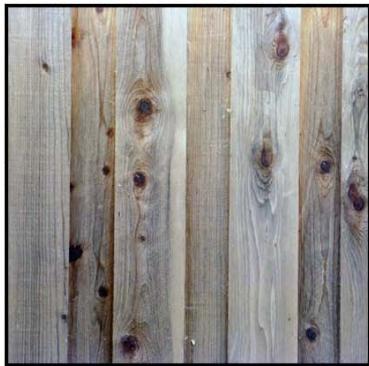
- Segmentação ou divisão de uma imagem em regiões.
- Descrição e extração de características.
- Classificação e rotulação de uma região.
- Análise de forma.
- Réplica.



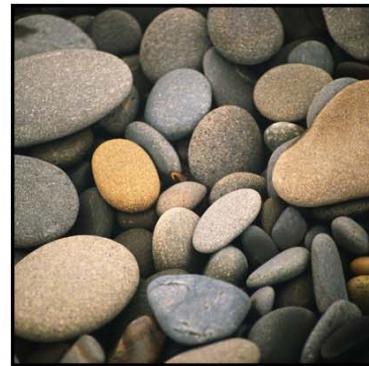
a) Água



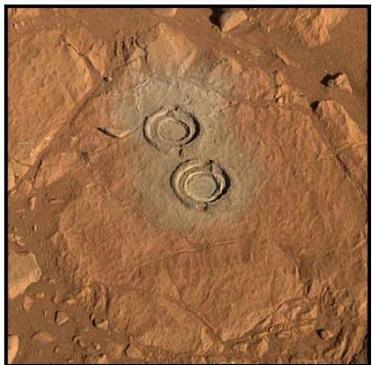
b) Folhas



c) Madeira



d) Pedra



e) Solo



f) Tecido



g) Tijolos



h) Vegetação

Figura 7.1 - Exemplos de texturas naturais (a,b,c,d,h) e artificiais (e,f,g).

	0	1	2	3	4	5	6
0	85	70	86	92	60	102	202
1	91	81	98	113	86	119	189
2	96	86	102	107	74	107	194
3	101	91	113	107	83	118	198
4	99	68	107	107	76	108	194
5	107	94	93	115	83	115	198
6	94	98	98	107	81	115	194

Figura 7.3 - Região de 7x7 pixels para cálculo do coeficiente de Hurst (Parker, 1997).

$\sqrt{18}$	$\sqrt{13}$	$\sqrt{10}$	3	$\sqrt{10}$	$\sqrt{13}$	$\sqrt{18}$
$\sqrt{13}$	$\sqrt{8}$	$\sqrt{5}$	2	$\sqrt{5}$	$\sqrt{8}$	$\sqrt{13}$
$\sqrt{10}$	$\sqrt{5}$	$\sqrt{2}$	1	$\sqrt{2}$	$\sqrt{5}$	$\sqrt{10}$
3	2	1	0	1	2	3
$\sqrt{10}$	$\sqrt{5}$	$\sqrt{2}$	1	$\sqrt{2}$	$\sqrt{5}$	$\sqrt{10}$
$\sqrt{13}$	$\sqrt{8}$	$\sqrt{5}$	2	$\sqrt{5}$	$\sqrt{8}$	$\sqrt{13}$
$\sqrt{18}$	$\sqrt{13}$	$\sqrt{10}$	3	$\sqrt{10}$	$\sqrt{13}$	$\sqrt{18}$

Figura 7.4 - Oito grupos de pixels correspondentes às distâncias.

## Aplicação:



(a)



(b)



(c)

Figura 7.5. Exemplo de uso do CVE: (a) Melanoma; (b) Segmentação considerando a área interior e (c) Localização do contorno ampliado.

# **Dimensão Fractal**

**7.6.1. Estimando a Dimensão Fractal de  
Imagens Binárias**

**7.6.2. Estimando a Dimensão Fractal de  
Imagens em Escala de Cinza**

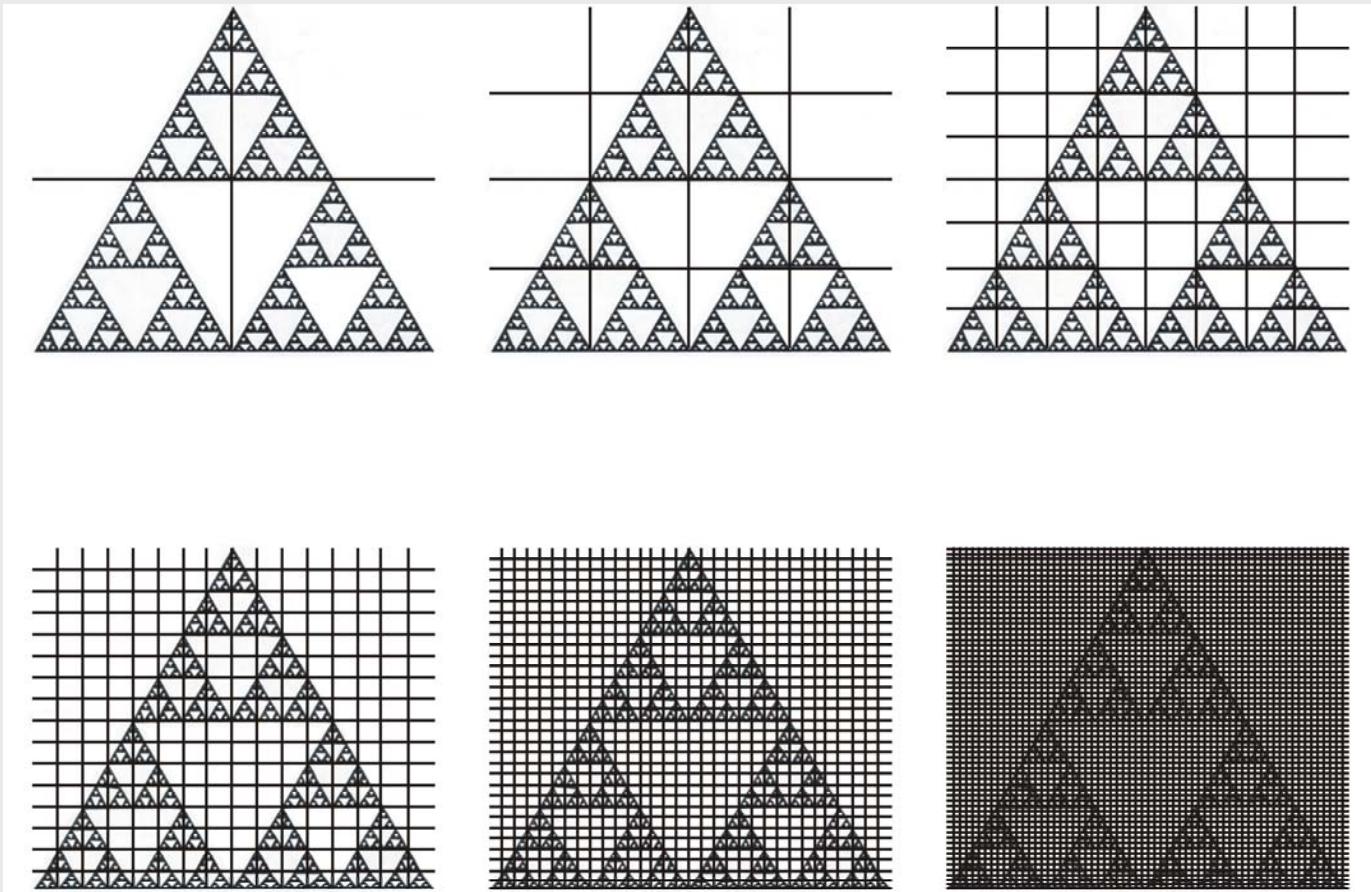


Figura 7.14 - Divisão recursiva da imagem triângulo de Sierpinsky.